

Convergência, Desigualdades e Leis dos Grandes Números

Resumo consolidado de 8 quadros de aula · Probabilidade / Inferência · Desigualdades e convergência

1 · Motivação: da amostra ao estimador

- Sejam $Y_1, \dots, Y_n$ v.a. i.i.d. com $E(Y_i) = \mu$ e $\text{Var}(Y_i) = \sigma^2$.
Objetivo: a partir das realizações de Y , estimar μ .

- Estratégia:** usar a versão empírica de μ — a média amostral.

$$\hat{\mu} = \bar{Y}_n = (1/n) \sum_{i=1}^n Y_i$$

- $\hat{\mu}$ é v.a.? **Sim** — é função de v.a., logo tem distribuição própria: a **distribuição amostral**.
- A amostral exata às vezes é fácil de obter; quando não é, resta **aproximar** ou resumir a distribuição por medidas:

$$E(\hat{\mu}) = \mu \quad \text{Var}(\hat{\mu}) = \sigma^2/n$$

2 · Sequência de variáveis aleatórias

- Dadas $X_1, \dots, X_n$ com f.p./f.d.p. $f(\cdot)$ e uma função qualquer $g(\cdot)$, define-se a sequência $Y_1 = g(X_1)$, $Y_2 = g(X_1, X_2)$, ..., $Y_n = g(X_1, \dots, X_n)$.
- Ex. (moeda):** $X = 1$ se cara, $X = 0$ se coroa $\Rightarrow Y_1 = X_1$, $Y_2 = (X_1 + X_2)/2$, ..., $Y_n = (X_1 + \dots + X_n)/n$.
- Estatísticas amostrais que dependem de n são sequências de v.a.: média $\sum x_i/n$ e variância $\sum (x_i - \bar{x})^2/(n-1)$.

3 · Convergência em probabilidade

$\{Y_n\}_{n \geq 1}$ converge em probabilidade para uma constante ou v.a. Y se, para todo $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|Y_n - Y| > \varepsilon) = 0 \quad \Rightarrow \quad \text{notação: } Y_n \xrightarrow{P} Y$$

- Equivalência a $(Y_n - Y) \xrightarrow{P} 0$: a massa de probabilidade fora de qualquer faixa $\pm \varepsilon$ em torno do alvo some quando n cresce.

4 · Desigualdade de Markov

Y v.a. **não negativa** com $E(Y) = \mu$ e $\varepsilon > 0$ arbitrário:

$$P(Y \geq \varepsilon) \leq E(Y)/\varepsilon$$

- Prova (contínuo):** $E(Y) = \int_0^\infty y f(y) dy \geq \int_\varepsilon^\infty y f(y) dy \geq \varepsilon \int_\varepsilon^\infty f(y) dy = \varepsilon \cdot P(Y \geq \varepsilon)$.
- Prova (v.a. auxiliar):** $X = 0$ se $Y < \varepsilon$ e $X = \varepsilon$ se $Y \geq \varepsilon$. Como $X \leq Y$, $E(X) = \varepsilon \cdot P(Y \geq \varepsilon) \leq E(Y)$.

5 · Desigualdade de Chebyshev

Y com $E(Y) = \mu$ e $\text{Var}(Y) = \sigma^2$ **ambos finitos**; $\forall \varepsilon > 0$:

$$P(|Y - \mu| > \varepsilon) \leq \text{Var}(Y)/\varepsilon^2 = \sigma^2/\varepsilon^2$$

- Prova:** $P(|Y - \mu| > \varepsilon) = P((Y - \mu)^2 > \varepsilon^2)$ por monotonia; aplicando Markov à v.a. não negativa $(Y - \mu)^2$, obtém-se $E[(Y - \mu)^2]/\varepsilon^2 = \sigma^2/\varepsilon^2$.
- Corolário:** para $\psi(\cdot)$ monótona, $P(\psi(|Y|) > \psi(\varepsilon)) \leq E[\psi(|Y|)]/\psi(\varepsilon)$ — Markov e Chebyshev são casos particulares.

6 · Leis dos grandes números

- Lei fraca (Chebyshev):** Y_i i.i.d. com μ e σ^2 **finitos** $\Rightarrow \bar{Y}_n \xrightarrow{P} \mu$.
- Prova:** $E(\bar{Y}_n) = \mu$ e $\text{Var}(\bar{Y}_n) = \sigma^2/n$; por Chebyshev, $P(|\bar{Y}_n - \mu| > \varepsilon) \leq \sigma^2/(n \varepsilon^2) \rightarrow 0$ quando $n \rightarrow \infty$.
- Lei de Kolmogorov:** basta $E(|Y_i|) < \infty$ e $E(Y_i) = \mu$ para ter $\bar{Y}_n \xrightarrow{P} \mu$ — **não exige variância finita**.
- A condição $E(|Y_i|) = \int |y| f(y) dy < \infty$ **controla as caudas** da distribuição (caudas pesadas, tipo Gumbel, quebram a convergência).

7 · Exercício aplicado — moeda viciada ($p = 0,20$, $n = 20$ lançamentos)

$X = n^\circ$ de caras $\Rightarrow X \sim \text{Bin}(20; 0,2)$, com $E(X) = np = 4$ e $\text{Var}(X) = np(1-p) = 3,2$. Pede-se um limite superior para $P(X \geq 16)$ e a comparação com o valor exato:

Abordagem	Conta	Resultado	Informação usada
Markov	$P(X \geq 16) \leq E(X)/16 = 4/16$	0,25	só a média ($E(X) = 4$)
Chebyshev (complemento)	$P(X - 4 \geq 12) \leq 3,2/12^2$	$\approx 0,0222$	média e variância ($\sigma^2 = 3,2$)
Binomial exata	$\sum_{x=16}^{20} C(20,x) 0,2^x 0,8^{20-x}$	$\approx 1,4 \times 10^{-8}$	a distribuição completa

Leitura do exercício: o limite de Markov é **válido, porém extremamente frouxo** — sete ordens de grandeza acima do valor exato. É o preço de usar apenas a média: quanto mais informação da distribuição se usa, mais apertado fica o limite.

PRINCIPAIS CONCLUSÕES

- A média amostral é v.a.: tem distribuição amostral própria, resumida por $E(\hat{\mu}) = \mu$ e $\text{Var}(\hat{\mu}) = \sigma^2/n$.
- Markov e Chebyshev limitam probabilidades de cauda **sem conhecer a distribuição** — bastam μ (e σ^2).
- Chebyshev é Markov aplicada a $(Y - \mu)^2$; ambas são casos do corolário com $\psi(\cdot)$ monótona.
- A lei fraca sai em três linhas: $\text{Var}(\bar{Y}_n) = \sigma^2/n \rightarrow 0$ força $P(|\bar{Y}_n - \mu| > \varepsilon) \rightarrow 0$.
- Kolmogorov troca a exigência de σ^2 finita por $E(|Y|) < \infty$: o que realmente importa é o controle das caudas.

PRÓXIMOS PASSOS

- Verificar numericamente o quanto Chebyshev aperta o limite frente a Markov em outros valores de ε .
- Separar convergência **em probabilidade** (lei fraca) de convergência **quase certa** (lei forte).
- Avançar para convergência em distribuição e o Teorema Central do Limite — a aproximação que falta.
- Aplicar as leis à consistência de estimadores e à distribuição amostral de $\hat{\mu}$ para n finito.