

Dados Pareados, Proporções e Intervalos de Confiança

Resumo consolidado de 19 quadros de aula · CE309 Inferência Estatística · Dados pareados, proporções e estimação por intervalo

1 · Diferença de médias com dados pareados

Amostra de **pares** $(X_1, Y_1), \dots, (X_n, Y_n)$ com $X_i \sim N(\mu_1, \sigma_1^2)$ e $Y_i \sim N(\mu_2, \sigma_2^2)$ **dependentes**. Trabalha-se com $D_i = X_i - Y_i$:

$$D = X - Y = \sum (X_i - Y_i)/n \sim N(\mu_1 - \mu_2, \sigma_D^2/n)$$

- $\sigma_D^2 = \text{Var}(X_i) + \text{Var}(Y_i) - 2\text{Cov}(X_i, Y_i)$ — a covariância é **desconhecida**, e é justamente ela que o pareamento aproveita.
- Estimando σ_D^2 por $S_D^2 = \sum (d_i - \bar{d})^2/(n-1)$, a padronização vira uma t :

$$(D - \mu_D)/(S_D/\sqrt{n}) \sim t_{n-1}$$

- Ex. (colesterol, 15 homens, antes x depois de 3 meses de dieta):** $\bar{d} = -26,87$, $S_D = 19,04$. Sob $\mu_1 = \mu_2$: $P(D \leq -26,87) = P(t_{14} \leq -5,466) \approx 0$ — a queda observada é praticamente impossível se as médias fossem iguais.

2 · Diferença de proporções

$X \sim B(p_1)$ com a.a. de tamanho m e $Y \sim B(p_2)$ com a.a. de tamanho n , independentes. Para $m + n$ grande, o TCL aproxima cada proporção e também a diferença:

$$\hat{p}_1 - \hat{p}_2 \sim^A N(p_1 - p_2, p_1(1-p_1)/m + p_2(1-p_2)/n)$$

- Padronizando chega-se a $N(0,1)$; sob a hipótese $p_1 = p_2$, a média da diferença é 0.
- Ex. (chefes de família):** $30/120 = 0,25$ e $50/150 = 0,33 \Rightarrow$ diferença observada 0,08. $P(|\hat{p}_1 - \hat{p}_2| > 0,08) = P(|Z| > 1,45) = 0,147$ — acima de 0,05, ou seja, compatível com proporções populacionais iguais.

3 · Intervalo de confiança: como se constrói

- Ponto de partida: o **estimador pontual** e sua distribuição amostral. Para μ com σ^2 conhecida, $\hat{\mu} = \bar{Y} \sim N(\mu, \sigma^2/n)$, logo $(\bar{Y} - \mu)/(\sigma/\sqrt{n}) \sim N(0,1)$.
- Fixa-se a probabilidade $1 - \alpha$ (**nível de confiança**) e buscam-se limites com $P(\bar{Y}_{Li} < \mu < \bar{Y}_{Us}) = 1 - \alpha$. Vários pares servem; escolhem-se os **simétricos**, deixando $\alpha/2$ em cada cauda.

$$P(\bar{Y} - z_{\alpha/2} \sigma/\sqrt{n} < \mu < \bar{Y} + z_{\alpha/2} \sigma/\sqrt{n}) = 1 - \alpha$$

- Margem de erro** (erro máximo provável): $e = z_{\alpha/2} \cdot \sigma/\sqrt{n}$.

4 · Interpretação e escolhas práticas

- O intervalo é aleatório, não o parâmetro.** Repetindo o experimento 100 vezes, espera-se que $(1-\alpha) \cdot 100$ dos intervalos construídos contenham o valor verdadeiro.
- Com σ^2 **desconhecida** e população normal, troca-se z por t_{n-1} — caudas mais largas compensam a estimação de σ por S .
- Na proporção, a margem de erro depende do próprio p : usa-se $\hat{p}$ (intervalo **otimista**) ou 0,5 (intervalo **conservador**, que maximiza $p(1-p)$ e dá a maior amplitude).
- Para σ^2 o intervalo é **assimétrico**: a χ^2 não é simétrica, então os dois quantis são diferentes.
- Ex. 1 (débitos de cartão):** $n = 15$, $\bar{y} = 5900$, $S = 3058$, 95% $\Rightarrow t_{14;0,025} = 2,1448 \Rightarrow \text{IC} = [4206,37; 7593,63]$. Como 5000 pertence ao intervalo, não há evidência contra $\mu = 5000$.
- Ex. 2 (aquecimento global):** $n = 1500$, $\hat{p} = 1050/1500 = 0,7$, 99% $\Rightarrow z = 2,576$. Otimista: $[0,6695; 0,7304]$; conservador: $[0,6682; 0,7332]$ — quase idênticos porque n é grande.

5 · Formulário de intervalos de confiança

Parâmetro	Suposições	Intervalo de confiança de $(1 - \alpha) \cdot 100\%$
μ	população normal (ou n grande) e σ^2 conhecida	$\bar{y} \pm z_{\alpha/2} \cdot \sigma/\sqrt{n}$ (margem de erro $e = z_{\alpha/2} \sigma/\sqrt{n}$)
μ	população normal e σ^2 desconhecida	$\bar{y} \pm t_{n-1; \alpha/2} \cdot S/\sqrt{n}$
p	n grande (TCL)	$\hat{p} \pm z_{\alpha/2} \sqrt{(\hat{p}(1-\hat{p}))/n}$ — conservador: trocar $\hat{p}$ por 0,5
σ^2	população normal — $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$	$[(n-1)S^2 / \chi^2_{\alpha/2; n-1}; (n-1)S^2 / \chi^2_{1-\alpha/2; n-1}]$
$\mu_1 - \mu_2$	duas normais independentes, σ^2 conhecidas	$(\bar{y}_1 - \bar{y}_2) \pm z_{\alpha/2} \sqrt{(\sigma_1^2/n + \sigma_2^2/m)}$
$\mu_1 - \mu_2$	σ^2 desconhecidas e iguais	$(\bar{y}_1 - \bar{y}_2) \pm t_{n+m-2; \alpha/2} \cdot S_p \sqrt{(1/m + 1/n)}$
μ_D (pareados)	decorre da distribuição amostral de D	$\bar{d} \pm t_{n-1; \alpha/2} \cdot S_D/\sqrt{n}$

Fio condutor da disciplina: população $\rightarrow$ característica Y com distribuição $\rightarrow$ amostragem (AAS) $\rightarrow$ estatística $T = f(y) \rightarrow$ **distribuição amostral** $\rightarrow$ estimador pontual ($\bar{Y} \rightarrow \hat{\mu}$, pela LGN) $\rightarrow$ **estimação por intervalo**, usando o TCL quando a distribuição exata não está disponível.

PRINCIPAIS CONCLUSÕES

- Dados pareados não são duas amostras independentes: reduz-se tudo a **uma** amostra de diferenças D_i , e a covariância deixa de ser um problema.
- Toda a construção do IC é a mesma receita: distribuição amostral do estimador $\rightarrow$ padronizar $\rightarrow$ isolar o parâmetro entre dois quantis simétricos.
- Quem muda é só o quantil: z (σ^2 conhecida ou n grande), t (σ^2 estimada) e χ^2 (variância, com intervalo assimétrico).
- O intervalo é aleatório e o parâmetro é fixo — “95% de confiança” é uma afirmação sobre o procedimento, não sobre μ .
- IC e teste conversam: 5000 dentro do IC de débitos e $0,147 > 0,05$ nas proporções levam à mesma leitura de “sem evidência contra a hipótese”.

PRÓXIMOS PASSOS

- Terminar a lista de IC (CE309): item 3 — IC de 90% para a variância dos diâmetros de 20 parafusos (χ^2).
- Item 4 — IC de 95% para a diferença de gastos médios (duas amostras de 50, médias 62 e 71, $\sigma = 20$).
- Estudar o dimensionamento de n a partir da margem de erro desejada.
- Formalizar a ponte com os **testes de hipóteses** ($H_0: \mu = 5000$ já apareceu na resolução).