

CE309 – Inferência Estatística

Guia de Estudos: Propriedades de Estimadores e Método dos Momentos

Material de apoio para a Lista 6

Sumário

1	Preliminares: o problema de estimação	2
2	Ferramentas de esperança e variância	2
2.1	Resultados sob normalidade	4
2.2	Estatísticas de ordem: máximo e mínimo	4
3	Viés e não-vício	5
4	Erro quadrático médio	5
4.1	Comparação de estimadores	6
4.2	Limite inferior de Cramér–Rao (ponte para verossimilhança)	6
5	Consistência	7
5.1	As desigualdades que fazem o trabalho	7
5.2	Relações entre os tipos de consistência	8
5.3	Lei dos Grandes Números e funções contínuas	8
5.4	Quando um estimador <i>não</i> é consistente	9
5.5	Consistência via f.d.a. (útil para máximos e mínimos)	9
6	Método dos momentos	9
7	Tabela de momentos de referência	10
8	Exemplos resolvidos à mão	10
9	Roteiros de prova (checklist)	14

1 Preliminares: o problema de estimação

Definição 1.1 (Modelo estatístico e amostra aleatória). Seja Y uma variável aleatória com função de densidade (ou de probabilidade) $f(y; \theta)$, em que $\theta \in \Theta \subseteq \mathbb{R}^p$ é um parâmetro desconhecido e Θ é o *espaço paramétrico*. Dizemos que $Y_1, \dots, Y_n$ é uma *amostra aleatória* (a.a.) de Y se as Y_i são independentes e identicamente distribuídas (i.i.d.) com a mesma distribuição de Y . A densidade conjunta é

$$f(y_1, \dots, y_n; \theta) = \prod_{i=1}^n f(y_i; \theta).$$

Definição 1.2 (Estatística, estimador e estimativa). Uma *estatística* é qualquer função $T = T(Y_1, \dots, Y_n)$ da amostra que **não depende** de θ . Um *estimador* de θ (ou de uma função $\tau(\theta)$) é uma estatística usada para aproximar θ . O valor numérico $t = T(y_1, \dots, y_n)$ obtido com os dados observados é a *estimativa*.

Observação 1.1. O estimador é uma **variável aleatória**; a estimativa é um **número**. Todas as propriedades deste guia (viés, variância, EQM, consistência) são propriedades da *distribuição amostral* do estimador, isto é, de como ele se comportaria em repetidas amostras. Por isso calculamos $\mathbb{E}_\theta(T)$, $\text{Var}_\theta(T)$ etc., sempre sob o valor verdadeiro θ . O índice θ em $\mathbb{E}_\theta$ lembra que a esperança é calculada usando $f(\cdot; \theta)$.

Notações usadas ao longo do texto:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i, \quad \mu = \mathbb{E}(Y), \quad \sigma^2 = \text{Var}(Y), \quad Y_{(1)} = \min_i Y_i, \quad Y_{(n)} = \max_i Y_i.$$

2 Ferramentas de esperança e variância

Quase tudo nesta lista se reduz a calcular esperanças e variâncias de somas. Revisamos as regras com *demonstração*.

Teorema 2.1 (Linearidade da esperança). Para constantes $a_1, \dots, a_n, b$ e variáveis aleatórias $Y_1, \dots, Y_n$ com esperança finita (**não é preciso independência**):

$$\mathbb{E}\left(b + \sum_{i=1}^n a_i Y_i\right) = b + \sum_{i=1}^n a_i \mathbb{E}(Y_i).$$

Demonstração. Segue da linearidade da integral (ou da soma, no caso discreto): $\mathbb{E}(aX + bW) = \iint (ax + bw)f(x, w) dx dw = a\mathbb{E}(X) + b\mathbb{E}(W)$; o caso geral sai por indução. $\square$

Teorema 2.2 (Variância de combinação linear).

$$\text{Var}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(Y_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(Y_i, Y_j).$$

Se as Y_i são independentes, $\text{Cov}(Y_i, Y_j) = 0$ para $i \neq j$ e

$$\text{Var}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(Y_i).$$

Demonstração. Seja $S = \sum_i a_i Y_i$, com $\mathbb{E}(S) = \sum_i a_i \mu_i$. Então $S - \mathbb{E}(S) = \sum_i a_i (Y_i - \mu_i)$ e

$$\text{Var}(S) = \mathbb{E}\left[\left(\sum_i a_i (Y_i - \mu_i)\right)^2\right] = \mathbb{E}\left[\sum_i \sum_j a_i a_j (Y_i - \mu_i)(Y_j - \mu_j)\right] = \sum_i \sum_j a_i a_j \text{Cov}(Y_i, Y_j).$$

Separando os termos $i = j$ (que dão $a_i^2 \text{Var}(Y_i)$) dos termos $i \neq j$ (que aparecem em pares) obtemos a fórmula. Independência implica $\mathbb{E}(Y_i Y_j) = \mathbb{E}(Y_i) \mathbb{E}(Y_j)$, logo $\text{Cov}(Y_i, Y_j) = 0$. $\square$

Observação 2.1 (Duas fórmulas usadas o tempo todo).

$$\text{Var}(Y) = \mathbb{E}(Y^2) - [\mathbb{E}(Y)]^2 \iff \mathbb{E}(Y^2) = \text{Var}(Y) + [\mathbb{E}(Y)]^2.$$

$$\text{Var}(aY + b) = a^2 \text{Var}(Y).$$

Teorema 2.3 (Média amostral). Se $Y_1, \dots, Y_n$ é a.a. de Y com $\mathbb{E}(Y) = \mu$ e $\text{Var}(Y) = \sigma^2 < \infty$ (qualquer distribuição), então

$$\mathbb{E}(\bar{Y}) = \mu, \quad \text{Var}(\bar{Y}) = \frac{\sigma^2}{n}.$$

Demonstração. Tomando $a_i = 1/n$ nos dois teoremas anteriores:

$$\mathbb{E}(\bar{Y}) = \sum_{i=1}^n \frac{1}{n} \mu = \frac{n\mu}{n} = \mu, \quad \text{Var}(\bar{Y}) = \sum_{i=1}^n \frac{1}{n^2} \sigma^2 = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

$\square$

Lema 2.4 (Identidade da soma de quadrados).

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2.$$

Demonstração. Expandindo o quadrado e usando $\sum_i Y_i = n\bar{Y}$:

$$\sum_{i=1}^n (Y_i^2 - 2Y_i \bar{Y} + \bar{Y}^2) = \sum_{i=1}^n Y_i^2 - 2\bar{Y} \sum_{i=1}^n Y_i + n\bar{Y}^2 = \sum_{i=1}^n Y_i^2 - 2n\bar{Y}^2 + n\bar{Y}^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2.$$

$\square$

Teorema 2.5 (Esperança da soma de quadrados centrada). Sob as hipóteses do Teorema 2.3 (qualquer distribuição com variância finita),

$$\mathbb{E}\left[\sum_{i=1}^n (Y_i - \bar{Y})^2\right] = (n-1)\sigma^2.$$

Demonstração. Pelo Lema 2.4 e linearidade, $\mathbb{E}[\sum_i (Y_i - \bar{Y})^2] = \sum_i \mathbb{E}(Y_i^2) - n\mathbb{E}(\bar{Y}^2)$. Pela Observação acima:

$$\mathbb{E}(Y_i^2) = \sigma^2 + \mu^2, \quad \mathbb{E}(\bar{Y}^2) = \text{Var}(\bar{Y}) + [\mathbb{E}(\bar{Y})]^2 = \frac{\sigma^2}{n} + \mu^2.$$

Logo

$$\mathbb{E}\left[\sum_{i=1}^n (Y_i - \bar{Y})^2\right] = n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) = n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2 = (n-1)\sigma^2.$$

□

Observação 2.2 (Por que $n-1$?). Ao trocar μ (desconhecido) por $\bar{Y}$, a soma $\sum (Y_i - \bar{Y})^2$ fica *sistematicamente menor* que $\sum (Y_i - \mu)^2$, pois $\bar{Y}$ é o valor de c que minimiza $\sum (Y_i - c)^2$. Os desvios $Y_i - \bar{Y}$ satisfazem a restrição $\sum_i (Y_i - \bar{Y}) = 0$: só $n-1$ deles são “livres” (graus de liberdade).

2.1 Resultados sob normalidade

Teorema 2.6 (Teorema de Fisher / Cochran – enunciado). Se $Y_1, \dots, Y_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$, então:

- (i) $\bar{Y} \sim N(\mu, \sigma^2/n)$;
- (ii) $\frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{\sigma^2} \sim \chi_{n-1}^2$;
- (iii) $\bar{Y}$ e $\sum_{i=1}^n (Y_i - \bar{Y})^2$ são independentes.

Proposição 2.7 (Momentos da qui-quadrado). Se $W \sim \chi_k^2$, então $\mathbb{E}(W) = k$ e $\text{Var}(W) = 2k$.

Demonstração. Use a representação $W = \sum_{j=1}^k Z_j^2$ com $Z_j \stackrel{i.i.d.}{\sim} N(0, 1)$. Basta calcular $\mathbb{E}(Z^2)$ e $\text{Var}(Z^2)$.

Passo 1. $\mathbb{E}(Z^2) = \text{Var}(Z) + [\mathbb{E}(Z)]^2 = 1 + 0 = 1$.

Passo 2. $\mathbb{E}(Z^4)$ por integração por partes, com $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$ e $\phi'(z) = -z\phi(z)$:

$$\mathbb{E}(Z^4) = \int_{-\infty}^{\infty} z^3 \cdot z\phi(z) dz = \left[-z^3\phi(z) \right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} 3z^2\phi(z) dz = 0 + 3\mathbb{E}(Z^2) = 3.$$

Passo 3. $\text{Var}(Z^2) = \mathbb{E}(Z^4) - [\mathbb{E}(Z^2)]^2 = 3 - 1 = 2$.

Passo 4. Por linearidade e independência: $\mathbb{E}(W) = \sum_{j=1}^k 1 = k$ e $\text{Var}(W) = \sum_{j=1}^k 2 = 2k$. □

Observação 2.3 (Como usar). Se você sabe que $W = cT \sim \chi_k^2$ para uma constante $c > 0$, então $T = W/c$ e

$$\mathbb{E}(T) = \frac{k}{c}, \quad \text{Var}(T) = \frac{2k}{c^2}.$$

Essa é a técnica padrão para obter esperança e variância de estimadores de σ^2 sob normalidade.

2.2 Estatísticas de ordem: máximo e mínimo

Teorema 2.8 (Distribuição do máximo e do mínimo). Seja $Y_1, \dots, Y_n$ a.a. de Y com f.d.a. F e densidade f . Então

$$\begin{aligned} F_{Y_{(n)}}(y) &= [F(y)]^n, & f_{Y_{(n)}}(y) &= n[F(y)]^{n-1}f(y); \\ F_{Y_{(1)}}(y) &= 1 - [1 - F(y)]^n, & f_{Y_{(1)}}(y) &= n[1 - F(y)]^{n-1}f(y). \end{aligned}$$

Demonstração. O máximo é $\leq y$ se, e somente se, *todas* as observações são $\leq y$. Por independência:

$$\mathbb{P}(Y_{(n)} \leq y) = \mathbb{P}(Y_1 \leq y, \dots, Y_n \leq y) = \prod_{i=1}^n \mathbb{P}(Y_i \leq y) = [F(y)]^n.$$

O mínimo é $> y$ se, e somente se, todas são $> y$:

$$\mathbb{P}(Y_{(1)} > y) = \prod_{i=1}^n \mathbb{P}(Y_i > y) = [1 - F(y)]^n.$$

As densidades saem derivando em y (regra da cadeia). □

3 Viés e não-vício

Definição 3.1 (Viés). O *viés* (ou *vício*) de um estimador T de θ é

$$B_\theta(T) = \mathbb{E}_\theta(T) - \theta.$$

T é *não-viciado* (não-viesado) para θ se $B_\theta(T) = 0$, isto é, $\mathbb{E}_\theta(T) = \theta$, **para todo** $\theta \in \Theta$. Analogamente, T é não-viciado para $\tau(\theta)$ se $\mathbb{E}_\theta(T) = \tau(\theta)$ para todo θ .

Definição 3.2 (Assintoticamente não-viciado). Uma sequência de estimadores T_n é *assintoticamente não-viciada* se $\lim_{n \rightarrow \infty} B_\theta(T_n) = 0$ para todo $\theta \in \Theta$.

Observação 3.1 (Armadilhas frequentes). (a) “Para todo θ ” é essencial: um estimador constante $T \equiv 5$ tem viés zero quando $\theta = 5$, mas não é não-viciado.

- (b) Não-vício **não** é preservado por funções não lineares: se $\mathbb{E}(T) = \theta$, em geral $\mathbb{E}[g(T)] \neq g(\theta)$. Exemplo: se $\mathbb{E}(T) = \theta$, então $\mathbb{E}(T^2) = \text{Var}(T) + \theta^2 > \theta^2$ sempre que $\text{Var}(T) > 0$. Pela desigualdade de Jensen, para g convexa, $\mathbb{E}[g(T)] \geq g(\mathbb{E}T)$.
- (c) Não-vício é uma propriedade “em média”: diz que o estimador acerta o alvo na média de infinitas amostras, mas nada diz sobre o quanto ele se espalha. Por isso precisamos também da variância.

Proposição 3.1 (Combinações lineares). Se $\mathbb{E}(Y_i) = \mu$ para todo i , então $\mathbb{E}(\sum_i a_i Y_i) = \mu \sum_i a_i$.

Demonstração. Linearidade: $\mathbb{E}(\sum_i a_i Y_i) = \sum_i a_i \mathbb{E}(Y_i) = \sum_i a_i \mu = \mu \sum_i a_i$. □

4 Erro quadrático médio

Definição 4.1 (EQM). O *erro quadrático médio* de T como estimador de θ é

$$\text{EQM}_\theta(T) = \mathbb{E}_\theta[(T - \theta)^2].$$

Teorema 4.1 (Decomposição viés-variância).

$$\text{EQM}_\theta(T) = \text{Var}_\theta(T) + [B_\theta(T)]^2.$$

Demonstração. Somamos e subtraímos $\mathbb{E}_\theta(T)$ dentro do quadrado:

$$(T - \theta)^2 = [(T - \mathbb{E}T) + (\mathbb{E}T - \theta)]^2 = (T - \mathbb{E}T)^2 + 2(T - \mathbb{E}T)(\mathbb{E}T - \theta) + (\mathbb{E}T - \theta)^2.$$

Tomando esperança: o primeiro termo dá $\text{Var}(T)$; o último é constante e dá $[\text{B}(T)]^2$; o termo cruzado é

$$2(\mathbb{E}T - \theta) \mathbb{E}(T - \mathbb{E}T) = 2(\mathbb{E}T - \theta)(\mathbb{E}T - \mathbb{E}T) = 0.$$

□

Corolário 4.2. Se T é não-viciado, $\text{EQM}_\theta(T) = \text{Var}_\theta(T)$.

Observação 4.1 (Interpretação). O EQM mede a distância quadrática média entre o estimador e o alvo. O viés mede erro *sistemático* (acurácia); a variância mede *dispersão* (precisão). O EQM penaliza ambos. Um estimador levemente viciado mas com variância bem menor pode ter EQM menor que um não-viciado (Exemplo 8.3).

4.1 Comparação de estimadores

Definição 4.2 (Comparação via EQM e eficiência relativa). Sejam T_1 e T_2 estimadores de θ .

- (i) T_1 é *melhor* (uniformemente) que T_2 se $\text{EQM}_\theta(T_1) \leq \text{EQM}_\theta(T_2)$ para todo $\theta \in \Theta$, com desigualdade estrita para algum θ .
- (ii) A *eficiência relativa* de T_1 em relação a T_2 é

$$\text{ef}_\theta(T_1, T_2) = \frac{\text{EQM}_\theta(T_2)}{\text{EQM}_\theta(T_1)}.$$

Se $\text{ef} > 1$, T_1 é mais eficiente naquele θ .

Observação 4.2 (As curvas podem se cruzar). Muitas vezes $\text{EQM}_\theta(T_1) < \text{EQM}_\theta(T_2)$ para alguns valores de θ e o contrário para outros. Nesse caso **nenhum dos dois é uniformemente melhor**, e a resposta correta numa prova é: “depende do valor de θ ”, identificando a região onde cada um vence. Para encontrá-la, resolva a desigualdade $\text{EQM}(T_1) < \text{EQM}(T_2)$ em θ .

4.2 Limite inferior de Cramér–Rao (ponte para verossimilhança)

Esta seção dá um padrão de comparação: a menor variância possível para estimadores não-viciados (sob regularidade).

Definição 4.3 (Verossimilhança, escore e informação). Para uma a.a. com densidade $f(y; \theta)$, $\theta \in \mathbb{R}$:

$$L(\theta) = \prod_{i=1}^n f(y_i; \theta), \quad \ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(y_i; \theta),$$

$$U(\theta) = \frac{\partial \ell(\theta)}{\partial \theta} \quad (\text{função escore}), \quad I_o(\theta) = -\frac{\partial^2 \ell(\theta)}{\partial \theta^2} \quad (\text{informação observada}),$$

$$I_e(\theta) = \mathbb{E}_\theta[U(\theta)^2] = \mathbb{E}_\theta[I_o(\theta)] \quad (\text{informação esperada de Fisher}).$$

Teorema 4.3 (Desigualdade de Cramér–Rao). Sob condições de regularidade (em particular, o suporte de f não depende de θ e é permitido derivar sob o sinal de integral), se T é

não-viciado para $\tau(\theta)$, então

$$\text{Var}_\theta(T) \geq \frac{[\tau'(\theta)]^2}{I_e(\theta)}.$$

Esboço. (i) $\mathbb{E}_\theta[U(\theta)] = \int \frac{\partial}{\partial \theta} f dy = \frac{\partial}{\partial \theta} \int f dy = 0$, logo $\text{Var}(U) = I_e(\theta)$. (ii) $\text{Cov}(T, U) = \mathbb{E}(TU) = \int T \frac{\partial f}{\partial \theta} dy = \frac{\partial}{\partial \theta} \mathbb{E}(T) = \tau'(\theta)$. (iii) Pela desigualdade de Cauchy-Schwarz, $[\text{Cov}(T, U)]^2 \leq \text{Var}(T) \text{Var}(U)$, isto é, $[\tau'(\theta)]^2 \leq \text{Var}(T) I_e(\theta)$. $\square$

Observação 4.3. Um estimador não-viciado cuja variância atinge o limite é chamado *eficiente*. Em modelos como $U(0, \theta)$ o suporte depende de θ , a regularidade falha e o limite **não se aplica** (estimadores podem ter variância de ordem $1/n^2$, menor que a “usual” $1/n$).

5 Consistência

Agora olhamos para uma *sequência* de estimadores $T_n = T_n(Y_1, \dots, Y_n)$, $n = 1, 2, \dots$, e perguntamos: com mais dados, T_n se aproxima de θ ?

Definição 5.1 (Consistência em média quadrática). T_n é *médio quadrático consistente* (consistente em MQ) para θ se

$$\lim_{n \rightarrow \infty} \text{EQM}_\theta(T_n) = \lim_{n \rightarrow \infty} \mathbb{E}_\theta[(T_n - \theta)^2] = 0, \quad \forall \theta \in \Theta.$$

Notação: $T_n \xrightarrow{\text{MQ}} \theta$.

Definição 5.2 (Consistência em probabilidade (fraca)). T_n é *consistente* (em probabilidade) para θ se, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta(|T_n - \theta| \geq \varepsilon) = 0 \iff \lim_{n \rightarrow \infty} \mathbb{P}_\theta(|T_n - \theta| < \varepsilon) = 1, \quad \forall \theta \in \Theta.$$

Notação: $T_n \xrightarrow{\mathbb{P}} \theta$.

Observação 5.1 (Leitura da definição). Fixe uma “margem de erro” ε tão pequena quanto quiser. Consistência diz que a probabilidade de o estimador errar por mais que ε vai a zero quando n cresce. Repare que é uma afirmação sobre **probabilidades**, não sobre cada realização.

5.1 As desigualdades que fazem o trabalho

Teorema 5.1 (Desigualdade de Markov). Se $X \geq 0$ e $a > 0$, então $\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$.

Demonstração. Como $X \geq 0$, vale pontualmente $X \geq a \mathbf{1}\{X \geq a\}$ (se $X \geq a$, o lado direito é $a \leq X$; caso contrário é $0 \leq X$). Tomando esperança: $\mathbb{E}(X) \geq a \mathbb{E}[\mathbf{1}\{X \geq a\}] = a \mathbb{P}(X \geq a)$. $\square$

Corolário 5.2 (Chebyshev generalizada). Para qualquer $c \in \mathbb{R}$ e $\varepsilon > 0$:

$$\mathbb{P}(|T - c| \geq \varepsilon) = \mathbb{P}((T - c)^2 \geq \varepsilon^2) \leq \frac{\mathbb{E}[(T - c)^2]}{\varepsilon^2}.$$

Com $c = \theta$: $\mathbb{P}_\theta(|T - \theta| \geq \varepsilon) \leq \text{EQM}_\theta(T)/\varepsilon^2$. Com $c = \mathbb{E}(T)$: $\mathbb{P}(|T - \mathbb{E}(T)| \geq \varepsilon) \leq \text{Var}(T)/\varepsilon^2$ (Chebyshev clássica).

Demonstração. Aplique Markov a $X = (T - c)^2 \geq 0$ com $a = \varepsilon^2$; os eventos $\{|T - c| \geq \varepsilon\}$ e $\{(T - c)^2 \geq \varepsilon^2\}$ são iguais. $\square$

5.2 Relações entre os tipos de consistência

Teorema 5.3 (MQ $\Rightarrow$ probabilidade). Se $T_n \xrightarrow{MQ} \theta$, então $T_n \xrightarrow{\mathbb{P}} \theta$.

Demonstração. Pelo Corolário 5.2, para todo $\varepsilon > 0$:

$$0 \leq \mathbb{P}_\theta(|T_n - \theta| \geq \varepsilon) \leq \frac{\text{EQM}_\theta(T_n)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Pelo teorema do confronto, a probabilidade tende a zero. $\square$

Corolário 5.4 (Critério prático). $\text{EQM}_\theta(T_n) \rightarrow 0$ se, e somente se, $B_\theta(T_n) \rightarrow 0$ e $\text{Var}_\theta(T_n) \rightarrow 0$. Logo: se T_n é (assintoticamente) não-viciado e $\text{Var}(T_n) \rightarrow 0$, então T_n é consistente em MQ e, portanto, em probabilidade.

Demonstração. Pela decomposição, $\text{EQM} = \text{Var} + B^2$ é soma de dois termos não negativos; a soma vai a zero se, e somente se, cada parcela vai a zero. $\square$

Observação 5.2 (A recíproca é falsa). Consistência em probabilidade **não** implica consistência em MQ. Contraexemplo: seja

$$\mathbb{P}(T_n = \theta + n) = \frac{1}{n}, \quad \mathbb{P}(T_n = \theta) = 1 - \frac{1}{n}.$$

Para $0 < \varepsilon < 1$ e $n \geq 2$: $\mathbb{P}(|T_n - \theta| \geq \varepsilon) = \mathbb{P}(T_n = \theta + n) = 1/n \rightarrow 0$, logo $T_n \xrightarrow{\mathbb{P}} \theta$. Mas

$$\text{EQM}(T_n) = \mathbb{E}[(T_n - \theta)^2] = n^2 \cdot \frac{1}{n} + 0 \cdot \left(1 - \frac{1}{n}\right) = n \rightarrow \infty.$$

5.3 Lei dos Grandes Números e funções contínuas

Teorema 5.5 (Lei Fraca dos Grandes Números). Se $Y_1, \dots, Y_n$ é a.a. com $\mathbb{E}(Y) = \mu$ e $\text{Var}(Y) = \sigma^2 < \infty$, então $\bar{Y} \xrightarrow{\mathbb{P}} \mu$. Mais geralmente, se $\mathbb{E}(Y^{2k}) < \infty$, o k -ésimo momento amostral $M_k = \frac{1}{n} \sum_i Y_i^k$ satisfaz $M_k \xrightarrow{\mathbb{P}} \mathbb{E}(Y^k)$.

Demonstração. Pelo Teorema 2.3, $\mathbb{E}(\bar{Y}) = \mu$ e $\text{Var}(\bar{Y}) = \sigma^2/n$. Por Chebyshev, $\mathbb{P}(|\bar{Y} - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0$. Para M_k , aplique o mesmo argumento às variáveis $X_i = Y_i^k$, que são i.i.d. com média $\mathbb{E}(Y^k)$ e variância $\mathbb{E}(Y^{2k}) - [\mathbb{E}(Y^k)]^2 < \infty$. $\square$

Teorema 5.6 (Aplicação contínua). Se $T_n \xrightarrow{\mathbb{P}} \theta$ e g é contínua em θ , então $g(T_n) \xrightarrow{\mathbb{P}} g(\theta)$. O resultado vale também para vetores: se $(T_{1n}, \dots, T_{pn}) \xrightarrow{\mathbb{P}} (\theta_1, \dots, \theta_p)$ e $g: \mathbb{R}^p \rightarrow \mathbb{R}$ é contínua nesse ponto, então $g(T_{1n}, \dots, T_{pn}) \xrightarrow{\mathbb{P}} g(\theta_1, \dots, \theta_p)$.

Ideia. Continuidade em θ : dado $\varepsilon > 0$ existe $\delta > 0$ tal que $|t - \theta| < \delta \Rightarrow |g(t) - g(\theta)| < \varepsilon$. Logo $\{|g(T_n) - g(\theta)| \geq \varepsilon\} \subseteq \{|T_n - \theta| \geq \delta\}$ e $\mathbb{P}(|g(T_n) - g(\theta)| \geq \varepsilon) \leq \mathbb{P}(|T_n - \theta| \geq \delta) \rightarrow 0$. $\square$

Observação 5.3. Consequências úteis: se $T_n \xrightarrow{\mathbb{P}} \theta$ e $a_n \rightarrow a$ (sequência numérica), então $a_n T_n \xrightarrow{\mathbb{P}} a\theta$; somas e produtos de sequências consistentes são consistentes para a soma e o produto dos limites.

5.4 Quando um estimador *não* é consistente

Proposição 5.7 (Estimador que não usa a informação crescente). *Seja T um estimador cuja distribuição **não depende de n** (por exemplo, uma função de um número fixo de observações). Se T não é degenerado em θ , isto é, existe $\varepsilon_0 > 0$ com $p_0 = \mathbb{P}_\theta(|T - \theta| \geq \varepsilon_0) > 0$, então T não é consistente.*

Demonstração. Para todo n , $\mathbb{P}_\theta(|T_n - \theta| \geq \varepsilon_0) = p_0$, uma constante positiva. Logo o limite é $p_0 \neq 0$, violando a definição (que exige limite zero para *todo* ε). $\square$

Observação 5.4. Para provar **não-consistência** basta exibir *um* $\varepsilon > 0$ para o qual $\mathbb{P}(|T_n - \theta| \geq \varepsilon) \not\rightarrow 0$. Mostrar apenas que o EQM não vai a zero **não basta**, pois MQ é mais forte que probabilidade (pela observação da recíproca falsa).

5.5 Consistência via f.d.a. (útil para máximos e mínimos)

Quando T_n é um máximo ou mínimo, muitas vezes é mais fácil calcular $\mathbb{P}(|T_n - \theta| \geq \varepsilon)$ *diretamente* pela f.d.a. (Teorema 2.8) do que passar pelo EQM. O roteiro é:

1. Observe se T_n fica sempre de um lado de θ (por exemplo $T_n \leq \theta$); isso simplifica o valor absoluto.
2. Escreva $\mathbb{P}(|T_n - \theta| \geq \varepsilon)$ em termos de F_{T_n} .
3. Use que $r^n \rightarrow 0$ quando $0 \leq r < 1$.

Veja o Exemplo 8.2, item (d), onde isso é feito para um mínimo.

6 Método dos momentos

Definição 6.1 (Momentos populacionais e amostrais). O k -ésimo momento populacional (em torno da origem) é $\mu'_k(\theta) = \mathbb{E}_\theta(Y^k)$. O k -ésimo momento amostral é

$$M_k = \frac{1}{n} \sum_{i=1}^n Y_i^k.$$

Em particular $M_1 = \bar{Y}$.

Definição 6.2 (Estimador de momentos). Se $\theta = (\theta_1, \dots, \theta_p)$, o *estimador de momentos* $\tilde{\theta}$ é a solução (em θ) do sistema

$$\mu'_1(\theta) = M_1, \quad \mu'_2(\theta) = M_2, \quad \dots, \quad \mu'_p(\theta) = M_p.$$

Usa-se a notação $\tilde{\theta}$ para distinguir do EMV $\hat{\theta}$.

Roteiro de prova – método dos momentos

1. Conte quantos parâmetros desconhecidos há (p).
2. Calcule os p primeiros momentos populacionais $\mathbb{E}(Y), \dots, \mathbb{E}(Y^p)$ como funções de θ , **fazendo as integrais** (ou consultando a tabela da Seção 7). Se $\mathbb{E}(Y)$ não depende de θ (ou for zero por simetria), ele não serve: passe para o próximo momento.
3. Iguale cada momento populacional ao amostral correspondente.

4. Resolva o sistema para θ e troque θ por $\tilde{\theta}$.
5. Confira se a estimativa pertence a Θ e é compatível com os dados.

Teorema 6.1 (Propriedades gerais). (i) Cada M_k é não-viciado para μ'_k : $\mathbb{E}(M_k) = \frac{1}{n} \sum_i \mathbb{E}(Y_i^k) = \mu'_k$.

(ii) Se $\tilde{\theta} = g(M_1, \dots, M_p)$ com g contínua, então $\tilde{\theta}$ é consistente para θ (LGN + aplicação contínua, Teoremas 5.5 e 5.6).

(iii) Em geral, $\tilde{\theta}$ é **viciado** quando g é não linear (pela observação sobre não-vício e funções não lineares).

- Observação 6.1** (Limitações do método). (a) **Não unicidade:** o mesmo parâmetro pode ser estimado igualando momentos diferentes (por exemplo, na Poisson $\mathbb{E}(Y) = \text{Var}(Y) = \lambda$), gerando estimadores distintos.
- (b) **Incompatibilidade com os dados:** a estimativa pode cair fora de Θ ou contradizer a amostra (Exemplo 8.7).
- (c) **Não usa a verossimilhança:** nem sempre é eficiente; costuma servir como ponto de partida (por exemplo, valor inicial para algoritmos de máxima verossimilhança).

7 Tabela de momentos de referência

Distribuição	Densidade / f.p.	$\mathbb{E}(Y)$	$\text{Var}(Y)$
Ber(p)	$p^y(1-p)^{1-y}$, $y \in \{0, 1\}$	p	$p(1-p)$
Bin(n, p)	$\binom{n}{y} p^y (1-p)^{n-y}$	np	$np(1-p)$
Poi(λ)	$e^{-\lambda} \lambda^y / y!$	λ	λ
$N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-(y-\mu)^2/(2\sigma^2)}$	μ	σ^2
Exp(λ) (taxa)	$\lambda e^{-\lambda y}$, $y > 0$	$1/\lambda$	$1/\lambda^2$
Gama(α, β) (taxa)	$\frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$, $y > 0$	α/β	α/β^2
$U(a, b)$	$\frac{1}{b-a} \mathbf{1}\{a < y < b\}$	$(a+b)/2$	$(b-a)^2/12$
χ_k^2	Gama($k/2, 1/2$)	k	$2k$

Observação 7.1 (Integral gama – a ferramenta para momentos de densidades do tipo $y^\alpha e^{-by}$). Para $\alpha > 0$, $\beta > 0$:

$$\int_0^\infty y^{\alpha-1} e^{-\beta y} dy = \frac{\Gamma(\alpha)}{\beta^\alpha}, \quad \Gamma(m) = (m-1)! \text{ para } m \in \mathbb{N}.$$

Prova: substitua $u = \beta y$, $dy = du/\beta$: $\int_0^\infty (u/\beta)^{\alpha-1} e^{-u} du/\beta = \beta^{-\alpha} \Gamma(\alpha)$. Ao calcular $\mathbb{E}(Y^k)$ de uma densidade com fator $y^\alpha e^{-by}$, junte as potências de y e reconheça uma integral gama.

8 Exemplos resolvidos à mão

Os exemplos usam modelos *diferentes* dos da lista, para que as técnicas fiquem claras sem entregar as respostas.

Exemplo 8.1 (Poisson: as cinco propriedades + Cramér–Rao). Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} \text{Poi}(\lambda)$ e $\hat{\lambda} = \bar{Y}$.

(a) **Não-vício.** Por linearidade, com $\mathbb{E}(Y_i) = \lambda$:

$$\mathbb{E}(\hat{\lambda}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(Y_i) = \frac{1}{n} \cdot n\lambda = \lambda.$$

Logo $B_\lambda(\hat{\lambda}) = 0$ para todo $\lambda > 0$.

(b) **Variância.** Por independência, com $\text{Var}(Y_i) = \lambda$:

$$\text{Var}(\hat{\lambda}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) = \frac{n\lambda}{n^2} = \frac{\lambda}{n}.$$

(c) **EQM.** Pela decomposição:

$$\text{EQM}_\lambda(\hat{\lambda}) = \text{Var}(\hat{\lambda}) + [B(\hat{\lambda})]^2 = \frac{\lambda}{n} + 0 = \frac{\lambda}{n}.$$

(d) **Consistência em MQ.** Para cada $\lambda > 0$ fixo:

$$\lim_{n \rightarrow \infty} \text{EQM}_\lambda(\hat{\lambda}) = \lim_{n \rightarrow \infty} \frac{\lambda}{n} = 0.$$

(e) **Consistência em probabilidade.** Pela desigualdade de Chebyshev, para todo $\varepsilon > 0$:

$$0 \leq \mathbb{P}(|\hat{\lambda} - \lambda| \geq \varepsilon) \leq \frac{\text{EQM}_\lambda(\hat{\lambda})}{\varepsilon^2} = \frac{\lambda}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

(f) **Comparação com o limite de Cramér–Rao.**

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!}, \quad \ell(\lambda) = -n\lambda + \left(\sum_{i=1}^n y_i \right) \log \lambda - \sum_{i=1}^n \log(y_i!).$$

$$U(\lambda) = \frac{\partial \ell}{\partial \lambda} = -n + \frac{\sum_i y_i}{\lambda}, \quad I_o(\lambda) = -\frac{\partial^2 \ell}{\partial \lambda^2} = \frac{\sum_i y_i}{\lambda^2},$$

$$I_e(\lambda) = \mathbb{E}[I_o(\lambda)] = \frac{\mathbb{E}(\sum_i Y_i)}{\lambda^2} = \frac{n\lambda}{\lambda^2} = \frac{n}{\lambda}.$$

Com $\tau(\lambda) = \lambda$, $\tau'(\lambda) = 1$, o limite é $1/I_e(\lambda) = \lambda/n = \text{Var}(\hat{\lambda})$. Portanto $\hat{\lambda}$ é **eficiente**.

(g) **Numérico.** Amostra $(2, 0, 3, 1, 4)$, $n = 5$:

$$\hat{\lambda} = \frac{2+0+3+1+4}{5} = \frac{10}{5} = 2, \quad \widehat{\text{EQM}} = \frac{\hat{\lambda}}{n} = \frac{2}{5} = 0,4.$$

Exemplo 8.2 (Exponencial: dois estimadores não-viciados, só um consistente). Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim}$ Exponencial com *média* β , isto é, $f(y; \beta) = \frac{1}{\beta} e^{-y/\beta} \mathbf{1}\{y > 0\}$, com $\mathbb{E}(Y) = \beta$, $\text{Var}(Y) = \beta^2$ e $F(y) = 1 - e^{-y/\beta}$ para $y > 0$. Considere

$$T_1 = \bar{Y}, \quad T_2 = n Y_{(1)}.$$

(a) **Distribuição de $Y_{(1)}$.** Pelo Teorema 2.8, para $y > 0$:

$$\mathbb{P}(Y_{(1)} > y) = [1 - F(y)]^n = (e^{-y/\beta})^n = e^{-ny/\beta}.$$

Ou seja, $Y_{(1)} \sim$ Exponencial com média β/n . Então, para $T_2 = nY_{(1)}$:

$$\mathbb{P}(T_2 > t) = \mathbb{P}\left(Y_{(1)} > \frac{t}{n}\right) = e^{-n(t/n)/\beta} = e^{-t/\beta},$$

isto é, $T_2 \sim$ Exponencial com média β , **qualquer que seja n .**

(b) **Não-vício e variância.**

$$\mathbb{E}(T_1) = \beta, \quad \text{Var}(T_1) = \frac{\beta^2}{n}; \quad \mathbb{E}(T_2) = \beta, \quad \text{Var}(T_2) = \beta^2.$$

Ambos são não-viciados, então $\text{EQM}(T_1) = \beta^2/n$ e $\text{EQM}(T_2) = \beta^2$.

(c) **Eficiência relativa.**

$$\text{ef}(T_1, T_2) = \frac{\text{EQM}(T_2)}{\text{EQM}(T_1)} = \frac{\beta^2}{\beta^2/n} = n.$$

T_1 é n vezes mais eficiente, para todo β : T_1 é uniformemente melhor (para $n \geq 2$).

(d) **Consistência.** T_1 : $\text{EQM}(T_1) = \beta^2/n \rightarrow 0$, logo é consistente (MQ e em probabilidade).

T_2 : como sua distribuição não depende de n , pela Proposição 5.7 não é consistente. Explícitamente, para $0 < \varepsilon < \beta$:

$$\mathbb{P}(|T_2 - \beta| \geq \varepsilon) = \mathbb{P}(T_2 \leq \beta - \varepsilon) + \mathbb{P}(T_2 \geq \beta + \varepsilon) = (1 - e^{-(\beta-\varepsilon)/\beta}) + e^{-(\beta+\varepsilon)/\beta},$$

um número positivo que **não depende de n** , logo não tende a zero.

Moral: não-vício não garante consistência. O que importa é se a dispersão do estimador encolhe com n .

Exemplo 8.3 (Um estimador viciado pode ter EQM menor). Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ com σ^2 conhecido, e $T_c = c\bar{Y}$ com $0 < c \leq 1$.

Viés: $\mathbb{E}(T_c) = c\mu$, logo $\text{B}(T_c) = c\mu - \mu = (c-1)\mu$.

Variância: $\text{Var}(T_c) = c^2 \text{Var}(\bar{Y}) = c^2 \sigma^2/n$.

EQM:

$$\text{EQM}_\mu(T_c) = \frac{c^2 \sigma^2}{n} + (c-1)^2 \mu^2.$$

Numérico: $n = 10$, $\sigma^2 = 1$, comparando $c = 1$ (média amostral) com $c = 0,9$:

$$\text{EQM}(T_1) = \frac{1}{10} = 0,1, \quad \text{EQM}(T_{0,9}) = \frac{0,81}{10} + (0,1)^2 \mu^2 = 0,081 + 0,01\mu^2.$$

$T_{0,9}$ é melhor se, e somente se,

$$0,081 + 0,01\mu^2 < 0,1 \iff 0,01\mu^2 < 0,019 \iff \mu^2 < 1,9 \iff |\mu| < \sqrt{1,9} \approx 1,378.$$

As curvas de EQM se cruzam: nenhum dos dois é uniformemente melhor. Note ainda que, para $c < 1$ fixo, $\text{B}(T_c) \rightarrow (c-1)\mu \neq 0$, então T_c **não** é consistente para $\mu \neq 0$, embora possa ganhar em amostras pequenas.

Exemplo 8.4 (Momentos – exponencial com taxa λ , incluindo o viés). Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$, $f(y; \lambda) = \lambda e^{-\lambda y}$, $y > 0$.

Passo 1 (momento populacional). Usando a integral gama com $\alpha = 2$, $\beta = \lambda$:

$$\mathbb{E}(Y) = \int_0^\infty y \lambda e^{-\lambda y} dy = \lambda \cdot \frac{\Gamma(2)}{\lambda^2} = \lambda \cdot \frac{1}{\lambda^2} = \frac{1}{\lambda}.$$

Passo 2 (igualar e resolver).

$$\frac{1}{\tilde{\lambda}} = \bar{Y} \implies \tilde{\lambda} = \frac{1}{\bar{Y}}.$$

Passo 3 (consistência). $\bar{Y} \xrightarrow{\mathbb{P}} 1/\lambda$ (LGN) e $g(x) = 1/x$ é contínua em $1/\lambda > 0$, logo $\tilde{\lambda} \xrightarrow{\mathbb{P}} \lambda$.

Passo 4 (viés). $S = \sum_i Y_i \sim \text{Gama}(n, \lambda)$ e $\tilde{\lambda} = n/S$. Pela integral gama:

$$\mathbb{E}\left(\frac{1}{S}\right) = \int_0^\infty \frac{1}{s} \cdot \frac{\lambda^n}{\Gamma(n)} s^{n-1} e^{-\lambda s} ds = \frac{\lambda^n}{\Gamma(n)} \cdot \frac{\Gamma(n-1)}{\lambda^{n-1}} = \frac{\lambda}{n-1} \quad (n \geq 2),$$

usando $\Gamma(n) = (n-1)\Gamma(n-1)$. Logo

$$\mathbb{E}(\tilde{\lambda}) = \frac{n\lambda}{n-1}, \quad \text{B}(\tilde{\lambda}) = \frac{n\lambda}{n-1} - \lambda = \frac{\lambda}{n-1} \xrightarrow{n \rightarrow \infty} 0.$$

O estimador é viciado, mas assintoticamente não-viciado. (Isso ilustra a observação sobre funções não lineares: $\mathbb{E}(1/\bar{Y}) \neq 1/\mathbb{E}(\bar{Y})$.)

Numérico. Amostra (0,4; 1,1; 0,7; 2,8):

$$\bar{y} = \frac{0,4 + 1,1 + 0,7 + 2,8}{4} = \frac{5,0}{4} = 1,25, \quad \tilde{\lambda} = \frac{1}{1,25} = 0,8.$$

Exemplo 8.5 (Momentos com dois parâmetros – Gama(α, β)). Seja $Y \sim \text{Gama}(\alpha, \beta)$ (taxa), ambos desconhecidos ($p = 2$).

Passo 1. $\mathbb{E}(Y) = \alpha/\beta$ e $\text{Var}(Y) = \alpha/\beta^2$, logo

$$\mathbb{E}(Y^2) = \text{Var}(Y) + [\mathbb{E}(Y)]^2 = \frac{\alpha}{\beta^2} + \frac{\alpha^2}{\beta^2} = \frac{\alpha(\alpha+1)}{\beta^2}.$$

Passo 2 (sistema).

$$\frac{\tilde{\alpha}}{\tilde{\beta}} = M_1, \quad \frac{\tilde{\alpha}(\tilde{\alpha}+1)}{\tilde{\beta}^2} = M_2.$$

Passo 3 (resolver). Subtraindo o quadrado da primeira equação da segunda:

$$M_2 - M_1^2 = \frac{\tilde{\alpha}^2 + \tilde{\alpha}}{\tilde{\beta}^2} - \frac{\tilde{\alpha}^2}{\tilde{\beta}^2} = \frac{\tilde{\alpha}}{\tilde{\beta}^2}.$$

Dividindo a primeira equação por esta:

$$\frac{M_1}{M_2 - M_1^2} = \frac{\tilde{\alpha}/\tilde{\beta}}{\tilde{\alpha}/\tilde{\beta}^2} = \tilde{\beta} \implies \tilde{\beta} = \frac{M_1}{M_2 - M_1^2}, \quad \tilde{\alpha} = M_1 \tilde{\beta} = \frac{M_1^2}{M_2 - M_1^2}.$$

Observe que, pelo Lema 2.4, $M_2 - M_1^2 = \frac{1}{n} \sum_i (Y_i - \bar{Y})^2$.

Numérico. Amostra $(1, 2, 2, 3, 7)$, $n = 5$:

$$M_1 = \frac{15}{5} = 3, \quad M_2 = \frac{1 + 4 + 4 + 9 + 49}{5} = \frac{67}{5} = 13,4, \quad M_2 - M_1^2 = 13,4 - 9 = 4,4.$$

$$\tilde{\beta} = \frac{3}{4,4} \approx 0,682, \quad \tilde{\alpha} = \frac{9}{4,4} \approx 2,045.$$

Exemplo 8.6 (Momentos – Normal com μ e σ^2 desconhecidos). $\mathbb{E}(Y) = \mu$ e $\mathbb{E}(Y^2) = \sigma^2 + \mu^2$. O sistema

$$\tilde{\mu} = M_1, \quad \tilde{\sigma}^2 + \tilde{\mu}^2 = M_2$$

dá

$$\tilde{\mu} = \bar{Y}, \quad \tilde{\sigma}^2 = M_2 - M_1^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

Pelo Teorema 2.5, $\mathbb{E}(\tilde{\sigma}^2) = \frac{n-1}{n} \sigma^2$: o estimador de momentos da variância usa divisor n , não $n - 1$.

Exemplo 8.7 (Momentos – quando a estimativa contradiz os dados). Seja $Y \sim U(\theta, \theta + 1)$, $\theta \in \mathbb{R}$. Então $\mathbb{E}(Y) = \frac{\theta + (\theta + 1)}{2} = \theta + \frac{1}{2}$ e

$$\tilde{\theta} + \frac{1}{2} = \bar{Y} \implies \tilde{\theta} = \bar{Y} - \frac{1}{2}.$$

Ele é não-viciado e $\text{Var}(\tilde{\theta}) = \text{Var}(\bar{Y}) = \frac{1}{12n} \rightarrow 0$, logo consistente.

Problema com os dados. Amostra $(0,9; 1,0; 1,1; 1,85)$:

$$\bar{y} = \frac{4,85}{4} = 1,2125, \quad \tilde{\theta} = 0,7125.$$

Mas o suporte exige $\theta < y_i < \theta + 1$ para toda observação, isto é,

$$\theta < \min_i y_i = 0,9 \quad \text{e} \quad \theta > \max_i y_i - 1 = 0,85.$$

Como $0,7125 < 0,85$, o modelo com $\theta = \tilde{\theta}$ diria que observar 1,85 era *impossível*. A estimativa de momentos ignora a informação contida nos extremos da amostra. Quando o suporte depende do parâmetro, vale sempre a pena checar isso e comparar com estimadores baseados em $Y_{(1)}$ ou $Y_{(n)}$.

9 Roteiros de prova (checklist)

Mostrar que T é não-viciado. Calcule $\mathbb{E}_\theta(T)$ usando linearidade (escreva T como combinação de Y_i sempre que possível) e mostre que é igual a θ para todo θ .

Encontrar $\text{Var}(T)$. Se $T = \sum a_i Y_i$ com Y_i independentes: $\sum a_i^2 \text{Var}(Y_i)$. Se T envolve somas de quadrados sob normalidade: escreva T como constante $\times \chi^2$. Se T é máximo ou mínimo: obtenha a densidade pelo Teorema 2.8 e integre para $\mathbb{E}(T)$ e $\mathbb{E}(T^2)$.

Encontrar o EQM. $\text{EQM} = \text{Var} + B^2$. Nunca esqueça o viés ao quadrado.

Consistência em MQ. Mostre que $\lim_{n \rightarrow \infty} \text{EQM}_\theta(T_n) = 0$ para cada θ fixo.

Consistência em probabilidade. Ou (i) cite MQ $\Rightarrow$ P, escrevendo a cadeia de Chebyshev $\mathbb{P}(|T_n - \theta| \geq \varepsilon) \leq \text{EQM} / \varepsilon^2 \rightarrow 0$; ou (ii) calcule $\mathbb{P}(|T_n - \theta| \geq \varepsilon)$ diretamente pela f.d.a.; ou (iii) use LGN + aplicação contínua.

Não-consistência. Exiba um $\varepsilon > 0$ com $\mathbb{P}(|T_n - \theta| \geq \varepsilon) \not\rightarrow 0$.

Comparar estimadores. Calcule os dois EQM, forme a diferença ou a razão e estude o sinal *como função de* θ e de n . Conclua se há dominância uniforme ou cruzamento, e discuta também viés e consistência.

Estimador de momentos. Roteiro da Seção 6: momentos populacionais $\rightarrow$ igualar aos amostrais $\rightarrow$ resolver $\rightarrow$ checar Θ e compatibilidade com os dados.