

CE309 – Inferência Estatística

Guia de Estudos: Propriedades de Estimadores e Método dos Momentos

Material de apoio para a Lista 6

Sumário

1	Preliminares: o problema de estimação	2
2	Ferramentas de esperança e variância	2
2.1	Resultados sob normalidade	4
2.2	Estatísticas de ordem: máximo e mínimo	4
3	Viés e não-vício	5
4	Erro quadrático médio	5
4.1	Comparação de estimadores	6
4.2	Limite inferior de Cramér–Rao (ponte para verossimilhança)	6
5	Consistência	7
5.1	As desigualdades que fazem o trabalho	7
5.2	Relações entre os tipos de consistência	8
5.3	Lei dos Grandes Números e funções contínuas	8
5.4	Quando um estimador <i>não</i> é consistente	9
5.5	Consistência via f.d.a. (útil para máximos e mínimos)	9
6	Método dos momentos	9
7	Tabela de momentos de referência	10
8	Caixa de ferramentas: propriedades numeradas	10
9	Exemplos resolvidos à mão, passo a passo	12
9.1	Exemplo 1 – Poisson: as cinco propriedades e Cramér–Rao	12
9.2	Exemplo 2 – Exponencial: dois estimadores não-viciados, só um consistente	16
9.3	Exemplo 3 – Um estimador viciado pode ter EQM menor	18
9.4	Exemplo 4 – Momentos: exponencial com taxa λ , incluindo o viés	19
9.5	Exemplo 5 – Momentos com dois parâmetros: $\text{Gama}(\alpha, \beta)$	22
9.6	Exemplo 6 – Momentos: Normal com μ e σ^2 desconhecidos	23
9.7	Exemplo 7 – Momentos: quando a estimativa contradiz os dados	24
10	Roteiros de prova (checklist)	25

1 Preliminares: o problema de estimação

Definição 1.1 (Modelo estatístico e amostra aleatória). Seja Y uma variável aleatória com função de densidade (ou de probabilidade) $f(y; \theta)$, em que $\theta \in \Theta \subseteq \mathbb{R}^p$ é um parâmetro desconhecido e Θ é o *espaço paramétrico*. Dizemos que $Y_1, \dots, Y_n$ é uma *amostra aleatória* (a.a.) de Y se as Y_i são independentes e identicamente distribuídas (i.i.d.) com a mesma distribuição de Y . A densidade conjunta é

$$f(y_1, \dots, y_n; \theta) = \prod_{i=1}^n f(y_i; \theta).$$

Definição 1.2 (Estatística, estimador e estimativa). Uma *estatística* é qualquer função $T = T(Y_1, \dots, Y_n)$ da amostra que **não depende** de θ . Um *estimador* de θ (ou de uma função $\tau(\theta)$) é uma estatística usada para aproximar θ . O valor numérico $t = T(y_1, \dots, y_n)$ obtido com os dados observados é a *estimativa*.

Observação 1.1. O estimador é uma **variável aleatória**; a estimativa é um **número**. Todas as propriedades deste guia (viés, variância, EQM, consistência) são propriedades da *distribuição amostral* do estimador, isto é, de como ele se comportaria em repetidas amostras. Por isso calculamos $\mathbb{E}_\theta(T)$, $\text{Var}_\theta(T)$ etc., sempre sob o valor verdadeiro θ . O índice θ em $\mathbb{E}_\theta$ lembra que a esperança é calculada usando $f(\cdot; \theta)$.

Notações usadas ao longo do texto:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i, \quad \mu = \mathbb{E}(Y), \quad \sigma^2 = \text{Var}(Y), \quad Y_{(1)} = \min_i Y_i, \quad Y_{(n)} = \max_i Y_i.$$

2 Ferramentas de esperança e variância

Quase tudo nesta lista se reduz a calcular esperanças e variâncias de somas. Revisamos as regras com *demonstração*.

Teorema 2.1 (Linearidade da esperança). Para constantes $a_1, \dots, a_n, b$ e variáveis aleatórias $Y_1, \dots, Y_n$ com esperança finita (**não é preciso independência**):

$$\mathbb{E}\left(b + \sum_{i=1}^n a_i Y_i\right) = b + \sum_{i=1}^n a_i \mathbb{E}(Y_i).$$

Demonstração. Segue da linearidade da integral (ou da soma, no caso discreto): $\mathbb{E}(aX + bW) = \iint (ax + bw)f(x, w) dx dw = a\mathbb{E}(X) + b\mathbb{E}(W)$; o caso geral sai por indução. $\square$

Teorema 2.2 (Variância de combinação linear).

$$\text{Var}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(Y_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(Y_i, Y_j).$$

Se as Y_i são independentes, $\text{Cov}(Y_i, Y_j) = 0$ para $i \neq j$ e

$$\text{Var}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(Y_i).$$

Demonstração. Seja $S = \sum_i a_i Y_i$, com $\mathbb{E}(S) = \sum_i a_i \mu_i$. Então $S - \mathbb{E}(S) = \sum_i a_i (Y_i - \mu_i)$ e

$$\text{Var}(S) = \mathbb{E}\left[\left(\sum_i a_i (Y_i - \mu_i)\right)^2\right] = \mathbb{E}\left[\sum_i \sum_j a_i a_j (Y_i - \mu_i)(Y_j - \mu_j)\right] = \sum_i \sum_j a_i a_j \text{Cov}(Y_i, Y_j).$$

Separando os termos $i = j$ (que dão $a_i^2 \text{Var}(Y_i)$) dos termos $i \neq j$ (que aparecem em pares) obtemos a fórmula. Independência implica $\mathbb{E}(Y_i Y_j) = \mathbb{E}(Y_i) \mathbb{E}(Y_j)$, logo $\text{Cov}(Y_i, Y_j) = 0$. $\square$

Observação 2.1 (Duas fórmulas usadas o tempo todo).

$$\text{Var}(Y) = \mathbb{E}(Y^2) - [\mathbb{E}(Y)]^2 \iff \mathbb{E}(Y^2) = \text{Var}(Y) + [\mathbb{E}(Y)]^2.$$

$$\text{Var}(aY + b) = a^2 \text{Var}(Y).$$

Teorema 2.3 (Média amostral). Se $Y_1, \dots, Y_n$ é a.a. de Y com $\mathbb{E}(Y) = \mu$ e $\text{Var}(Y) = \sigma^2 < \infty$ (qualquer distribuição), então

$$\mathbb{E}(\bar{Y}) = \mu, \quad \text{Var}(\bar{Y}) = \frac{\sigma^2}{n}.$$

Demonstração. Tomando $a_i = 1/n$ nos dois teoremas anteriores:

$$\mathbb{E}(\bar{Y}) = \sum_{i=1}^n \frac{1}{n} \mu = \frac{n\mu}{n} = \mu, \quad \text{Var}(\bar{Y}) = \sum_{i=1}^n \frac{1}{n^2} \sigma^2 = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

$\square$

Lema 2.4 (Identidade da soma de quadrados).

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2.$$

Demonstração. Expandindo o quadrado e usando $\sum_i Y_i = n\bar{Y}$:

$$\sum_{i=1}^n (Y_i^2 - 2Y_i \bar{Y} + \bar{Y}^2) = \sum_{i=1}^n Y_i^2 - 2\bar{Y} \sum_{i=1}^n Y_i + n\bar{Y}^2 = \sum_{i=1}^n Y_i^2 - 2n\bar{Y}^2 + n\bar{Y}^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2.$$

$\square$

Teorema 2.5 (Esperança da soma de quadrados centrada). Sob as hipóteses do Teorema 2.3 (qualquer distribuição com variância finita),

$$\mathbb{E}\left[\sum_{i=1}^n (Y_i - \bar{Y})^2\right] = (n-1)\sigma^2.$$

Demonstração. Pelo Lema 2.4 e linearidade, $\mathbb{E}[\sum_i (Y_i - \bar{Y})^2] = \sum_i \mathbb{E}(Y_i^2) - n\mathbb{E}(\bar{Y}^2)$. Pela Observação acima:

$$\mathbb{E}(Y_i^2) = \sigma^2 + \mu^2, \quad \mathbb{E}(\bar{Y}^2) = \text{Var}(\bar{Y}) + [\mathbb{E}(\bar{Y})]^2 = \frac{\sigma^2}{n} + \mu^2.$$

Logo

$$\mathbb{E}\left[\sum_{i=1}^n (Y_i - \bar{Y})^2\right] = n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) = n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2 = (n-1)\sigma^2.$$

□

Observação 2.2 (Por que $n-1$?). Ao trocar μ (desconhecido) por $\bar{Y}$, a soma $\sum (Y_i - \bar{Y})^2$ fica *sistematicamente menor* que $\sum (Y_i - \mu)^2$, pois $\bar{Y}$ é o valor de c que minimiza $\sum (Y_i - c)^2$. Os desvios $Y_i - \bar{Y}$ satisfazem a restrição $\sum_i (Y_i - \bar{Y}) = 0$: só $n-1$ deles são “livres” (graus de liberdade).

2.1 Resultados sob normalidade

Teorema 2.6 (Teorema de Fisher / Cochran – enunciado). Se $Y_1, \dots, Y_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$, então:

- (i) $\bar{Y} \sim N(\mu, \sigma^2/n)$;
- (ii) $\frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{\sigma^2} \sim \chi_{n-1}^2$;
- (iii) $\bar{Y}$ e $\sum_{i=1}^n (Y_i - \bar{Y})^2$ são independentes.

Proposição 2.7 (Momentos da qui-quadrado). Se $W \sim \chi_k^2$, então $\mathbb{E}(W) = k$ e $\text{Var}(W) = 2k$.

Demonstração. Use a representação $W = \sum_{j=1}^k Z_j^2$ com $Z_j \stackrel{i.i.d.}{\sim} N(0, 1)$. Basta calcular $\mathbb{E}(Z^2)$ e $\text{Var}(Z^2)$.

Passo 1. $\mathbb{E}(Z^2) = \text{Var}(Z) + [\mathbb{E}(Z)]^2 = 1 + 0 = 1$.

Passo 2. $\mathbb{E}(Z^4)$ por integração por partes, com $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$ e $\phi'(z) = -z\phi(z)$:

$$\mathbb{E}(Z^4) = \int_{-\infty}^{\infty} z^3 \cdot z\phi(z) dz = \left[-z^3\phi(z) \right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} 3z^2\phi(z) dz = 0 + 3\mathbb{E}(Z^2) = 3.$$

Passo 3. $\text{Var}(Z^2) = \mathbb{E}(Z^4) - [\mathbb{E}(Z^2)]^2 = 3 - 1 = 2$.

Passo 4. Por linearidade e independência: $\mathbb{E}(W) = \sum_{j=1}^k 1 = k$ e $\text{Var}(W) = \sum_{j=1}^k 2 = 2k$. □

Observação 2.3 (Como usar). Se você sabe que $W = cT \sim \chi_k^2$ para uma constante $c > 0$, então $T = W/c$ e

$$\mathbb{E}(T) = \frac{k}{c}, \quad \text{Var}(T) = \frac{2k}{c^2}.$$

Essa é a técnica padrão para obter esperança e variância de estimadores de σ^2 sob normalidade.

2.2 Estatísticas de ordem: máximo e mínimo

Teorema 2.8 (Distribuição do máximo e do mínimo). Seja $Y_1, \dots, Y_n$ a.a. de Y com f.d.a. F e densidade f . Então

$$\begin{aligned} F_{Y_{(n)}}(y) &= [F(y)]^n, & f_{Y_{(n)}}(y) &= n[F(y)]^{n-1}f(y); \\ F_{Y_{(1)}}(y) &= 1 - [1 - F(y)]^n, & f_{Y_{(1)}}(y) &= n[1 - F(y)]^{n-1}f(y). \end{aligned}$$

Demonstração. O máximo é $\leq y$ se, e somente se, *todas* as observações são $\leq y$. Por independência:

$$\mathbb{P}(Y_{(n)} \leq y) = \mathbb{P}(Y_1 \leq y, \dots, Y_n \leq y) = \prod_{i=1}^n \mathbb{P}(Y_i \leq y) = [F(y)]^n.$$

O mínimo é $> y$ se, e somente se, todas são $> y$:

$$\mathbb{P}(Y_{(1)} > y) = \prod_{i=1}^n \mathbb{P}(Y_i > y) = [1 - F(y)]^n.$$

As densidades saem derivando em y (regra da cadeia). □

3 Viés e não-vício

Definição 3.1 (Viés). O *viés* (ou *vício*) de um estimador T de θ é

$$B_\theta(T) = \mathbb{E}_\theta(T) - \theta.$$

T é *não-viciado* (não-viesado) para θ se $B_\theta(T) = 0$, isto é, $\mathbb{E}_\theta(T) = \theta$, **para todo** $\theta \in \Theta$. Analogamente, T é não-viciado para $\tau(\theta)$ se $\mathbb{E}_\theta(T) = \tau(\theta)$ para todo θ .

Definição 3.2 (Assintoticamente não-viciado). Uma sequência de estimadores T_n é *assintoticamente não-viciada* se $\lim_{n \rightarrow \infty} B_\theta(T_n) = 0$ para todo $\theta \in \Theta$.

Observação 3.1 (Armadilhas frequentes). (a) “Para todo θ ” é essencial: um estimador constante $T \equiv 5$ tem viés zero quando $\theta = 5$, mas não é não-viciado.

- (b) Não-vício **não** é preservado por funções não lineares: se $\mathbb{E}(T) = \theta$, em geral $\mathbb{E}[g(T)] \neq g(\theta)$. Exemplo: se $\mathbb{E}(T) = \theta$, então $\mathbb{E}(T^2) = \text{Var}(T) + \theta^2 > \theta^2$ sempre que $\text{Var}(T) > 0$. Pela desigualdade de Jensen, para g convexa, $\mathbb{E}[g(T)] \geq g(\mathbb{E}T)$.
- (c) Não-vício é uma propriedade “em média”: diz que o estimador acerta o alvo na média de infinitas amostras, mas nada diz sobre o quanto ele se espalha. Por isso precisamos também da variância.

Proposição 3.1 (Combinações lineares). Se $\mathbb{E}(Y_i) = \mu$ para todo i , então $\mathbb{E}(\sum_i a_i Y_i) = \mu \sum_i a_i$.

Demonstração. Linearidade: $\mathbb{E}(\sum_i a_i Y_i) = \sum_i a_i \mathbb{E}(Y_i) = \sum_i a_i \mu = \mu \sum_i a_i$. □

4 Erro quadrático médio

Definição 4.1 (EQM). O *erro quadrático médio* de T como estimador de θ é

$$\text{EQM}_\theta(T) = \mathbb{E}_\theta[(T - \theta)^2].$$

Teorema 4.1 (Decomposição viés-variância).

$$\text{EQM}_\theta(T) = \text{Var}_\theta(T) + [B_\theta(T)]^2.$$

Demonstração. Somamos e subtraímos $\mathbb{E}_\theta(T)$ dentro do quadrado:

$$(T - \theta)^2 = [(T - \mathbb{E}T) + (\mathbb{E}T - \theta)]^2 = (T - \mathbb{E}T)^2 + 2(T - \mathbb{E}T)(\mathbb{E}T - \theta) + (\mathbb{E}T - \theta)^2.$$

Tomando esperança: o primeiro termo dá $\text{Var}(T)$; o último é constante e dá $[\text{B}(T)]^2$; o termo cruzado é

$$2(\mathbb{E}T - \theta) \mathbb{E}(T - \mathbb{E}T) = 2(\mathbb{E}T - \theta)(\mathbb{E}T - \mathbb{E}T) = 0.$$

□

Corolário 4.2. Se T é não-viciado, $\text{EQM}_\theta(T) = \text{Var}_\theta(T)$.

Observação 4.1 (Interpretação). O EQM mede a distância quadrática média entre o estimador e o alvo. O viés mede erro *sistemático* (acurácia); a variância mede *dispersão* (precisão). O EQM penaliza ambos. Um estimador levemente viciado mas com variância bem menor pode ter EQM menor que um não-viciado (exemplo da Seção 9.3).

4.1 Comparação de estimadores

Definição 4.2 (Comparação via EQM e eficiência relativa). Sejam T_1 e T_2 estimadores de θ .

- (i) T_1 é *melhor* (uniformemente) que T_2 se $\text{EQM}_\theta(T_1) \leq \text{EQM}_\theta(T_2)$ para todo $\theta \in \Theta$, com desigualdade estrita para algum θ .
- (ii) A *eficiência relativa* de T_1 em relação a T_2 é

$$\text{ef}_\theta(T_1, T_2) = \frac{\text{EQM}_\theta(T_2)}{\text{EQM}_\theta(T_1)}.$$

Se $\text{ef} > 1$, T_1 é mais eficiente naquele θ .

Observação 4.2 (As curvas podem se cruzar). Muitas vezes $\text{EQM}_\theta(T_1) < \text{EQM}_\theta(T_2)$ para alguns valores de θ e o contrário para outros. Nesse caso **nenhum dos dois é uniformemente melhor**, e a resposta correta numa prova é: “depende do valor de θ ”, identificando a região onde cada um vence. Para encontrá-la, resolva a desigualdade $\text{EQM}(T_1) < \text{EQM}(T_2)$ em θ .

4.2 Limite inferior de Cramér–Rao (ponte para verossimilhança)

Esta seção dá um padrão de comparação: a menor variância possível para estimadores não-viciados (sob regularidade).

Definição 4.3 (Verossimilhança, escore e informação). Para uma a.a. com densidade $f(y; \theta)$, $\theta \in \mathbb{R}$:

$$L(\theta) = \prod_{i=1}^n f(y_i; \theta), \quad \ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(y_i; \theta),$$

$$U(\theta) = \frac{\partial \ell(\theta)}{\partial \theta} \quad (\text{função escore}), \quad I_o(\theta) = -\frac{\partial^2 \ell(\theta)}{\partial \theta^2} \quad (\text{informação observada}),$$

$$I_e(\theta) = \mathbb{E}_\theta[U(\theta)^2] = \mathbb{E}_\theta[I_o(\theta)] \quad (\text{informação esperada de Fisher}).$$

Teorema 4.3 (Desigualdade de Cramér–Rao). Sob condições de regularidade (em particular, o suporte de f não depende de θ e é permitido derivar sob o sinal de integral), se T é

não-viciado para $\tau(\theta)$, então

$$\text{Var}_\theta(T) \geq \frac{[\tau'(\theta)]^2}{I_e(\theta)}.$$

Esboço. (i) $\mathbb{E}_\theta[U(\theta)] = \int \frac{\partial}{\partial \theta} f dy = \frac{\partial}{\partial \theta} \int f dy = 0$, logo $\text{Var}(U) = I_e(\theta)$. (ii) $\text{Cov}(T, U) = \mathbb{E}(TU) = \int T \frac{\partial f}{\partial \theta} dy = \frac{\partial}{\partial \theta} \mathbb{E}(T) = \tau'(\theta)$. (iii) Pela desigualdade de Cauchy-Schwarz, $[\text{Cov}(T, U)]^2 \leq \text{Var}(T) \text{Var}(U)$, isto é, $[\tau'(\theta)]^2 \leq \text{Var}(T) I_e(\theta)$. $\square$

Observação 4.3. Um estimador não-viciado cuja variância atinge o limite é chamado *eficiente*. Em modelos como $U(0, \theta)$ o suporte depende de θ , a regularidade falha e o limite **não se aplica** (estimadores podem ter variância de ordem $1/n^2$, menor que a “usual” $1/n$).

5 Consistência

Agora olhamos para uma *sequência* de estimadores $T_n = T_n(Y_1, \dots, Y_n)$, $n = 1, 2, \dots$, e perguntamos: com mais dados, T_n se aproxima de θ ?

Definição 5.1 (Consistência em média quadrática). T_n é *médio quadrático consistente* (consistente em MQ) para θ se

$$\lim_{n \rightarrow \infty} \text{EQM}_\theta(T_n) = \lim_{n \rightarrow \infty} \mathbb{E}_\theta[(T_n - \theta)^2] = 0, \quad \forall \theta \in \Theta.$$

Notação: $T_n \xrightarrow{\text{MQ}} \theta$.

Definição 5.2 (Consistência em probabilidade (fraca)). T_n é *consistente* (em probabilidade) para θ se, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}_\theta(|T_n - \theta| \geq \varepsilon) = 0 \iff \lim_{n \rightarrow \infty} \mathbb{P}_\theta(|T_n - \theta| < \varepsilon) = 1, \quad \forall \theta \in \Theta.$$

Notação: $T_n \xrightarrow{\mathbb{P}} \theta$.

Observação 5.1 (Leitura da definição). Fixe uma “margem de erro” ε tão pequena quanto quiser. Consistência diz que a probabilidade de o estimador errar por mais que ε vai a zero quando n cresce. Repare que é uma afirmação sobre **probabilidades**, não sobre cada realização.

5.1 As desigualdades que fazem o trabalho

Teorema 5.1 (Desigualdade de Markov). Se $X \geq 0$ e $a > 0$, então $\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$.

Demonstração. Como $X \geq 0$, vale pontualmente $X \geq a \mathbf{1}\{X \geq a\}$ (se $X \geq a$, o lado direito é $a \leq X$; caso contrário é $0 \leq X$). Tomando esperança: $\mathbb{E}(X) \geq a \mathbb{E}[\mathbf{1}\{X \geq a\}] = a \mathbb{P}(X \geq a)$. $\square$

Corolário 5.2 (Chebyshev generalizada). Para qualquer $c \in \mathbb{R}$ e $\varepsilon > 0$:

$$\mathbb{P}(|T - c| \geq \varepsilon) = \mathbb{P}((T - c)^2 \geq \varepsilon^2) \leq \frac{\mathbb{E}[(T - c)^2]}{\varepsilon^2}.$$

Com $c = \theta$: $\mathbb{P}_\theta(|T - \theta| \geq \varepsilon) \leq \text{EQM}_\theta(T)/\varepsilon^2$. Com $c = \mathbb{E}(T)$: $\mathbb{P}(|T - \mathbb{E}(T)| \geq \varepsilon) \leq \text{Var}(T)/\varepsilon^2$ (Chebyshev clássica).

Demonstração. Aplique Markov a $X = (T - c)^2 \geq 0$ com $a = \varepsilon^2$; os eventos $\{|T - c| \geq \varepsilon\}$ e $\{(T - c)^2 \geq \varepsilon^2\}$ são iguais. $\square$

5.2 Relações entre os tipos de consistência

Teorema 5.3 (MQ $\Rightarrow$ probabilidade). Se $T_n \xrightarrow{MQ} \theta$, então $T_n \xrightarrow{\mathbb{P}} \theta$.

Demonstração. Pelo Corolário 5.2, para todo $\varepsilon > 0$:

$$0 \leq \mathbb{P}_\theta(|T_n - \theta| \geq \varepsilon) \leq \frac{\text{EQM}_\theta(T_n)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Pelo teorema do confronto, a probabilidade tende a zero. $\square$

Corolário 5.4 (Critério prático). $\text{EQM}_\theta(T_n) \rightarrow 0$ se, e somente se, $\text{B}_\theta(T_n) \rightarrow 0$ e $\text{Var}_\theta(T_n) \rightarrow 0$. Logo: se T_n é (assintoticamente) não-viciado e $\text{Var}(T_n) \rightarrow 0$, então T_n é consistente em MQ e, portanto, em probabilidade.

Demonstração. Pela decomposição, $\text{EQM} = \text{Var} + \text{B}^2$ é soma de dois termos não negativos; a soma vai a zero se, e somente se, cada parcela vai a zero. $\square$

Observação 5.2 (A recíproca é falsa). Consistência em probabilidade **não** implica consistência em MQ. Contraexemplo: seja

$$\mathbb{P}(T_n = \theta + n) = \frac{1}{n}, \quad \mathbb{P}(T_n = \theta) = 1 - \frac{1}{n}.$$

Para $0 < \varepsilon < 1$ e $n \geq 2$: $\mathbb{P}(|T_n - \theta| \geq \varepsilon) = \mathbb{P}(T_n = \theta + n) = 1/n \rightarrow 0$, logo $T_n \xrightarrow{\mathbb{P}} \theta$. Mas

$$\text{EQM}(T_n) = \mathbb{E}[(T_n - \theta)^2] = n^2 \cdot \frac{1}{n} + 0 \cdot \left(1 - \frac{1}{n}\right) = n \rightarrow \infty.$$

5.3 Lei dos Grandes Números e funções contínuas

Teorema 5.5 (Lei Fraca dos Grandes Números). Se $Y_1, \dots, Y_n$ é a.a. com $\mathbb{E}(Y) = \mu$ e $\text{Var}(Y) = \sigma^2 < \infty$, então $\bar{Y} \xrightarrow{\mathbb{P}} \mu$. Mais geralmente, se $\mathbb{E}(Y^{2k}) < \infty$, o k -ésimo momento amostral $M_k = \frac{1}{n} \sum_i Y_i^k$ satisfaz $M_k \xrightarrow{\mathbb{P}} \mathbb{E}(Y^k)$.

Demonstração. Pelo Teorema 2.3, $\mathbb{E}(\bar{Y}) = \mu$ e $\text{Var}(\bar{Y}) = \sigma^2/n$. Por Chebyshev, $\mathbb{P}(|\bar{Y} - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0$. Para M_k , aplique o mesmo argumento às variáveis $X_i = Y_i^k$, que são i.i.d. com média $\mathbb{E}(Y^k)$ e variância $\mathbb{E}(Y^{2k}) - [\mathbb{E}(Y^k)]^2 < \infty$. $\square$

Teorema 5.6 (Aplicação contínua). Se $T_n \xrightarrow{\mathbb{P}} \theta$ e g é contínua em θ , então $g(T_n) \xrightarrow{\mathbb{P}} g(\theta)$. O resultado vale também para vetores: se $(T_{1n}, \dots, T_{pn}) \xrightarrow{\mathbb{P}} (\theta_1, \dots, \theta_p)$ e $g: \mathbb{R}^p \rightarrow \mathbb{R}$ é contínua nesse ponto, então $g(T_{1n}, \dots, T_{pn}) \xrightarrow{\mathbb{P}} g(\theta_1, \dots, \theta_p)$.

Ideia. Continuidade em θ : dado $\varepsilon > 0$ existe $\delta > 0$ tal que $|t - \theta| < \delta \Rightarrow |g(t) - g(\theta)| < \varepsilon$. Logo $\{|g(T_n) - g(\theta)| \geq \varepsilon\} \subseteq \{|T_n - \theta| \geq \delta\}$ e $\mathbb{P}(|g(T_n) - g(\theta)| \geq \varepsilon) \leq \mathbb{P}(|T_n - \theta| \geq \delta) \rightarrow 0$. $\square$

Observação 5.3. Consequências úteis: se $T_n \xrightarrow{\mathbb{P}} \theta$ e $a_n \rightarrow a$ (sequência numérica), então $a_n T_n \xrightarrow{\mathbb{P}} a\theta$; somas e produtos de sequências consistentes são consistentes para a soma e o produto dos limites.

5.4 Quando um estimador *não* é consistente

Proposição 5.7 (Estimador que não usa a informação crescente). *Seja T um estimador cuja distribuição **não depende de n** (por exemplo, uma função de um número fixo de observações). Se T não é degenerado em θ , isto é, existe $\varepsilon_0 > 0$ com $p_0 = \mathbb{P}_\theta(|T - \theta| \geq \varepsilon_0) > 0$, então T não é consistente.*

Demonstração. Para todo n , $\mathbb{P}_\theta(|T_n - \theta| \geq \varepsilon_0) = p_0$, uma constante positiva. Logo o limite é $p_0 \neq 0$, violando a definição (que exige limite zero para *todo* ε). $\square$

Observação 5.4. Para provar **não-consistência** basta exibir *um* $\varepsilon > 0$ para o qual $\mathbb{P}(|T_n - \theta| \geq \varepsilon) \not\rightarrow 0$. Mostrar apenas que o EQM não vai a zero **não basta**, pois MQ é mais forte que probabilidade (pela observação da recíproca falsa).

5.5 Consistência via f.d.a. (útil para máximos e mínimos)

Quando T_n é um máximo ou mínimo, muitas vezes é mais fácil calcular $\mathbb{P}(|T_n - \theta| \geq \varepsilon)$ *diretamente* pela f.d.a. (Teorema 2.8) do que passar pelo EQM. O roteiro é:

1. Observe se T_n fica sempre de um lado de θ (por exemplo $T_n \leq \theta$); isso simplifica o valor absoluto.
2. Escreva $\mathbb{P}(|T_n - \theta| \geq \varepsilon)$ em termos de F_{T_n} .
3. Use que $r^n \rightarrow 0$ quando $0 \leq r < 1$.

Veja o Exemplo 2 (Seção 9.2), item (d), onde isso é feito para um mínimo.

6 Método dos momentos

Definição 6.1 (Momentos populacionais e amostrais). O k -ésimo momento populacional (em torno da origem) é $\mu'_k(\theta) = \mathbb{E}_\theta(Y^k)$. O k -ésimo momento amostral é

$$M_k = \frac{1}{n} \sum_{i=1}^n Y_i^k.$$

Em particular $M_1 = \bar{Y}$.

Definição 6.2 (Estimador de momentos). Se $\theta = (\theta_1, \dots, \theta_p)$, o *estimador de momentos* $\tilde{\theta}$ é a solução (em θ) do sistema

$$\mu'_1(\theta) = M_1, \quad \mu'_2(\theta) = M_2, \quad \dots, \quad \mu'_p(\theta) = M_p.$$

Usa-se a notação $\tilde{\theta}$ para distinguir do EMV $\hat{\theta}$.

Roteiro de prova – método dos momentos

1. Conte quantos parâmetros desconhecidos há (p).
2. Calcule os p primeiros momentos populacionais $\mathbb{E}(Y), \dots, \mathbb{E}(Y^p)$ como funções de θ , **fazendo as integrais** (ou consultando a tabela da Seção 7). Se $\mathbb{E}(Y)$ não depende de θ (ou for zero por simetria), ele não serve: passe para o próximo momento.
3. Iguale cada momento populacional ao amostral correspondente.

4. Resolva o sistema para θ e troque θ por $\tilde{\theta}$.
5. Confira se a estimativa pertence a Θ e é compatível com os dados.

Teorema 6.1 (Propriedades gerais). (i) Cada M_k é não-viciado para μ'_k : $\mathbb{E}(M_k) = \frac{1}{n} \sum_i \mathbb{E}(Y_i^k) = \mu'_k$.

(ii) Se $\tilde{\theta} = g(M_1, \dots, M_p)$ com g contínua, então $\tilde{\theta}$ é consistente para θ (LGN + aplicação contínua, Teoremas 5.5 e 5.6).

(iii) Em geral, $\tilde{\theta}$ é **viciado** quando g é não linear (pela observação sobre não-vício e funções não lineares).

- Observação 6.1** (Limitações do método). (a) **Não unicidade:** o mesmo parâmetro pode ser estimado igualando momentos diferentes (por exemplo, na Poisson $\mathbb{E}(Y) = \text{Var}(Y) = \lambda$), gerando estimadores distintos.
- (b) **Incompatibilidade com os dados:** a estimativa pode cair fora de Θ ou contradizer a amostra (exemplo da Seção 9.7).
- (c) **Não usa a verossimilhança:** nem sempre é eficiente; costuma servir como ponto de partida (por exemplo, valor inicial para algoritmos de máxima verossimilhança).

7 Tabela de momentos de referência

Distribuição	Densidade / f.p.	$\mathbb{E}(Y)$	$\text{Var}(Y)$
Ber(p)	$p^y(1-p)^{1-y}, y \in \{0, 1\}$	p	$p(1-p)$
Bin(n, p)	$\binom{n}{y} p^y (1-p)^{n-y}$	np	$np(1-p)$
Poi(λ)	$e^{-\lambda} \lambda^y / y!$	λ	λ
$N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-(y-\mu)^2/(2\sigma^2)}$	μ	σ^2
Exp(λ) (taxa)	$\lambda e^{-\lambda y}, y > 0$	$1/\lambda$	$1/\lambda^2$
Gama(α, β) (taxa)	$\frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}, y > 0$	α/β	α/β^2
$U(a, b)$	$\frac{1}{b-a} \mathbf{1}\{a < y < b\}$	$(a+b)/2$	$(b-a)^2/12$
χ_k^2	Gama($k/2, 1/2$)	k	$2k$

Observação 7.1 (Integral gama – a ferramenta para momentos de densidades do tipo $y^\alpha e^{-by}$). Para $\alpha > 0, \beta > 0$:

$$\int_0^\infty y^{\alpha-1} e^{-\beta y} dy = \frac{\Gamma(\alpha)}{\beta^\alpha}, \quad \Gamma(m) = (m-1)! \text{ para } m \in \mathbb{N}.$$

Prova: substitua $u = \beta y, dy = du/\beta$: $\int_0^\infty (u/\beta)^{\alpha-1} e^{-u} du/\beta = \beta^{-\alpha} \Gamma(\alpha)$. Ao calcular $\mathbb{E}(Y^k)$ de uma densidade com fator $y^\alpha e^{-by}$, junte as potências de y e reconheça uma integral gama.

8 Caixa de ferramentas: propriedades numeradas

Nos exemplos da próxima seção, **cada passagem algébrica vem com uma etiqueta cinza à direita**, como [P1], indicando qual propriedade abaixo foi usada. A ideia é que você consiga refazer qualquer linha sozinho, sabendo exatamente *por que* ela vale.

Esperança e variância

- (P1) **Linearidade da esperança.** $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$ e $\mathbb{E}(\sum_i X_i) = \sum_i \mathbb{E}(X_i)$. Constantes “saem” da esperança e a esperança de uma soma é a soma das esperanças (não exige independência).
- (P2) **Constantes na variância.** $\text{Var}(aX + b) = a^2 \text{Var}(X)$. A constante sai *ao quadrado*; somar uma constante b não altera a dispersão.
- (P3) **Variância da soma de independentes.** Se $X_1, \dots, X_n$ são independentes, $\text{Var}(\sum_i X_i) = \sum_i \text{Var}(X_i)$ (as covariâncias são nulas).
- (P4) **Fórmula de atalho.** $\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$, ou seja, $\mathbb{E}(X^2) = \text{Var}(X) + [\mathbb{E}(X)]^2$.
- (P5) **Esperança de constante.** $\mathbb{E}(c) = c$ e $\text{Var}(c) = 0$.
- (P6) **Independência.** $\mathbb{E}(XW) = \mathbb{E}(X)\mathbb{E}(W)$ e $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ para eventos ligados a variáveis independentes.
- (P7) **Esperança de uma função (LOTUS).** $\mathbb{E}[g(X)] = \int g(x)f(x)dx$ (contínua) ou $\sum_x g(x)p(x)$ (discreta).
- (P8) **Identicamente distribuídas.** Em uma a.a., todas as Y_i têm a mesma distribuição de Y ; logo $\mathbb{E}(Y_i) = \mathbb{E}(Y)$, $\text{Var}(Y_i) = \text{Var}(Y)$ e $\mathbb{P}(Y_i > y) = \mathbb{P}(Y > y)$ para todo i .

Somatórios e produtórios

- (S1) $\sum_{i=1}^n c = nc$ (somar a mesma constante n vezes).
- (S2) $\sum_i c x_i = c \sum_i x_i$ (constante sai do somatório).
- (S3) $\sum_i (x_i + w_i) = \sum_i x_i + \sum_i w_i$.
- (S4) $\sum_{i=1}^n x_i = n\bar{x}$ (definição da média: $\bar{x} = \frac{1}{n} \sum_i x_i$).
- (S5) $\prod_{i=1}^n c = c^n$ e $\prod_i (a_i b_i) = (\prod_i a_i)(\prod_i b_i)$.

Logaritmo e exponencial (sempre $\log = \ln$)

- (L1) $\log(ab) = \log a + \log b$; portanto $\log \prod_i a_i = \sum_i \log a_i$.
- (L2) $\log(a^b) = b \log a$.
- (L3) $\log(e^x) = x$; $e^a e^b = e^{a+b}$; $(e^a)^n = e^{na}$.
- (L4) $\log(a/b) = \log a - \log b$.

Derivadas

- (D1) $\frac{d}{dx}(cx) = c$ e $\frac{d}{dx}c = 0$ (o que não depende da variável é constante).
- (D2) $\frac{d}{dx} \log x = \frac{1}{x}$ e $\frac{d}{dx} x^k = kx^{k-1}$ (em particular $\frac{d}{dx} x^{-1} = -x^{-2}$).
- (D3) Derivada da soma é a soma das derivadas.

Integrais

- (I1) **Integral gama.** Para $\alpha > 0$ e $\beta > 0$: $\int_0^\infty y^{\alpha-1} e^{-\beta y} dy = \frac{\Gamma(\alpha)}{\beta^\alpha}$.
- (I2) **Propriedades da função gama.** $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$; $\Gamma(1) = 1$; $\Gamma(m) = (m-1)!$ para m inteiro positivo. Ex.: $\Gamma(2) = 1$, $\Gamma(3) = 2$, $\Gamma(4) = 6$.
- (I3) Constante sai da integral: $\int c g(y) dy = c \int g(y) dy$.
- (I4) **Polinômios.** $\int_a^b y^k dy = \left[\frac{y^{k+1}}{k+1} \right]_a^b = \frac{b^{k+1} - a^{k+1}}{k+1}$.
- (I5) **Exponencial.** $\int_0^y \frac{1}{\beta} e^{-t/\beta} dt = \left[-e^{-t/\beta} \right]_0^y = 1 - e^{-y/\beta}$.

Probabilidade

- (Pr1) **Complemento.** $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$; em particular $\mathbb{P}(Y > y) = 1 - F(y)$.
- (Pr2) **União disjunta.** Se $A \cap B = \emptyset$, $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$.
- (Pr3) **Valor absoluto.** $|X - c| \geq \varepsilon \iff X \leq c - \varepsilon$ ou $X \geq c + \varepsilon$ (dois eventos disjuntos).
- (Pr4) **FGM.** $M_X(t) = \mathbb{E}(e^{tX})$. A FGM de uma soma de independentes é o produto das FGMs, e a FGM determina a distribuição (unicidade).
- (Pr5) **Mínimo e máximo.** $\{Y_{(1)} > y\} = \{Y_1 > y, \dots, Y_n > y\}$ e $\{Y_{(n)} \leq y\} = \{Y_1 \leq y, \dots, Y_n \leq y\}$.

Limites e desigualdades

- (Li1) Para c constante (não depende de n): $\lim_{n \rightarrow \infty} c/n = 0$ e $\lim_{n \rightarrow \infty} c = c$.
- (Li2) **Confronto.** Se $0 \leq a_n \leq b_n$ e $b_n \rightarrow 0$, então $a_n \rightarrow 0$.
- (Li3) Multiplicar ou dividir uma desigualdade por número **positivo** preserva o sentido; somar ou subtrair qualquer número também.
- (Li4) Se $a, b \geq 0$: $a < b \iff a^2 < b^2$, e $\sqrt{a^2} = |a|$.

Resultados do próprio guia que serão citados

[Decomp] $\text{EQM} = \text{Var} + B^2$ (Teorema 4.1). [Cheb] $\mathbb{P}(|T - \theta| \geq \varepsilon) \leq \text{EQM}(T)/\varepsilon^2$ (Corolário 5.2). [LGN] $\bar{Y} \xrightarrow{\mathbb{P}} \mathbb{E}(Y)$ (Teorema 5.5). [Cont] aplicação contínua (Teorema 5.6). [Lema-SQ] $\sum_i (Y_i - \bar{Y})^2 = \sum_i Y_i^2 - n\bar{Y}^2$ (Lema 2.4). [Teo-SQ] $\mathbb{E}[\sum_i (Y_i - \bar{Y})^2] = (n-1)\sigma^2$ (Teorema 2.5).

9 Exemplos resolvidos à mão, passo a passo

Os exemplos usam modelos *diferentes* dos da lista, para que as técnicas fiquem claras sem entregar as respostas. Leia cada linha e, antes de olhar a etiqueta, tente dizer qual propriedade justifica a passagem.

9.1 Exemplo 1 – Poisson: as cinco propriedades e Cramér–Rao

Enunciado. Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} \text{Poi}(\lambda)$, com $f(y; \lambda) = \frac{e^{-\lambda} \lambda^y}{y!}$, $y = 0, 1, 2, \dots$, e o estimador $\hat{\lambda} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$.

Passo 0 – de onde vêm $\mathbb{E}(Y) = \lambda$ e $\text{Var}(Y) = \lambda$

Não decore: veja de onde sai. Vamos usar a série de Taylor $\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^\lambda$.

Esperança. O termo $y = 0$ vale zero (está multiplicado por $y = 0$), então a soma começa em $y = 1$. Como $\frac{y}{y!} = \frac{1}{(y-1)!}$ para $y \geq 1$:

$$\begin{aligned}
 \mathbb{E}(Y) &= \sum_{y=0}^{\infty} y \frac{e^{-\lambda} \lambda^y}{y!} & [\text{P7}] \\
 &= \sum_{y=1}^{\infty} \frac{e^{-\lambda} \lambda^y}{(y-1)!} & [\text{termo } y=0 \text{ é nulo; } y/y! = 1/(y-1)!] \\
 &= \lambda e^{-\lambda} \sum_{y=1}^{\infty} \frac{\lambda^{y-1}}{(y-1)!} & [\lambda^y = \lambda \cdot \lambda^{y-1}; \text{S2}] \\
 &= \lambda e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} & [\text{troca } k = y-1] \\
 &= \lambda e^{-\lambda} e^\lambda = \lambda. & [\text{série de Taylor; L3}]
 \end{aligned}$$

Variância. O truque é calcular $\mathbb{E}[Y(Y-1)]$, porque $\frac{y(y-1)}{y!} = \frac{1}{(y-2)!}$ para $y \geq 2$. Repetindo o raciocínio:

$$\mathbb{E}[Y(Y-1)] = \sum_{y=2}^{\infty} \frac{e^{-\lambda} \lambda^y}{(y-2)!} = \lambda^2 e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = \lambda^2. \quad [\text{mesmo argumento, } k = y-2]$$

Como $\mathbb{E}[Y(Y-1)] = \mathbb{E}(Y^2) - \mathbb{E}(Y)$ (por P1), temos $\mathbb{E}(Y^2) = \lambda^2 + \lambda$. Então

$$\begin{aligned}
 \text{Var}(Y) &= \mathbb{E}(Y^2) - [\mathbb{E}(Y)]^2 \\
 &= \lambda^2 + \lambda - \lambda^2 = \lambda.
 \end{aligned} \quad [\text{P4}]$$

(a) Não-vício

Objetivo: mostrar que $\mathbb{E}(\hat{\lambda}) = \lambda$ para todo $\lambda > 0$.

$$\begin{aligned}
 \mathbb{E}(\hat{\lambda}) &= \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) & [\text{definição de } \hat{\lambda}] \\
 &= \frac{1}{n} \mathbb{E}\left(\sum_{i=1}^n Y_i\right) & [\text{P1: constante } 1/n \text{ sai}] \\
 &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}(Y_i) & [\text{P1: esperança da soma}] \\
 &= \frac{1}{n} \sum_{i=1}^n \lambda & [\text{P8 + Passo 0}] \\
 &= \frac{1}{n} \cdot n\lambda & [\text{S1}] \\
 &= \lambda.
 \end{aligned}$$

Logo $B_\lambda(\hat{\lambda}) = \mathbb{E}(\hat{\lambda}) - \lambda = \lambda - \lambda = 0$ para todo $\lambda > 0$: $\hat{\lambda}$ é não-viciado.

(b) Variância

$$\begin{aligned}\text{Var}(\hat{\lambda}) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) \\ &= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n Y_i\right) && [\text{P2: } 1/n \text{ sai ao quadrado}] \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) && [\text{P3: as } Y_i \text{ são independentes}] \\ &= \frac{1}{n^2} \sum_{i=1}^n \lambda && [\text{P8 + Passo 0}] \\ &= \frac{1}{n^2} \cdot n\lambda && [\text{S1}] \\ &= \frac{\lambda}{n}. && [\text{simplifica } n/n^2 = 1/n]\end{aligned}$$

Erro comum: esquecer o quadrado em P2 e escrever $\frac{1}{n} \cdot n\lambda = \lambda$. Outro erro: usar P3 sem citar a independência, que é exatamente o que a justifica.

(c) Erro quadrático médio

$$\begin{aligned}\text{EQM}_\lambda(\hat{\lambda}) &= \text{Var}(\hat{\lambda}) + [\text{B}_\lambda(\hat{\lambda})]^2 && [\text{Decomp}] \\ &= \frac{\lambda}{n} + 0^2 && [\text{itens (a) e (b)}] \\ &= \frac{\lambda}{n}.\end{aligned}$$

(d) Consistência em média quadrática

Fixamos um valor qualquer de $\lambda > 0$. Ele **não muda com n** , então funciona como uma constante no limite:

$$\lim_{n \rightarrow \infty} \text{EQM}_\lambda(\hat{\lambda}) = \lim_{n \rightarrow \infty} \frac{\lambda}{n} = 0. \quad [\text{Li1 com } c = \lambda]$$

Como isso vale para todo $\lambda > 0$, $\hat{\lambda}$ é médio quadrático consistente.

(e) Consistência em probabilidade

Objetivo: para todo $\varepsilon > 0$, mostrar que $\mathbb{P}(|\hat{\lambda} - \lambda| \geq \varepsilon) \rightarrow 0$.

$$\begin{aligned}\mathbb{P}(|\hat{\lambda} - \lambda| \geq \varepsilon) &\leq \frac{\text{EQM}_\lambda(\hat{\lambda})}{\varepsilon^2} && [\text{Cheb}] \\ &= \frac{\lambda/n}{\varepsilon^2} = \frac{\lambda}{n\varepsilon^2}. && [\text{item (c)}]\end{aligned}$$

Com λ e ε fixos, $\frac{\lambda}{\varepsilon^2}$ é uma constante e $\frac{\lambda}{n\varepsilon^2} \rightarrow 0$ (Li1). Como toda probabilidade é ≥ 0 , temos

$$0 \leq \mathbb{P}(|\hat{\lambda} - \lambda| \geq \varepsilon) \leq \frac{\lambda}{n\varepsilon^2} \rightarrow 0,$$

e pelo confronto (Li2) a probabilidade tende a zero. Portanto $\hat{\lambda} \xrightarrow{\mathbb{P}} \lambda$.

Atalho legítimo em prova: “como $\hat{\lambda}$ é consistente em MQ (item d), pelo Teorema 5.3 é consistente em probabilidade”. Mas é bom saber escrever a cadeia acima, porque é ela que *prova* o teorema.

(f) Verossimilhança, escore, I_o , I_e e Cramér–Rao

Verossimilhança. Por independência, a densidade conjunta é o produto:

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!}.$$

Log-verossimilhança. O log transforma o produto em soma:

$$\ell(\lambda) = \log \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!} = \sum_{i=1}^n \log \left(\frac{e^{-\lambda} \lambda^{y_i}}{y_i!} \right) \quad [\text{L1}]$$

$$= \sum_{i=1}^n \left[\log e^{-\lambda} + \log \lambda^{y_i} - \log(y_i!) \right] \quad [\text{L1 e L4}]$$

$$= \sum_{i=1}^n \left[-\lambda + y_i \log \lambda - \log(y_i!) \right] \quad [\text{L3 e L2}]$$

$$= \sum_{i=1}^n (-\lambda) + \sum_{i=1}^n y_i \log \lambda - \sum_{i=1}^n \log(y_i!) \quad [\text{S3}]$$

$$= -n\lambda + \left(\sum_{i=1}^n y_i \right) \log \lambda - \sum_{i=1}^n \log(y_i!). \quad [\text{S1 e S2}]$$

Escore. Derivamos termo a termo em relação a λ (D3). Os y_i são números observados, logo constantes:

$$\frac{d}{d\lambda}(-n\lambda) = -n \quad [\text{D1}]$$

$$\frac{d}{d\lambda} \left[\left(\sum_i y_i \right) \log \lambda \right] = \left(\sum_i y_i \right) \cdot \frac{1}{\lambda} \quad [\text{D1 e D2}]$$

$$\frac{d}{d\lambda} \left[\sum_i \log(y_i!) \right] = 0 \quad [\text{D1: não depende de } \lambda]$$

$$U(\lambda) = -n + \frac{\sum_{i=1}^n y_i}{\lambda}.$$

Informação observada. Derivamos de novo e trocamos o sinal. Escreva $\frac{\sum_i y_i}{\lambda} = \left(\sum_i y_i \right) \lambda^{-1}$:

$$\frac{d^2 \ell}{d\lambda^2} = \frac{dU}{d\lambda} = 0 + \left(\sum_i y_i \right) \cdot (-1) \lambda^{-2} \quad [\text{D1 e D2}]$$

$$= -\frac{\sum_i y_i}{\lambda^2},$$

$$I_o(\lambda) = -\frac{d^2 \ell}{d\lambda^2} = \frac{\sum_{i=1}^n y_i}{\lambda^2}.$$

Informação esperada. Trocamos os valores observados y_i pelas variáveis aleatórias Y_i e tomamos esperança:

$$I_e(\lambda) = \mathbb{E} \left[\frac{\sum_i Y_i}{\lambda^2} \right] = \frac{1}{\lambda^2} \sum_{i=1}^n \mathbb{E}(Y_i) \quad [\text{P1}]$$

$$= \frac{n\lambda}{\lambda^2} = \frac{n}{\lambda}. \quad [\text{P8, S1}]$$

Conferência pela outra definição, $I_e = \mathbb{E}[U^2]$. Primeiro, $\mathbb{E}[U] = -n + \frac{n\lambda}{\lambda} = 0$. Então $\mathbb{E}[U^2] = \text{Var}(U)$ (P4), e

$$\text{Var}(U) = \text{Var}\left(-n + \frac{1}{\lambda} \sum_i Y_i\right) = \frac{1}{\lambda^2} \text{Var}\left(\sum_i Y_i\right) = \frac{n\lambda}{\lambda^2} = \frac{n}{\lambda}$$

usando P2 (a constante $-n$ some e $1/\lambda$ sai ao quadrado) e P3. As duas definições batem.

Limite de Cramér-Rao. Aqui o alvo é o próprio λ , então $\tau(\lambda) = \lambda$ e $\tau'(\lambda) = 1$:

$$\text{LICR} = \frac{[\tau'(\lambda)]^2}{I_e(\lambda)} = \frac{1}{n/\lambda} = \frac{\lambda}{n}.$$

Como $\text{Var}(\hat{\lambda}) = \lambda/n$ (item b) é *igual* ao limite, $\hat{\lambda}$ é **eficiente**. Nenhum estimador não-viciado de λ tem variância menor.

Bônus: o EMV. Igualando o escore a zero:

$$-n + \frac{\sum_i y_i}{\lambda} = 0 \iff \frac{\sum_i y_i}{\lambda} = n \iff \lambda = \frac{\sum_i y_i}{n} = \bar{y}.$$

A segunda derivada $-\sum_i y_i/\lambda^2 < 0$ confirma que é um máximo. Aqui o EMV coincide com o estimador de momentos ($\mathbb{E}(Y) = \lambda = \bar{Y}$), mas isso *nem sempre* acontece.

(g) Numérico

Amostra (2, 0, 3, 1, 4), com $n = 5$:

$$\sum_i y_i = 2 + 0 + 3 + 1 + 4 = 10,$$

$$\hat{\lambda} = \frac{10}{5} = 2,$$

$$\widehat{\text{Var}}(\hat{\lambda}) = \frac{\hat{\lambda}}{n} = \frac{2}{5} = 0,4 \quad (\text{trocamos o } \lambda \text{ desconhecido pela estimativa}),$$

$$\text{erro-padrão} = \sqrt{0,4} \approx 0,632.$$

9.2 Exemplo 2 – Exponencial: dois estimadores não-viciados, só um consistente

Enunciado. Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim}$ Exponencial com *média* β , isto é, $f(y; \beta) = \frac{1}{\beta} e^{-y/\beta}$ para $y > 0$. Compare $T_1 = \bar{Y}$ e $T_2 = n Y_{(1)}$, em que $Y_{(1)} = \min(Y_1, \dots, Y_n)$.

Passo 0 – momentos e f.d.a. de Y

Esperança. Reescrevemos o integrando no formato da integral gama $y^{\alpha-1} e^{-(\text{taxa})y}$. Aqui $y = y^{2-1}$ e a taxa é $1/\beta$:

$$\mathbb{E}(Y) = \int_0^\infty y \cdot \frac{1}{\beta} e^{-y/\beta} dy \quad [\text{P7}]$$

$$= \frac{1}{\beta} \int_0^\infty y^{2-1} e^{-(1/\beta)y} dy \quad [\text{I3}]$$

$$= \frac{1}{\beta} \cdot \frac{\Gamma(2)}{(1/\beta)^2} \quad [\text{I1 com } \alpha = 2, \text{ taxa } 1/\beta]$$

$$= \frac{1}{\beta} \cdot \frac{1}{1/\beta^2} \quad [\text{I2: } \Gamma(2) = 1! = 1]$$

$$= \frac{1}{\beta} \cdot \beta^2 = \beta.$$

Segundo momento. Agora $y^2 = y^{3-1}$:

$$\begin{aligned}\mathbb{E}(Y^2) &= \frac{1}{\beta} \int_0^\infty y^{3-1} e^{-(1/\beta)y} dy = \frac{1}{\beta} \cdot \frac{\Gamma(3)}{(1/\beta)^3} & [\text{P7, I3, I1 com } \alpha = 3] \\ &= \frac{1}{\beta} \cdot 2\beta^3 = 2\beta^2. & [\text{I2: } \Gamma(3) = 2! = 2]\end{aligned}$$

Variância.

$$\text{Var}(Y) = \mathbb{E}(Y^2) - [\mathbb{E}(Y)]^2 = 2\beta^2 - \beta^2 = \beta^2. \quad [\text{P4}]$$

F.d.a. e sobrevivência. Para $y > 0$:

$$F(y) = \int_0^y \frac{1}{\beta} e^{-t/\beta} dt = 1 - e^{-y/\beta}, \quad [\text{I5}]$$

$$\mathbb{P}(Y > y) = 1 - F(y) = e^{-y/\beta}. \quad [\text{Pr1}]$$

(a) A distribuição de $Y_{(1)}$ e de T_2

Ideia-chave: o mínimo é maior que y se, e somente se, *todas* as observações são maiores que y .

$$\begin{aligned}\mathbb{P}(Y_{(1)} > y) &= \mathbb{P}(Y_1 > y, Y_2 > y, \dots, Y_n > y) & [\text{Pr5}] \\ &= \prod_{i=1}^n \mathbb{P}(Y_i > y) & [\text{P6: independência}] \\ &= \prod_{i=1}^n e^{-y/\beta} & [\text{P8 + Passo 0}] \\ &= (e^{-y/\beta})^n & [\text{S5}] \\ &= e^{-ny/\beta}. & [\text{L3}]\end{aligned}$$

Compare com a sobrevivência de uma exponencial de média m , que é $e^{-y/m}$. Escrevendo $e^{-ny/\beta} = e^{-y/(\beta/n)}$, vemos que $Y_{(1)}$ é exponencial com **média** β/n .

Agora $T_2 = nY_{(1)}$. Para $t > 0$:

$$\begin{aligned}\mathbb{P}(T_2 > t) &= \mathbb{P}(nY_{(1)} > t) \\ &= \mathbb{P}\left(Y_{(1)} > \frac{t}{n}\right) & [\text{Li3: dividir por } n > 0] \\ &= e^{-n(t/n)/\beta} & [\text{resultado acima com } y = t/n] \\ &= e^{-t/\beta}. & [n \cdot \frac{t}{n} = t]\end{aligned}$$

Ou seja, T_2 tem exatamente a mesma distribuição de uma única observação Y , qualquer que seja n . Multiplicar por n desfaz o encolhimento do mínimo.

(b) Viés e variância de cada estimador

$T_1 = \bar{Y}$. Repetindo os passos do Exemplo 1 (a) e (b), agora com $\mathbb{E}(Y_i) = \beta$ e $\text{Var}(Y_i) = \beta^2$:

$$\mathbb{E}(T_1) = \frac{1}{n} \sum_{i=1}^n \beta = \beta, \quad \text{Var}(T_1) = \frac{1}{n^2} \sum_{i=1}^n \beta^2 = \frac{n\beta^2}{n^2} = \frac{\beta^2}{n}.$$

$T_2 = nY_{(1)}$. Pelo item (a), T_2 tem a mesma distribuição de Y , então herda os momentos do Passo 0:

$$\mathbb{E}(T_2) = \beta, \quad \text{Var}(T_2) = \beta^2.$$

Também dá para ver a esperança por P1: $\mathbb{E}(T_2) = n \mathbb{E}(Y_{(1)}) = n \cdot \frac{\beta}{n} = \beta$.

Conclusão: $B(T_1) = B(T_2) = 0$, ou seja, *ambos são não-viciados*.

(c) EQM e eficiência relativa

Como ambos são não-viciados, pela Decomp o EQM é só a variância:

$$\text{EQM}(T_1) = \frac{\beta^2}{n}, \quad \text{EQM}(T_2) = \beta^2.$$

$$\begin{aligned} \text{ef}(T_1, T_2) &= \frac{\text{EQM}(T_2)}{\text{EQM}(T_1)} = \frac{\beta^2}{\beta^2/n} && [\text{definição}] \\ &= \beta^2 \cdot \frac{n}{\beta^2} && [\text{dividir por fração} = \text{multiplicar pelo inverso}] \\ &= n. \end{aligned}$$

Para $n \geq 2$, $\text{EQM}(T_1) < \text{EQM}(T_2)$ para **todo** $\beta > 0$, então T_1 é uniformemente melhor.

(d) Consistência

T_1 . $\text{EQM}(T_1) = \beta^2/n \rightarrow 0$ (Li1), logo T_1 é consistente em MQ e, portanto, em probabilidade.

T_2 . Vamos calcular a probabilidade de erro diretamente. Tome $0 < \varepsilon < \beta$ (assim $\beta - \varepsilon > 0$):

$$\begin{aligned} \mathbb{P}(|T_2 - \beta| \geq \varepsilon) &= \mathbb{P}(T_2 \leq \beta - \varepsilon) + \mathbb{P}(T_2 \geq \beta + \varepsilon) && [\text{Pr3 e Pr2}] \\ &= F(\beta - \varepsilon) + e^{-(\beta + \varepsilon)/\beta} && [T_2 \text{ tem a f.d.a. } F \text{ do Passo 0}] \\ &= \left(1 - e^{-(\beta - \varepsilon)/\beta}\right) + e^{-(\beta + \varepsilon)/\beta} \\ &= 1 - e^{-1 + \varepsilon/\beta} + e^{-1 - \varepsilon/\beta}. && [\frac{\beta \pm \varepsilon}{\beta} = 1 \pm \frac{\varepsilon}{\beta}] \end{aligned}$$

Repare que **não aparece** n nessa expressão. Ela é estritamente positiva, porque já a segunda parcela $e^{-1 - \varepsilon/\beta}$ é positiva. Logo o limite quando $n \rightarrow \infty$ é essa mesma constante positiva, e não zero: T_2 **não é consistente**.

Numérico, com $\beta = 1$ e $\varepsilon = 0,5$:

$$1 - e^{-0,5} + e^{-1,5} \approx 1 - 0,6065 + 0,2231 = 0,6166.$$

Mesmo com um milhão de observações, há cerca de 62% de chance de T_2 errar por 0,5 ou mais.

Moral: não-vício não garante consistência. O que importa é se a dispersão do estimador encolhe com n ; a de T_2 não encolhe.

9.3 Exemplo 3 – Um estimador viciado pode ter EQM menor

Enunciado. Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ com σ^2 conhecido. Considere $T_c = c\bar{Y}$ com $0 < c \leq 1$ (“encolher” a média em direção a zero).

Viés

$$\begin{aligned} \mathbb{E}(T_c) &= \mathbb{E}(c\bar{Y}) = c\mathbb{E}(\bar{Y}) && [\text{P1}] \\ &= c\mu, && [\text{Teorema 2.3}] \\ \text{B}(T_c) &= \mathbb{E}(T_c) - \mu = c\mu - \mu = (c - 1)\mu. && [\text{coloca } \mu \text{ em evidência}] \end{aligned}$$

Se $c < 1$ e $\mu \neq 0$, o estimador é viciado.

Variância

$$\begin{aligned} \text{Var}(T_c) &= \text{Var}(c\bar{Y}) = c^2 \text{Var}(\bar{Y}) && [\text{P2}] \\ &= c^2 \frac{\sigma^2}{n}. && [\text{Teorema 2.3}] \end{aligned}$$

EQM

$$\begin{aligned}
 \text{EQM}_\mu(T_c) &= \text{Var}(T_c) + [\text{B}(T_c)]^2 && [\text{Decomp}] \\
 &= \frac{c^2\sigma^2}{n} + [(c-1)\mu]^2 \\
 &= \frac{c^2\sigma^2}{n} + (c-1)^2\mu^2. && [(ab)^2 = a^2b^2]
 \end{aligned}$$

Leia a fórmula: diminuir c *reduz* a primeira parcela (variância) mas *aumenta* a segunda (viés²). É o **compromisso viés-variância**.

Comparação numérica: $n = 10$, $\sigma^2 = 1$, $c = 1$ **contra** $c = 0,9$

$$\begin{aligned}
 \text{EQM}(T_1) &= \frac{1^2 \cdot 1}{10} + (1-1)^2\mu^2 = 0,1, \\
 \text{EQM}(T_{0,9}) &= \frac{(0,9)^2 \cdot 1}{10} + (0,9-1)^2\mu^2 = \frac{0,81}{10} + (-0,1)^2\mu^2 = 0,081 + 0,01\mu^2.
 \end{aligned}$$

Quando $T_{0,9}$ é melhor? Resolvemos a desigualdade passo a passo:

$$\begin{aligned}
 0,081 + 0,01\mu^2 &< 0,1 \\
 0,01\mu^2 &< 0,019 && [\text{Li3: subtrai } 0,081] \\
 \mu^2 &< 1,9 && [\text{Li3: divide por } 0,01 > 0] \\
 |\mu| &< \sqrt{1,9} \approx 1,378. && [\text{Li4}]
 \end{aligned}$$

Conclusão: se $|\mu| < 1,378$, o estimador viciado $T_{0,9}$ tem EQM menor; se $|\mu| > 1,378$, $\bar{Y}$ vence. As curvas se cruzam, então *nenhum é uniformemente melhor*. Como μ é desconhecido, não sabemos de antemão em qual região estamos.

Bônus: o c ótimo (e por que não dá para usá-lo)

Derivamos o EQM em relação a c e igualamos a zero. Pela regra da cadeia, $\frac{d}{dc}(c-1)^2 = 2(c-1)$:

$$\begin{aligned}
 \frac{d}{dc} \text{EQM} &= \frac{2c\sigma^2}{n} + 2(c-1)\mu^2 = 0 \\
 c\frac{\sigma^2}{n} + c\mu^2 - \mu^2 &= 0 && [\text{divide por } 2 \text{ e distribui}] \\
 c\left(\frac{\sigma^2}{n} + \mu^2\right) &= \mu^2 && [\text{coloca } c \text{ em evidência}] \\
 c^* &= \frac{\mu^2}{\mu^2 + \sigma^2/n}.
 \end{aligned}$$

O c^* depende do μ desconhecido, então $c^*\bar{Y}$ **não é uma estatística**. Lembre que estimador não pode depender do parâmetro.

Consistência de T_c com $c < 1$ fixo

O viés $(c-1)\mu$ **não depende de n** . Logo $\text{EQM} \rightarrow (c-1)^2\mu^2 \neq 0$ quando $\mu \neq 0$, e não há consistência em MQ. Também não há consistência em probabilidade: por LGN e Cont, $T_c = c\bar{Y} \xrightarrow{\mathbb{P}} c\mu \neq \mu$. Ganhar em amostras pequenas não garante bom comportamento assintótico.

9.4 Exemplo 4 – Momentos: exponencial com taxa λ , incluindo o viés

Enunciado. Seja $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$, com $f(y; \lambda) = \lambda e^{-\lambda y}$ para $y > 0$. Encontre o estimador de momentos de λ e estude suas propriedades.

Passo 1 – momento populacional

Há um parâmetro ($p = 1$), então basta o primeiro momento.

Via integral gama:

$$\begin{aligned}\mathbb{E}(Y) &= \int_0^\infty y \cdot \lambda e^{-\lambda y} dy & [\text{P7}] \\ &= \lambda \int_0^\infty y^{2-1} e^{-\lambda y} dy & [\text{I3}; y = y^{2-1}] \\ &= \lambda \cdot \frac{\Gamma(2)}{\lambda^2} & [\text{I1}; \alpha = 2, \text{ taxa } \lambda] \\ &= \lambda \cdot \frac{1}{\lambda^2} = \frac{1}{\lambda}. & [\text{I2}]\end{aligned}$$

Via integração por partes (para conferir). Com $u = y$, $dv = \lambda e^{-\lambda y} dy$, temos $du = dy$ e $v = -e^{-\lambda y}$:

$$\mathbb{E}(Y) = \left[-y e^{-\lambda y} \right]_0^\infty + \int_0^\infty e^{-\lambda y} dy = (0 - 0) + \left[-\frac{1}{\lambda} e^{-\lambda y} \right]_0^\infty = 0 + \left(0 + \frac{1}{\lambda} \right) = \frac{1}{\lambda}.$$

No primeiro colchete, $y e^{-\lambda y} \rightarrow 0$ quando $y \rightarrow \infty$ porque a exponencial decai mais rápido do que y cresce.

Passo 2 – igualar e resolver

O método manda igualar o momento populacional ao amostral, trocando λ por $\tilde{\lambda}$:

$$\begin{aligned}\frac{1}{\tilde{\lambda}} &= \bar{Y} \\ 1 &= \tilde{\lambda} \bar{Y} & [\text{multiplica os dois lados por } \tilde{\lambda}] \\ \tilde{\lambda} &= \frac{1}{\bar{Y}}. & [\text{divide por } \bar{Y} > 0]\end{aligned}$$

($\bar{Y} > 0$ com probabilidade 1, pois cada $Y_i > 0$.)

Passo 3 – consistência

- (i) Pela LGN, $\bar{Y} \xrightarrow{\mathbb{P}} \mathbb{E}(Y) = \frac{1}{\lambda}$.
- (ii) A função $g(x) = \frac{1}{x}$ é contínua em todo $x \neq 0$; em particular, em $x = \frac{1}{\lambda} > 0$.
- (iii) Pela aplicação contínua (Cont), $\tilde{\lambda} = g(\bar{Y}) \xrightarrow{\mathbb{P}} g\left(\frac{1}{\lambda}\right) = \frac{1}{1/\lambda} = \lambda$.

Logo $\tilde{\lambda}$ é consistente.

Passo 4 – viés

Como $\tilde{\lambda} = \frac{1}{\bar{Y}} = \frac{n}{S}$, com $S = \sum_i Y_i$, precisamos de $\mathbb{E}(1/S)$. Para isso precisamos da **distribuição de S** .

4a) FGM de uma $Y \sim \text{Exp}(\lambda)$. Para $t < \lambda$:

$$\begin{aligned}M_Y(t) &= \mathbb{E}(e^{tY}) = \int_0^\infty e^{ty} \lambda e^{-\lambda y} dy & [\text{P7}] \\ &= \lambda \int_0^\infty e^{-(\lambda-t)y} dy & [\text{L3}; e^{ty} e^{-\lambda y} = e^{-(\lambda-t)y}] \\ &= \lambda \cdot \frac{\Gamma(1)}{(\lambda-t)^1} = \frac{\lambda}{\lambda-t}. & [\text{I1 com } \alpha = 1; \text{ I2}]\end{aligned}$$

A condição $t < \lambda$ garante que a taxa $\lambda - t$ é positiva, como I1 exige.
4b) FGM da soma.

$$\begin{aligned} M_S(t) &= \mathbb{E}(e^{t \sum_i Y_i}) = \mathbb{E}\left(\prod_{i=1}^n e^{t Y_i}\right) & [\text{L3}] \\ &= \prod_{i=1}^n \mathbb{E}(e^{t Y_i}) & [\text{P6: independência}] \\ &= \left(\frac{\lambda}{\lambda - t}\right)^n. & [\text{P8 e S5}] \end{aligned}$$

A FGM de uma $\text{Gama}(\alpha, \beta)$ (taxa β) é $\left(\frac{\beta}{\beta - t}\right)^\alpha$. Pela unicidade (Pr4), $S \sim \text{Gama}(n, \lambda)$, ou seja,

$$f_S(s) = \frac{\lambda^n}{\Gamma(n)} s^{n-1} e^{-\lambda s}, \quad s > 0.$$

4c) Cálculo de $\mathbb{E}(1/S)$ (supondo $n \geq 2$):

$$\begin{aligned} \mathbb{E}\left(\frac{1}{S}\right) &= \int_0^\infty \frac{1}{s} \cdot \frac{\lambda^n}{\Gamma(n)} s^{n-1} e^{-\lambda s} ds & [\text{P7}] \\ &= \frac{\lambda^n}{\Gamma(n)} \int_0^\infty s^{n-2} e^{-\lambda s} ds & [\text{I3: } s^{-1} s^{n-1} = s^{n-2}] \\ &= \frac{\lambda^n}{\Gamma(n)} \int_0^\infty s^{(n-1)-1} e^{-\lambda s} ds & [\text{reescreve no formato de I1}] \\ &= \frac{\lambda^n}{\Gamma(n)} \cdot \frac{\Gamma(n-1)}{\lambda^{n-1}} & [\text{I1: } \alpha = n-1 > 0] \\ &= \lambda^{n-(n-1)} \cdot \frac{\Gamma(n-1)}{\Gamma(n)} & [\lambda^a / \lambda^b = \lambda^{a-b}] \\ &= \lambda \cdot \frac{\Gamma(n-1)}{(n-1) \Gamma(n-1)} & [\text{I2: } \Gamma(n) = (n-1) \Gamma(n-1)] \\ &= \frac{\lambda}{n-1}. \end{aligned}$$

4d) Esperança e viés de $\tilde{\lambda}$.

$$\begin{aligned} \mathbb{E}(\tilde{\lambda}) &= \mathbb{E}\left(\frac{n}{S}\right) = n \mathbb{E}\left(\frac{1}{S}\right) & [\text{P1}] \\ &= \frac{n\lambda}{n-1}, \\ B(\tilde{\lambda}) &= \frac{n\lambda}{n-1} - \lambda = \frac{n\lambda - (n-1)\lambda}{n-1} & [\text{denominador comum}] \\ &= \frac{n\lambda - n\lambda + \lambda}{n-1} = \frac{\lambda}{n-1}. \end{aligned}$$

Então $\tilde{\lambda}$ é **viciado** (superestima λ em média), mas $B(\tilde{\lambda}) = \frac{\lambda}{n-1} \rightarrow 0$: é **assintoticamente não-viciado**.

Por que superestima? A função $g(x) = 1/x$ é convexa em $x > 0$. Pela desigualdade de Jensen, $\mathbb{E}[g(\bar{Y})] \geq g(\mathbb{E}\bar{Y})$, isto é, $\mathbb{E}(1/\bar{Y}) \geq 1/\mathbb{E}(\bar{Y}) = \lambda$. É a mesma lição da observação sobre funções não lineares: $\mathbb{E}(1/\bar{Y}) \neq 1/\mathbb{E}(\bar{Y})$.

Correção do viés. Como $\mathbb{E}(\tilde{\lambda}) = \frac{n}{n-1} \lambda$, multiplicando por $\frac{n-1}{n}$ (P1):

$$\mathbb{E}\left(\frac{n-1}{n} \tilde{\lambda}\right) = \frac{n-1}{n} \cdot \frac{n}{n-1} \lambda = \lambda.$$

Logo $\tilde{\lambda}^* = \frac{n-1}{n} \cdot \frac{n}{S} = \frac{n-1}{S}$ é não-viciado.

Numérico

Amostra (0,4; 1,1; 0,7; 2,8), $n = 4$:

$$\begin{aligned}\sum_i y_i &= 0,4 + 1,1 + 0,7 + 2,8 = 5,0, \\ \bar{y} &= \frac{5,0}{4} = 1,25, \\ \tilde{\lambda} &= \frac{1}{1,25} = 0,8, \\ \tilde{\lambda}^* &= \frac{n-1}{\sum_i y_i} = \frac{3}{5,0} = 0,6.\end{aligned}$$

9.5 Exemplo 5 – Momentos com dois parâmetros: Gama(α, β)

Enunciado. Seja $Y_1, \dots, Y_n$ a.a. de $Y \sim \text{Gama}(\alpha, \beta)$ (taxa), com $f(y) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$ para $y > 0$, e ambos os parâmetros desconhecidos. Encontre os estimadores de momentos.

Passo 1 – dois parâmetros exigem dois momentos

Primeiro momento.

$$\begin{aligned}\mathbb{E}(Y) &= \int_0^\infty y \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y} dy && [\text{P7}] \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty y^{(\alpha+1)-1} e^{-\beta y} dy && [\text{I3}; y \cdot y^{\alpha-1} = y^\alpha = y^{(\alpha+1)-1}] \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+1)}{\beta^{\alpha+1}} && [\text{I1 com expoente } \alpha+1] \\ &= \frac{\Gamma(\alpha+1)}{\Gamma(\alpha)} \cdot \frac{\beta^\alpha}{\beta^{\alpha+1}} = \frac{\alpha \Gamma(\alpha)}{\Gamma(\alpha)} \cdot \frac{1}{\beta} && [\text{I2}] \\ &= \frac{\alpha}{\beta}.\end{aligned}$$

Segundo momento. Mesmo caminho, agora com $y^2 \cdot y^{\alpha-1} = y^{(\alpha+2)-1}$:

$$\begin{aligned}\mathbb{E}(Y^2) &= \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+2)}{\beta^{\alpha+2}} && [\text{P7, I3, I1}] \\ &= \frac{(\alpha+1)\alpha \Gamma(\alpha)}{\Gamma(\alpha)} \cdot \frac{1}{\beta^2} && [\text{I2 duas vezes}] \\ &= \frac{\alpha(\alpha+1)}{\beta^2}.\end{aligned}$$

O passo “I2 duas vezes” é $\Gamma(\alpha+2) = (\alpha+1)\Gamma(\alpha+1) = (\alpha+1)\alpha \Gamma(\alpha)$.

Passo 2 – montar o sistema

$$(i) \quad \frac{\tilde{\alpha}}{\tilde{\beta}} = M_1, \quad (ii) \quad \frac{\tilde{\alpha}(\tilde{\alpha}+1)}{\tilde{\beta}^2} = M_2.$$

Passo 3 – resolver

Separe a fração de (ii) em duas:

$$\frac{\tilde{\alpha}(\tilde{\alpha}+1)}{\tilde{\beta}^2} = \frac{\tilde{\alpha}^2 + \tilde{\alpha}}{\tilde{\beta}^2} = \frac{\tilde{\alpha}^2}{\tilde{\beta}^2} + \frac{\tilde{\alpha}}{\tilde{\beta}^2}.$$

Use (i) ao quadrado: $\frac{\tilde{\alpha}^2}{\tilde{\beta}^2} = \left(\frac{\tilde{\alpha}}{\tilde{\beta}}\right)^2 = M_1^2$. Substituindo em (ii):

$$\begin{aligned} M_1^2 + \frac{\tilde{\alpha}}{\tilde{\beta}^2} &= M_2 \\ \text{(iii)} \quad \frac{\tilde{\alpha}}{\tilde{\beta}^2} &= M_2 - M_1^2. \end{aligned} \quad [\text{subtraia } M_1^2]$$

Divida (i) por (iii), membro a membro:

$$\begin{aligned} \frac{\tilde{\alpha}/\tilde{\beta}}{\tilde{\alpha}/\tilde{\beta}^2} &= \frac{M_1}{M_2 - M_1^2} \\ \frac{\tilde{\alpha}}{\tilde{\beta}} \cdot \frac{\tilde{\beta}^2}{\tilde{\alpha}} &= \frac{M_1}{M_2 - M_1^2} \quad [\text{inverso da fração}] \\ \tilde{\beta} &= \frac{M_1}{M_2 - M_1^2}. \quad [\text{cancela } \tilde{\alpha} \text{ e um } \tilde{\beta}] \end{aligned}$$

Volte em (i) para achar $\tilde{\alpha}$:

$$\tilde{\alpha} = M_1 \tilde{\beta} = M_1 \cdot \frac{M_1}{M_2 - M_1^2} = \frac{M_1^2}{M_2 - M_1^2}.$$

Interpretação do denominador. Dividindo o Lema-SQ por n :

$$\frac{1}{n} \sum_i (Y_i - \bar{Y})^2 = \frac{1}{n} \sum_i Y_i^2 - \bar{Y}^2 = M_2 - M_1^2.$$

É a variância amostral com divisor n : positiva, a menos que todas as observações sejam iguais.

Numérico

Amostra (1, 2, 2, 3, 7), $n = 5$. Organize em tabela (é assim que se faz em prova):

i	1	2	3	4	5	Soma
y_i	1	2	2	3	7	15
y_i^2	1	4	4	9	49	67
$(y_i - \bar{y})^2$	4	1	1	0	16	22

$$\begin{aligned} M_1 &= \frac{15}{5} = 3, & M_2 &= \frac{67}{5} = 13,4, \\ M_2 - M_1^2 &= 13,4 - 9 = 4,4 & \left(\text{confere: } \frac{22}{5} = 4,4 \right), \\ \tilde{\beta} &= \frac{3}{4,4} = \frac{15}{22} \approx 0,682, \\ \tilde{\alpha} &= \frac{3^2}{4,4} = \frac{9}{4,4} = \frac{45}{22} \approx 2,045. \end{aligned}$$

Conferência na equação (i): $\tilde{\alpha}/\tilde{\beta} = \frac{45/22}{15/22} = \frac{45}{15} = 3 = M_1$. Correto.

9.6 Exemplo 6 – Momentos: Normal com μ e σ^2 desconhecidos

Passo 1. $\mathbb{E}(Y) = \mu$ e, por P4, $\mathbb{E}(Y^2) = \text{Var}(Y) + [\mathbb{E}(Y)]^2 = \sigma^2 + \mu^2$.

Passo 2 (sistema).

$$\text{(i)} \quad \tilde{\mu} = M_1, \quad \text{(ii)} \quad \tilde{\sigma}^2 + \tilde{\mu}^2 = M_2.$$

Passo 3 (resolver). De (i), $\tilde{\mu} = \bar{Y}$. Substituindo em (ii):

$$\begin{aligned}\tilde{\sigma}^2 &= M_2 - \tilde{\mu}^2 = M_2 - M_1^2 && [\text{subtrai } \tilde{\mu}^2] \\ &= \frac{1}{n} \sum_i Y_i^2 - \bar{Y}^2 = \frac{1}{n} \left[\sum_i Y_i^2 - n\bar{Y}^2 \right] && [\text{põe } \frac{1}{n} \text{ em evidência}] \\ &= \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2. && [\text{Lema-SQ}]\end{aligned}$$

Passo 4 (esperança).

$$\begin{aligned}\mathbb{E}(\tilde{\sigma}^2) &= \frac{1}{n} \mathbb{E} \left[\sum_i (Y_i - \bar{Y})^2 \right] && [\text{P1}] \\ &= \frac{1}{n} (n-1) \sigma^2 = \frac{n-1}{n} \sigma^2. && [\text{Teo-SQ}]\end{aligned}$$

O estimador de momentos da variância usa divisor n , e não $n-1$. A sua variância e o seu EQM ficam para a lista.

9.7 Exemplo 7 – Momentos: quando a estimativa contradiz os dados

Enunciado. Seja $Y \sim U(\theta, \theta+1)$, $\theta \in \mathbb{R}$. A densidade é $f(y; \theta) = \frac{1}{(\theta+1)-\theta} = 1$ para $\theta < y < \theta+1$, e zero fora desse intervalo.

Passo 1 – momentos

$$\begin{aligned}\mathbb{E}(Y) &= \int_{\theta}^{\theta+1} y \cdot 1 \, dy = \left[\frac{y^2}{2} \right]_{\theta}^{\theta+1} && [\text{P7, I4}] \\ &= \frac{(\theta+1)^2 - \theta^2}{2} = \frac{\theta^2 + 2\theta + 1 - \theta^2}{2} && [(a+b)^2 = a^2 + 2ab + b^2] \\ &= \frac{2\theta + 1}{2} = \theta + \frac{1}{2}.\end{aligned}$$

$$\begin{aligned}\mathbb{E}(Y^2) &= \left[\frac{y^3}{3} \right]_{\theta}^{\theta+1} = \frac{(\theta+1)^3 - \theta^3}{3} && [\text{P7, I4}] \\ &= \frac{\theta^3 + 3\theta^2 + 3\theta + 1 - \theta^3}{3} && [(a+b)^3 = a^3 + 3a^2b + 3ab^2 + b^3] \\ &= \theta^2 + \theta + \frac{1}{3},\end{aligned}$$

$$\begin{aligned}\text{Var}(Y) &= \mathbb{E}(Y^2) - [\mathbb{E}(Y)]^2 && [\text{P4}] \\ &= \theta^2 + \theta + \frac{1}{3} - \left(\theta + \frac{1}{2} \right)^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}.\end{aligned}$$

Passo 2 – estimador de momentos

$$\tilde{\theta} + \frac{1}{2} = \bar{Y} \implies \tilde{\theta} = \bar{Y} - \frac{1}{2}.$$

Passo 3 – propriedades

$$\mathbb{E}(\tilde{\theta}) = \mathbb{E}(\bar{Y}) - \frac{1}{2} \quad [\text{P1}]$$

$$= \theta + \frac{1}{2} - \frac{1}{2} = \theta, \quad [\text{Teorema 2.3}]$$

$$\text{Var}(\tilde{\theta}) = \text{Var}(\bar{Y}) = \frac{1/12}{n} = \frac{1}{12n}. \quad [\text{P2 com } a = 1; \text{ Teorema 2.3}]$$

Então $\tilde{\theta}$ é não-viciado, com $\text{EQM} = \frac{1}{12n} \rightarrow 0$: é consistente.

Passo 4 – o problema com os dados

Amostra (0,9; 1,0; 1,1; 1,85):

$$\bar{y} = \frac{0,9 + 1,0 + 1,1 + 1,85}{4} = \frac{4,85}{4} = 1,2125, \quad \tilde{\theta} = 1,2125 - 0,5 = 0,7125.$$

Quais valores de θ são compatíveis com a amostra? Cada observação precisa cair dentro do suporte, $\theta < y_i < \theta + 1$. Separamos as duas desigualdades:

- $\theta < y_i$ para **todo** $i \iff \theta < \min_i y_i = 0,9$;
- $y_i < \theta + 1$ para **todo** $i \iff \theta > y_i - 1$ para todo $i \iff \theta > \max_i y_i - 1 = 1,85 - 1 = 0,85$.

Só valores de θ em (0,85; 0,9) são compatíveis com os dados. A verossimilhança mostra o mesmo:

$$L(\theta) = \prod_{i=1}^n \mathbf{1}\{\theta < y_i < \theta + 1\} = \mathbf{1}\{\max_i y_i - 1 < \theta < \min_i y_i\}.$$

Ela vale 1 nesse intervalo e 0 fora dele.

Como $\tilde{\theta} = 0,7125 < 0,85$, temos $\tilde{\theta} + 1 = 1,7125 < 1,85$. Ou seja, o modelo ajustado diria que a observação 1,85 era **impossível**: $f(1,85; \tilde{\theta}) = 0$ e $L(\tilde{\theta}) = 0$.

Lição: o método dos momentos só olha para $\bar{Y}$ e ignora a informação dos extremos da amostra. Quando o suporte depende do parâmetro, sempre confira a compatibilidade e compare com estimadores baseados em $Y_{(1)}$ ou $Y_{(n)}$.

10 Roteiros de prova (checklist)

Mostrar que T é não-viciado. Calcule $\mathbb{E}_\theta(T)$ usando linearidade (escreva T como combinação de Y_i sempre que possível) e mostre que é igual a θ para todo θ .

Encontrar $\text{Var}(T)$. Se $T = \sum a_i Y_i$ com Y_i independentes: $\sum a_i^2 \text{Var}(Y_i)$. Se T envolve somas de quadrados sob normalidade: escreva T como constante $\times \chi^2$. Se T é máximo ou mínimo: obtenha a densidade pelo Teorema 2.8 e integre para $\mathbb{E}(T)$ e $\mathbb{E}(T^2)$.

Encontrar o EQM. $\text{EQM} = \text{Var} + B^2$. Nunca esqueça o viés ao quadrado.

Consistência em MQ. Mostre que $\lim_{n \rightarrow \infty} \text{EQM}_\theta(T_n) = 0$ para cada θ fixo.

Consistência em probabilidade. Ou (i) cite $\text{MQ} \Rightarrow \text{P}$, escrevendo a cadeia de Chebyshev $\mathbb{P}(|T_n - \theta| \geq \varepsilon) \leq \text{EQM} / \varepsilon^2 \rightarrow 0$; ou (ii) calcule $\mathbb{P}(|T_n - \theta| \geq \varepsilon)$ diretamente pela f.d.a.; ou (iii) use LGN + aplicação contínua.

Não-consistência. Exiba um $\varepsilon > 0$ com $\mathbb{P}(|T_n - \theta| \geq \varepsilon) \not\rightarrow 0$.

Comparar estimadores. Calcule os dois EQM, forme a diferença ou a razão e estude o sinal *como função de θ e de n* . Conclua se há dominância uniforme ou cruzamento, e discuta também viés e consistência.

Estimador de momentos. Roteiro da seção do método dos momentos: momentos populacionais $\rightarrow$ igualar aos amostrais $\rightarrow$ resolver $\rightarrow$ checar Θ e compatibilidade com os dados.