

CE309 – Inferência Estatística

Lista 6 – Propriedades de Estimadores e Método dos Momentos
Resolução comentada passo a passo

Sumário

Como ler esta resolução

Cada passagem algébrica traz uma etiqueta cinza à direita dizendo qual propriedade foi usada. As etiquetas são as mesmas do guia de estudos:

Etiqueta	Propriedade
P1	$\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$; $\mathbb{E}(\sum_i X_i) = \sum_i \mathbb{E}(X_i)$ (linearidade)
P2	$\text{Var}(aX + b) = a^2 \text{Var}(X)$
P3	X_i independentes $\Rightarrow \text{Var}(\sum_i X_i) = \sum_i \text{Var}(X_i)$
P4	$\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$, ou seja, $\mathbb{E}(X^2) = \text{Var}(X) + [\mathbb{E}(X)]^2$
P5	$\mathbb{E}(c) = c$, $\text{Var}(c) = 0$
P6	independência: $\mathbb{E}(XW) = \mathbb{E}(X)\mathbb{E}(W)$; $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$
P7	$\mathbb{E}[g(X)] = \int g(x)f(x)dx$ ou $\sum_x g(x)p(x)$ (LOTUS)
P8	identicamente distribuídas: $\mathbb{E}(Y_i) = \mathbb{E}(Y)$, $\text{Var}(Y_i) = \text{Var}(Y)$, $F_{Y_i} = F_Y$
S1, S2, S3	$\sum c = nc$; $\sum cx_i = c \sum x_i$; $\sum (x_i + w_i) = \sum x_i + \sum w_i$
S4, S5	$\sum x_i = n\bar{x}$; $\prod c = c^n$
I1	$\int_0^\infty y^{\alpha-1} e^{-\beta y} dy = \Gamma(\alpha)/\beta^\alpha$
I2	$\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$; $\Gamma(m) = (m-1)!$
I3	constante sai da integral
I4	$\int_a^b y^k dy = \frac{b^{k+1} - a^{k+1}}{k+1}$
Pr1, Pr2, Pr3	complemento; união disjunta; $ X - c \geq \varepsilon \iff X \leq c - \varepsilon$ ou $X \geq c + \varepsilon$
Pr5	$\{Y_{(n)} \leq y\} = \{Y_1 \leq y, \dots, Y_n \leq y\}$
Li1, Li2, Li3, Li4	$c/n \rightarrow 0$; confronto; operações que preservam desigualdade; $a, b \geq 0$: $a < b \iff a^2 < b^2$
Decomp	$\text{EQM} = \text{Var} + B^2$
Cheb	$\mathbb{P}(T - \theta \geq \varepsilon) \leq \text{EQM}(T)/\varepsilon^2$
LGN, Cont	$\bar{Y} \xrightarrow{\mathbb{P}} \mathbb{E}(Y)$; $T_n \xrightarrow{\mathbb{P}} \theta$ e g contínua em $\theta \Rightarrow g(T_n) \xrightarrow{\mathbb{P}} g(\theta)$

1 Exercício 1 – Bernoulli

Enunciado. $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Ber}(p)$, $i = 1, \dots, n$, e $\hat{p} = \frac{1}{n} \sum_{i=1}^n Y_i$.

Passo 0 – momentos da Bernoulli

Y assume o valor 1 com probabilidade p e o valor 0 com probabilidade $1 - p$.

$$\mathbb{E}(Y) = 0 \cdot (1 - p) + 1 \cdot p = p. \quad [\text{P7}]$$

Como $Y \in \{0, 1\}$, vale $Y^2 = Y$ ($0^2 = 0$ e $1^2 = 1$). Logo $\mathbb{E}(Y^2) = \mathbb{E}(Y) = p$ e

$$\begin{aligned} \text{Var}(Y) &= \mathbb{E}(Y^2) - [\mathbb{E}(Y)]^2 \\ &= p - p^2 = p(1 - p). \end{aligned} \quad \begin{array}{l} [\text{P4}] \\ [\text{põe } p \text{ em evidência}] \end{array}$$

(a) Não-vício

Objetivo: $\mathbb{E}(\hat{p}) = p$ para todo $p \in (0, 1)$.

$$\begin{aligned}\mathbb{E}(\hat{p}) &= \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) \\&= \frac{1}{n} \mathbb{E}\left(\sum_{i=1}^n Y_i\right) && [\text{P1: } 1/n \text{ sai}] \\&= \frac{1}{n} \sum_{i=1}^n \mathbb{E}(Y_i) && [\text{P1: esperança da soma}] \\&= \frac{1}{n} \sum_{i=1}^n p && [\text{P8 + Passo 0}] \\&= \frac{1}{n} \cdot np = p. && [\text{S1}]\end{aligned}$$

Resposta

$B_p(\hat{p}) = \mathbb{E}(\hat{p}) - p = p - p = 0$ para todo $p \in (0, 1)$. Logo $\hat{p}$ é não-viciado para p .

(b) Variância

$$\begin{aligned}\text{Var}(\hat{p}) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) \\&= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n Y_i\right) && [\text{P2: } 1/n \text{ sai ao quadrado}] \\&= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) && [\text{P3: } Y_i \text{ independentes}] \\&= \frac{1}{n^2} \sum_{i=1}^n p(1-p) && [\text{P8 + Passo 0}] \\&= \frac{1}{n^2} \cdot np(1-p) && [\text{S1}] \\&= \frac{p(1-p)}{n}.\end{aligned}$$

Resposta

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

(c) Erro quadrático médio

$$\begin{aligned}\text{EQM}_p(\hat{p}) &= \text{Var}(\hat{p}) + [B_p(\hat{p})]^2 && [\text{Decomp}] \\&= \frac{p(1-p)}{n} + 0^2 && [\text{itens (a) e (b)}] \\&= \frac{p(1-p)}{n}.\end{aligned}$$

Resposta

$$\text{EQM}_p(\hat{p}) = \frac{p(1-p)}{n} \text{ (igual à variância, porque o estimador é não-viciado).}$$

(d) Consistência em média quadrática

Fixe $p \in (0, 1)$. A quantidade $p(1-p)$ não depende de n , então funciona como constante:

$$\lim_{n \rightarrow \infty} \text{EQM}_p(\hat{p}) = \lim_{n \rightarrow \infty} \frac{p(1-p)}{n} = 0. \quad [\text{Li1 com } c = p(1-p)]$$

Resposta

Como $\text{EQM}_p(\hat{p}) \rightarrow 0$ para todo $p \in (0, 1)$, $\hat{p}$ é médio quadrático consistente.

(e) Consistência em probabilidade

Objetivo: para todo $\varepsilon > 0$, $\mathbb{P}(|\hat{p} - p| \geq \varepsilon) \rightarrow 0$.

$$\begin{aligned} 0 \leq \mathbb{P}(|\hat{p} - p| \geq \varepsilon) &\leq \frac{\text{EQM}_p(\hat{p})}{\varepsilon^2} && [\text{Cheb}] \\ &= \frac{p(1-p)}{n\varepsilon^2} && [\text{item (c)}] \\ &\leq \frac{1}{4n\varepsilon^2}. && [p(1-p) \leq \tfrac{1}{4}] \end{aligned}$$

A última desigualdade vem de $p(1-p) = \frac{1}{4} - (p - \frac{1}{2})^2 \leq \frac{1}{4}$. Ela é opcional, mas mostra que a cota nem depende de p . Como $\frac{1}{4n\varepsilon^2} \rightarrow 0$ (Li1), pelo confronto (Li2) a probabilidade vai a zero.

Resposta

$\mathbb{P}(|\hat{p} - p| \geq \varepsilon) \rightarrow 0$ para todo $\varepsilon > 0$ e todo p : $\hat{p} \xrightarrow{\mathbb{P}} p$. (Alternativamente: consistência em MQ implica consistência em probabilidade.)

2 Exercício 2 – Média da Normal

Enunciado. $Y_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ e $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n Y_i$. Usamos $\mathbb{E}(Y_i) = \mu$ e $\text{Var}(Y_i) = \sigma^2$.

(a) Não-vício

$$\mathbb{E}(\hat{\mu}) = \frac{1}{n} \mathbb{E}\left(\sum_{i=1}^n Y_i\right) \quad [\text{P1}]$$

$$= \frac{1}{n} \sum_{i=1}^n \mathbb{E}(Y_i) \quad [\text{P1}]$$

$$= \frac{1}{n} \sum_{i=1}^n \mu = \frac{1}{n} \cdot n\mu = \mu. \quad [\text{P8, S1}]$$

Resposta

$B_\mu(\hat{\mu}) = \mu - \mu = 0$ para todo $\mu \in \mathbb{R}$: $\hat{\mu}$ é não-viciado.

(b) Variância

$$\text{Var}(\hat{\mu}) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n Y_i\right) \quad [\text{P2}]$$

$$= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(Y_i) \quad [\text{P3: independência}]$$

$$= \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}. \quad [\text{P8, S1}]$$

Resposta

$$\text{Var}(\hat{\mu}) = \frac{\sigma^2}{n}.$$

(c) EQM

$$\text{EQM}_\mu(\hat{\mu}) = \text{Var}(\hat{\mu}) + [B_\mu(\hat{\mu})]^2 = \frac{\sigma^2}{n} + 0 = \frac{\sigma^2}{n}. \quad [\text{Decomp}]$$

Resposta

$$\text{EQM}_\mu(\hat{\mu}) = \frac{\sigma^2}{n}.$$

(d) Consistência em média quadrática

Com σ^2 fixo (não depende de n):

$$\lim_{n \rightarrow \infty} \text{EQM}_\mu(\hat{\mu}) = \lim_{n \rightarrow \infty} \frac{\sigma^2}{n} = 0. \quad [\text{Li1}]$$

Resposta

$\hat{\mu}$ é médio quadrático consistente para μ .

(e) Consistência em probabilidade

Caminho 1 (Chebyshev).

$$0 \leq \mathbb{P}(|\hat{\mu} - \mu| \geq \varepsilon) \leq \frac{\text{EQM}_\mu(\hat{\mu})}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0. \quad [\text{Cheb, Li1, Li2}]$$

Caminho 2 (cálculo exato, aproveitando a normalidade). Uma combinação linear de normais independentes é normal, então $\hat{\mu} \sim N(\mu, \sigma^2/n)$. Padronizando, $Z = \frac{\hat{\mu} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$, e

$$\mathbb{P}(|\hat{\mu} - \mu| \geq \varepsilon) = \mathbb{P}\left(|Z| \geq \frac{\varepsilon\sqrt{n}}{\sigma}\right) \quad [\text{Li3: divide por } \sigma/\sqrt{n} > 0]$$

$$= 2\left[1 - \Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right)\right]. \quad [\text{simetria da normal; Pr1}]$$

Quando $n \rightarrow \infty$, $\frac{\varepsilon\sqrt{n}}{\sigma} \rightarrow \infty$, logo $\Phi(\cdot) \rightarrow 1$ e a probabilidade vai a 0.

Resposta

$\hat{\mu} \xrightarrow{\mathbb{P}} \mu$, ou seja, $\hat{\mu}$ é consistente em probabilidade.

3 Exercício 3 – Variância da Normal: $\hat{\sigma}_1^2$ contra $\hat{\sigma}_2^2$

Enunciado. $Y_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\hat{\mu} = \bar{Y}$ e

$$\hat{\sigma}_1^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad \hat{\sigma}_2^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

Para simplificar, defina a **soma de quadrados** $SQ = \sum_{i=1}^n (Y_i - \bar{Y})^2$. Então

$$\hat{\sigma}_1^2 = \frac{SQ}{n}, \quad \hat{\sigma}_2^2 = \frac{SQ}{n-1}.$$

Estratégia: tudo depende de $\mathbb{E}(SQ)$ e $\text{Var}(SQ)$. Calcule essas duas quantidades uma vez só e depois divida por n ou $n-1$ usando P1 e P2.

Passo 0a – a identidade algébrica de SQ

$$\begin{aligned} SQ &= \sum_{i=1}^n (Y_i^2 - 2Y_i\bar{Y} + \bar{Y}^2) && [(a-b)^2 = a^2 - 2ab + b^2] \\ &= \sum_{i=1}^n Y_i^2 - 2\bar{Y} \sum_{i=1}^n Y_i + \sum_{i=1}^n \bar{Y}^2 && [\text{S3, S2 } (\bar{Y} \text{ não depende de } i)] \\ &= \sum_{i=1}^n Y_i^2 - 2\bar{Y} \cdot n\bar{Y} + n\bar{Y}^2 && [\text{S4, S1}] \\ &= \sum_{i=1}^n Y_i^2 - n\bar{Y}^2. \end{aligned}$$

Passo 0b – $\mathbb{E}(SQ)$

Precisamos de $\mathbb{E}(Y_i^2)$ e $\mathbb{E}(\bar{Y}^2)$, e ambos saem de P4:

$$\begin{aligned} \mathbb{E}(Y_i^2) &= \text{Var}(Y_i) + [\mathbb{E}(Y_i)]^2 = \sigma^2 + \mu^2, && [\text{P4, P8}] \\ \mathbb{E}(\bar{Y}^2) &= \text{Var}(\bar{Y}) + [\mathbb{E}(\bar{Y})]^2 = \frac{\sigma^2}{n} + \mu^2. && [\text{P4, Exercício 2}] \end{aligned}$$

Então

$$\begin{aligned} \mathbb{E}(SQ) &= \sum_{i=1}^n \mathbb{E}(Y_i^2) - n\mathbb{E}(\bar{Y}^2) && [\text{P1}] \\ &= n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) && [\text{S1}] \\ &= n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2 \\ &= (n-1)\sigma^2. \end{aligned}$$

Passo 0c – Var(SQ) pela qui-quadrado

Pelo Teorema de Fisher (válido sob normalidade),

$$W = \frac{SQ}{\sigma^2} \sim \chi_{n-1}^2, \quad \text{com} \quad \mathbb{E}(W) = n - 1, \quad \text{Var}(W) = 2(n - 1).$$

(A esperança confere com o Passo 0b, já que $\mathbb{E}(SQ) = \sigma^2 \mathbb{E}(W) = (n - 1)\sigma^2$.) Como $SQ = \sigma^2 W$:

$$\begin{aligned} \text{Var}(SQ) &= \text{Var}(\sigma^2 W) = (\sigma^2)^2 \text{Var}(W) \\ &= 2(n - 1)\sigma^4. \end{aligned} \quad [\text{P2}]$$

(a) Viés

Para $\hat{\sigma}_1^2$:

$$\mathbb{E}(\hat{\sigma}_1^2) = \mathbb{E}\left(\frac{SQ}{n}\right) = \frac{1}{n} \mathbb{E}(SQ) \quad [\text{P1}]$$

$$= \frac{(n - 1)\sigma^2}{n}, \quad [\text{Passo 0b}]$$

$$\text{B}(\hat{\sigma}_1^2) = \frac{(n - 1)\sigma^2}{n} - \sigma^2 = \frac{(n - 1)\sigma^2 - n\sigma^2}{n} = -\frac{\sigma^2}{n}. \quad [\text{denominador comum}]$$

Para $\hat{\sigma}_2^2$:

$$\mathbb{E}(\hat{\sigma}_2^2) = \frac{1}{n - 1} \mathbb{E}(SQ) = \frac{(n - 1)\sigma^2}{n - 1} = \sigma^2, \quad [\text{P1, Passo 0b}]$$

$$\text{B}(\hat{\sigma}_2^2) = \sigma^2 - \sigma^2 = 0.$$

Resposta

$\hat{\sigma}_1^2$ é **viciado**, com $\text{B}(\hat{\sigma}_1^2) = -\sigma^2/n$: em média subestima σ^2 . Ele é, porém, assintoticamente não-viciado, pois $-\sigma^2/n \rightarrow 0$.

$\hat{\sigma}_2^2$ é **não-viciado** para σ^2 .

(b) Variâncias

$$\text{Var}(\hat{\sigma}_1^2) = \text{Var}\left(\frac{SQ}{n}\right) = \frac{1}{n^2} \text{Var}(SQ) \quad [\text{P2}]$$

$$= \frac{2(n - 1)\sigma^4}{n^2}, \quad [\text{Passo 0c}]$$

$$\text{Var}(\hat{\sigma}_2^2) = \frac{1}{(n - 1)^2} \text{Var}(SQ) \quad [\text{P2}]$$

$$= \frac{2(n - 1)\sigma^4}{(n - 1)^2} = \frac{2\sigma^4}{n - 1}. \quad [\text{cancela um } (n - 1)]$$

Resposta

$$\text{Var}(\hat{\sigma}_1^2) = \frac{2(n - 1)\sigma^4}{n^2} \quad \text{e} \quad \text{Var}(\hat{\sigma}_2^2) = \frac{2\sigma^4}{n - 1}.$$

(c) EQM

$$\begin{aligned}\text{EQM}(\hat{\sigma}_1^2) &= \text{Var}(\hat{\sigma}_1^2) + [\text{B}(\hat{\sigma}_1^2)]^2 && [\text{Decomp}] \\ &= \frac{2(n-1)\sigma^4}{n^2} + \left(-\frac{\sigma^2}{n}\right)^2 \\ &= \frac{2(n-1)\sigma^4}{n^2} + \frac{\sigma^4}{n^2} \\ &= \frac{(2n-2+1)\sigma^4}{n^2} = \frac{(2n-1)\sigma^4}{n^2}, \\ \text{EQM}(\hat{\sigma}_2^2) &= \text{Var}(\hat{\sigma}_2^2) + 0^2 = \frac{2\sigma^4}{n-1}. && [\text{Decomp}]\end{aligned}$$

Resposta

$$\text{EQM}(\hat{\sigma}_1^2) = \frac{(2n-1)\sigma^4}{n^2} \quad \text{e} \quad \text{EQM}(\hat{\sigma}_2^2) = \frac{2\sigma^4}{n-1}.$$

(d) Consistência em média quadrática

Para $\hat{\sigma}_1^2$, dividimos numerador e denominador por n^2 para enxergar o limite:

$$\frac{(2n-1)\sigma^4}{n^2} = \sigma^4 \left(\frac{2n}{n^2} - \frac{1}{n^2} \right) = \sigma^4 \left(\frac{2}{n} - \frac{1}{n^2} \right) \xrightarrow{n \rightarrow \infty} \sigma^4(0-0) = 0. \quad [\text{Li1}]$$

Para $\hat{\sigma}_2^2$, como $n-1 \rightarrow \infty$:

$$\frac{2\sigma^4}{n-1} \xrightarrow{n \rightarrow \infty} 0. \quad [\text{Li1}]$$

Resposta

Ambos os EQM vão a zero para todo $\sigma^2 > 0$: $\hat{\sigma}_1^2$ e $\hat{\sigma}_2^2$ são médio quadrático consistentes.

(e) Consistência em probabilidade

Para $k = 1, 2$ e qualquer $\varepsilon > 0$:

$$0 \leq \mathbb{P}(|\hat{\sigma}_k^2 - \sigma^2| \geq \varepsilon) \leq \frac{\text{EQM}(\hat{\sigma}_k^2)}{\varepsilon^2}. \quad [\text{Cheb}]$$

Pelo item (d), o lado direito vai a zero; pelo confronto (Li2), o do meio também.

Resposta

$\hat{\sigma}_1^2 \xrightarrow{\mathbb{P}} \sigma^2$ e $\hat{\sigma}_2^2 \xrightarrow{\mathbb{P}} \sigma^2$: ambos são consistentes em probabilidade.

(f) Comparação

Vamos comparar os EQM fazendo a diferença:

$$\begin{aligned}\text{EQM}(\hat{\sigma}_2^2) - \text{EQM}(\hat{\sigma}_1^2) &= \sigma^4 \left[\frac{2}{n-1} - \frac{2n-1}{n^2} \right] \\ &= \sigma^4 \frac{2n^2 - (2n-1)(n-1)}{n^2(n-1)} && \text{[denominador comum]} \\ &= \sigma^4 \frac{2n^2 - (2n^2 - 3n + 1)}{n^2(n-1)} && \text{[distributiva]} \\ &= \frac{(3n-1)\sigma^4}{n^2(n-1)}.\end{aligned}$$

Para $n \geq 2$: $3n-1 > 0$, $n^2 > 0$, $n-1 > 0$ e $\sigma^4 > 0$. Logo a diferença é **estritamente positiva**, para todo σ^2 e todo $n \geq 2$.

Conferência numérica com $n = 5$ e $\sigma^2 = 1$: $\text{EQM}(\hat{\sigma}_1^2) = \frac{9}{25} = 0,36$ e $\text{EQM}(\hat{\sigma}_2^2) = \frac{2}{4} = 0,50$. A diferença é 0,14, e a fórmula dá $\frac{14}{25 \cdot 4} = 0,14$. Confere.

Resposta

- **Viés:** $\hat{\sigma}_2^2$ é não-viciado; $\hat{\sigma}_1^2$ é viciado (subestima), mas assintoticamente não-viciado.
- **EQM:** $\text{EQM}(\hat{\sigma}_1^2) < \text{EQM}(\hat{\sigma}_2^2)$ para todo $\sigma^2 > 0$ e todo $n \geq 2$. Pelo critério do EQM, $\hat{\sigma}_1^2$ é *uniformemente melhor*: o pequeno viés é mais que compensado pela variância menor.
- **Consistência:** ambos são consistentes, e a diferença entre eles some para n grande, pois $\frac{n}{n-1} \rightarrow 1$.
- **Conclusão:** não-vício não é sinônimo de “melhor”. Se o critério é não-vício, escolhe-se $\hat{\sigma}_2^2$ (o S^2 usual); se o critério é EQM, escolhe-se $\hat{\sigma}_1^2$, que também é o estimador de momentos e o EMV de σ^2 .

4 Exercício 4 – Média das duas primeiras observações

Enunciado. $Y_1, \dots, Y_n$ i.i.d. com $\mathbb{E}(Y) = \mu$ e $\text{Var}(Y) = \sigma^2$, com $0 < \sigma^2 < \infty$. Seja $T = \frac{Y_1 + Y_2}{2}$. Mostrar que T é não-viciado para μ , mas não é consistente.

Não-vício

$$\begin{aligned}\mathbb{E}(T) &= \frac{1}{2} [\mathbb{E}(Y_1) + \mathbb{E}(Y_2)] && \text{[P1]} \\ &= \frac{1}{2} (\mu + \mu) = \mu. && \text{[P8]}\end{aligned}$$

Logo $\text{B}(T) = 0$ para todo μ .

Variância e EQM

$$\begin{aligned}\text{Var}(T) &= \frac{1}{4} [\text{Var}(Y_1) + \text{Var}(Y_2)] && \text{[P2, P3]} \\ &= \frac{1}{4} \cdot 2\sigma^2 = \frac{\sigma^2}{2}, \\ \text{EQM}(T) &= \frac{\sigma^2}{2} + 0^2 = \frac{\sigma^2}{2}. && \text{[Decomp]}\end{aligned}$$

O EQM **não depende de n** , logo $\lim_n \text{EQM}(T) = \sigma^2/2 \neq 0$: T não é consistente em MQ.

Atenção: isso ainda *não* prova a não-consistência em probabilidade, porque a recíproca “probabilidade $\Rightarrow$ MQ” é falsa. Precisamos mostrar diretamente que existe $\varepsilon > 0$ com $\mathbb{P}(|T - \mu| \geq \varepsilon) \not\rightarrow 0$.

Não-consistência em probabilidade

Passo 1: a probabilidade não depende de n . T é função apenas de Y_1 e Y_2 , cuja distribuição conjunta é a mesma para qualquer tamanho de amostra $n \geq 2$. Logo, para cada $\varepsilon > 0$, o número

$$q(\varepsilon) = \mathbb{P}(|T - \mu| \geq \varepsilon)$$

é o mesmo para todo n , e portanto $\lim_{n \rightarrow \infty} \mathbb{P}(|T - \mu| \geq \varepsilon) = q(\varepsilon)$.

Passo 2: existe ε com $q(\varepsilon) > 0$. Suponha, por absurdo, que $q(\varepsilon) = 0$ para *todo* $\varepsilon > 0$. O evento $\{T \neq \mu\}$ pode ser escrito como a união $\bigcup_{k=1}^{\infty} \{|T - \mu| \geq 1/k\}$, então

$$\mathbb{P}(T \neq \mu) \leq \sum_{k=1}^{\infty} \mathbb{P}(|T - \mu| \geq 1/k) = \sum_{k=1}^{\infty} 0 = 0.$$

Ou seja, $T = \mu$ com probabilidade 1, o que daria $\text{Var}(T) = 0$ (P5). Isso contradiz $\text{Var}(T) = \sigma^2/2 > 0$. Logo existe $\varepsilon_0 > 0$ com $q(\varepsilon_0) > 0$, e

$$\lim_{n \rightarrow \infty} \mathbb{P}(|T - \mu| \geq \varepsilon_0) = q(\varepsilon_0) \neq 0.$$

Ilustração numérica (se $Y \sim N(\mu, \sigma^2)$). Nesse caso $T \sim N(\mu, \sigma^2/2)$. Com $\varepsilon = \sigma$:

$$\mathbb{P}(|T - \mu| \geq \sigma) = \mathbb{P}\left(|Z| \geq \frac{\sigma}{\sigma/\sqrt{2}}\right) = \mathbb{P}(|Z| \geq \sqrt{2}) = 2[1 - \Phi(1,414)] \approx 2(1 - 0,9214) \approx 0,157,$$

qualquer que seja n .

Resposta

$T = \frac{Y_1 + Y_2}{2}$ é não-viciado ($\mathbb{E}(T) = \mu$), mas **não é consistente**. Ele usa sempre a mesma quantidade de informação (duas observações), então sua distribuição não se concentra em μ quando n cresce. Não-vício não implica consistência.

5 Exercício 5 – Condição para combinação linear não-viciada

Enunciado. Determinar a condição sobre $a_1, \dots, a_n$ para que $T = \sum_{i=1}^n a_i Y_i$ seja não-viciado para $\mu = \mathbb{E}(Y)$.

Cálculo da esperança

$$\begin{aligned} \mathbb{E}(T) &= \mathbb{E}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n a_i \mathbb{E}(Y_i) & [\text{P1}] \\ &= \sum_{i=1}^n a_i \mu = \mu \sum_{i=1}^n a_i. & [\text{P8}, \text{S2}] \end{aligned}$$

Impondo o não-vício

Queremos $\mathbb{E}(T) = \mu$ para todo μ :

$$\mu \sum_{i=1}^n a_i = \mu \quad \text{para todo } \mu.$$

Tomando qualquer $\mu \neq 0$ e dividindo os dois lados por μ , obtemos $\sum_i a_i = 1$. Reciprocamente, se $\sum_i a_i = 1$, então $\mathbb{E}(T) = \mu \cdot 1 = \mu$ para todo μ .

Resposta

$T = \sum_{i=1}^n a_i Y_i$ é não-viciado para $\mathbb{E}(Y)$ se, e somente se, $\sum_{i=1}^n a_i = 1$.

Exemplos: $a_i = \frac{1}{n}$ para todo i dá $\bar{Y}$; $a_1 = a_2 = \frac{1}{2}$ e os demais zero dá o estimador do Exercício 4.

Complemento: qual combinação tem menor variância?

Por P2 e P3, $\text{Var}(T) = \sigma^2 \sum_i a_i^2$. Pela desigualdade de Cauchy-Schwarz,

$$\left(\sum_i a_i \cdot 1 \right)^2 \leq \left(\sum_i a_i^2 \right) \left(\sum_i 1^2 \right),$$

isto é,

$$1 = \left(\sum_{i=1}^n a_i \right)^2 \leq n \sum_{i=1}^n a_i^2 \implies \sum_{i=1}^n a_i^2 \geq \frac{1}{n},$$

com igualdade se, e somente se, todos os a_i são iguais, ou seja, $a_i = 1/n$. Logo, entre todas as combinações lineares não-viciadas, $\bar{Y}$ é a de **menor variância** (σ^2/n). No Exercício 4, por exemplo, $\sum a_i^2 = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$, que dá variância $\sigma^2/2$.

6 Exercício 6 – Binomial: $T_1 = Y/n$ contra $T_2 = (Y + 1)/(n + 2)$

Enunciado. $Y \sim \text{Bin}(n, p)$, com $\mathbb{E}(Y) = np$ e $\text{Var}(Y) = np(1 - p)$. (Isso sai do Exercício 1, pois Y é a soma de n Bernoullis independentes.)

EQM de $T_1 = Y/n$

$$\mathbb{E}(T_1) = \frac{\mathbb{E}(Y)}{n} = \frac{np}{n} = p \implies \text{B}(T_1) = 0, \quad [\text{P1}]$$

$$\text{Var}(T_1) = \frac{\text{Var}(Y)}{n^2} = \frac{np(1 - p)}{n^2} = \frac{p(1 - p)}{n}, \quad [\text{P2}]$$

$$\text{EQM}(T_1) = \frac{p(1 - p)}{n}. \quad [\text{Decomp}]$$

EQM de $T_2 = (Y + 1)/(n + 2)$

Viés.

$$\mathbb{E}(T_2) = \frac{\mathbb{E}(Y) + 1}{n + 2} = \frac{np + 1}{n + 2}, \quad [\text{P1}]$$

$$\begin{aligned} \text{B}(T_2) &= \frac{np + 1}{n + 2} - p = \frac{np + 1 - p(n + 2)}{n + 2} \\ &= \frac{np + 1 - np - 2p}{n + 2} = \frac{1 - 2p}{n + 2}. \end{aligned} \quad [\text{denominador comum}]$$

Variância. A constante +1 não altera a variância:

$$\text{Var}(T_2) = \frac{1}{(n+2)^2} \text{Var}(Y+1) = \frac{\text{Var}(Y)}{(n+2)^2} = \frac{np(1-p)}{(n+2)^2}. \quad [\text{P2 duas vezes}]$$

EQM.

$$\text{EQM}(T_2) = \frac{np(1-p)}{(n+2)^2} + \frac{(1-2p)^2}{(n+2)^2} = \frac{np(1-p) + (1-2p)^2}{(n+2)^2}. \quad [\text{Decomp}]$$

Resposta

$$\text{EQM}(T_1) = \frac{p(1-p)}{n} \quad \text{e} \quad \text{EQM}(T_2) = \frac{np(1-p) + (1-2p)^2}{(n+2)^2}.$$

Comparação

Simplificação útil. Seja $q = p(1-p)$. Como $(1-2p)^2 = 1 - 4p + 4p^2 = 1 - 4(p - p^2) = 1 - 4q$:

$$\text{EQM}(T_2) = \frac{nq + 1 - 4q}{(n+2)^2} = \frac{(n-4)q + 1}{(n+2)^2}.$$

Quando T_2 é melhor? Os denominadores são positivos, então podemos multiplicar cruzado sem mudar o sentido (Li3):

$$\begin{aligned} \text{EQM}(T_2) < \text{EQM}(T_1) &\iff \frac{(n-4)q + 1}{(n+2)^2} < \frac{q}{n} \\ &\iff n[(n-4)q + 1] < q(n+2)^2 & [\text{Li3: multiplica por } n(n+2)^2 > 0] \\ &\iff n^2q - 4nq + n < q(n^2 + 4n + 4) \\ &\iff n < q(n^2 + 4n + 4 - n^2 + 4n) & [\text{passa os termos com } q \text{ para a direita}] \\ &\iff n < q(8n + 4) \\ &\iff q > \frac{n}{8n + 4}. & [\text{Li3: divide por } 8n + 4 > 0] \end{aligned}$$

Em termos de p . A condição $p(1-p) > c$, com $c = \frac{n}{8n+4}$, equivale a $p^2 - p + c < 0$, cujas raízes são $p = \frac{1 \pm \sqrt{1-4c}}{2}$. Calculando o discriminante:

$$1 - 4c = 1 - \frac{4n}{8n+4} = \frac{8n+4-4n}{8n+4} = \frac{4n+4}{8n+4} = \frac{n+1}{2n+1}.$$

Como a parábola tem concavidade para cima, ela é negativa entre as raízes:

$$\text{EQM}(T_2) < \text{EQM}(T_1) \iff \left| p - \frac{1}{2} \right| < \frac{1}{2} \sqrt{\frac{n+1}{2n+1}}.$$

Conferência nos extremos.

- Em $p = 0$: $\text{EQM}(T_1) = 0$ e $\text{EQM}(T_2) = \frac{1}{(n+2)^2} > 0$, então T_1 vence (de fato, se $p = 0$ então $Y = 0$ e $T_1 = 0$ acerta sempre).
- Em $p = \frac{1}{2}$: $q = \frac{1}{4}$, $\text{EQM}(T_1) = \frac{1}{4n}$ e $\text{EQM}(T_2) = \frac{n/4}{(n+2)^2} = \frac{n}{4(n+2)^2}$. Como $n^2 < (n+2)^2$, temos $\frac{n}{4(n+2)^2} < \frac{1}{4n}$, e T_2 vence.

Numérico com $n = 10$. $c = \frac{10}{84} \approx 0,119$ e $\frac{1}{2}\sqrt{\frac{11}{21}} \approx \frac{1}{2}(0,7237) \approx 0,362$. Logo T_2 é melhor para $p \in (0,138; 0,862)$ e T_1 é melhor fora desse intervalo.

Resposta

Nenhum estimador é uniformemente melhor: as curvas de EQM se cruzam.

- T_2 tem EQM menor quando p está perto de $\frac{1}{2}$, precisamente quando $|p - \frac{1}{2}| < \frac{1}{2} \sqrt{\frac{n+1}{2n+1}}$. Ele “puxa” a estimativa para $\frac{1}{2}$, o que ajuda se p está no centro.
- T_1 tem EQM menor quando p está perto de 0 ou 1, e é não-viciado.
- Ambos são consistentes: $B(T_2) = \frac{1-2p}{n+2} \rightarrow 0$ e $\text{Var}(T_2) \rightarrow 0$.
- Quando $n \rightarrow \infty$, a região onde T_2 vence tende a $|p - \frac{1}{2}| < \frac{1}{2\sqrt{2}} \approx 0,354$, ou seja, $p \in (0,146; 0,854)$.

A escolha depende de conhecimento prévio sobre p . T_2 é o estimador de “Laplace”, que também aparece como estimador bayesiano com priori uniforme.

7 Exercício 7 – Momentos para $f(y; \theta) = \theta^2 y e^{-\theta y}$

Enunciado. $f(y; \theta) = \theta^2 y e^{-\theta y}$, $y > 0$, com um parâmetro ($p = 1$).

Reconheça o formato: $\theta^2 y^{2-1} e^{-\theta y} = \frac{\theta^2}{\Gamma(2)} y^{2-1} e^{-\theta y}$, porque $\Gamma(2) = 1$. Isso é uma Gama(2, θ) (taxa θ). Mesmo assim, vamos calcular pela integral.

Conferência: é densidade?

$$\int_0^\infty \theta^2 y e^{-\theta y} dy = \theta^2 \cdot \frac{\Gamma(2)}{\theta^2} = 1. \quad [\text{I3, I1 com } \alpha = 2; \text{ I2}]$$

Passo 1 – primeiro momento populacional

$$\begin{aligned} \mathbb{E}(Y) &= \int_0^\infty y \cdot \theta^2 y e^{-\theta y} dy & [\text{P7}] \\ &= \theta^2 \int_0^\infty y^{3-1} e^{-\theta y} dy & [\text{I3; } y \cdot y = y^2 = y^{3-1}] \\ &= \theta^2 \cdot \frac{\Gamma(3)}{\theta^3} & [\text{I1 com } \alpha = 3, \text{ taxa } \theta] \\ &= \theta^2 \cdot \frac{2}{\theta^3} = \frac{2}{\theta}. & [\text{I2: } \Gamma(3) = 2! = 2] \end{aligned}$$

Passo 2 – igualar ao momento amostral e resolver

$$\begin{aligned} \frac{2}{\bar{\theta}} &= \bar{Y} \\ 2 &= \tilde{\theta} \bar{Y} & [\text{multiplica por } \tilde{\theta}] \\ \tilde{\theta} &= \frac{2}{\bar{Y}}. & [\text{divide por } \bar{Y} > 0] \end{aligned}$$

Resposta

$$\tilde{\theta} = \frac{2}{\bar{Y}} = \frac{2n}{\sum_{i=1}^n Y_i}.$$

Complementos (não pedidos, mas úteis)

Consistência. $\bar{Y} \xrightarrow{\mathbb{P}} 2/\theta$ (LGN) e $g(x) = 2/x$ é contínua em $2/\theta > 0$. Pela aplicação contínua (Cont), $\tilde{\theta} \xrightarrow{\mathbb{P}} \frac{2}{2/\theta} = \theta$.

Viés. A soma de n variáveis Gama($2, \theta$) independentes é $S \sim \text{Gama}(2n, \theta)$ (pelo produto das FGMs). Repetindo o cálculo do Exemplo 4 do guia, agora com $2n$ no lugar de n :

$$\mathbb{E}\left(\frac{1}{S}\right) = \frac{\theta^{2n}}{\Gamma(2n)} \cdot \frac{\Gamma(2n-1)}{\theta^{2n-1}} = \frac{\theta}{2n-1} \implies \mathbb{E}(\tilde{\theta}) = 2n \cdot \frac{\theta}{2n-1} = \frac{2n}{2n-1}\theta.$$

Logo $\tilde{\theta}$ é viciado, com $B = \frac{\theta}{2n-1} \rightarrow 0$ (assintoticamente não-viciado).

EMV. Com $\ell(\theta) = 2n \log \theta + \sum_i \log y_i - \theta \sum_i y_i$, o escore é $U(\theta) = \frac{2n}{\theta} - \sum_i y_i$. Igualando a zero, $\hat{\theta} = \frac{2n}{\sum_i y_i} = \frac{2}{\bar{y}}$, que coincide com o de momentos. A informação observada é $I_o(\theta) = \frac{2n}{\theta^2} > 0$, o que confirma o máximo.

8 Exercício 8 – Uniforme $U(0, \theta)$

Dados do modelo. $f(y; \theta) = \frac{1}{\theta}$ para $0 < y < \theta$, e zero fora. A f.d.a. é

$$F(y) = \int_0^y \frac{1}{\theta} dt = \frac{y}{\theta}, \quad 0 \leq y \leq \theta,$$

com $F(y) = 0$ para $y < 0$ e $F(y) = 1$ para $y > \theta$.

(a) Consistência de $\hat{\theta} = Y_{(n)}$

Passo 1 – f.d.a. do máximo. Para $0 \leq y \leq \theta$:

$$\begin{aligned} F_{Y_{(n)}}(y) &= \mathbb{P}(Y_{(n)} \leq y) = \mathbb{P}(Y_1 \leq y, \dots, Y_n \leq y) && [\text{Pr5}] \\ &= \prod_{i=1}^n \mathbb{P}(Y_i \leq y) && [\text{P6}] \\ &= \left(\frac{y}{\theta}\right)^n. && [\text{P8, S5}] \end{aligned}$$

Passo 2 – simplificar o valor absoluto. Toda observação é menor que θ , logo $Y_{(n)} < \theta$ e $|Y_{(n)} - \theta| = \theta - Y_{(n)}$. Então

$$|Y_{(n)} - \theta| \geq \varepsilon \iff \theta - Y_{(n)} \geq \varepsilon \iff Y_{(n)} \leq \theta - \varepsilon.$$

Passo 3 – calcular a probabilidade. Separamos em dois casos.

Caso $\varepsilon \geq \theta$: então $\theta - \varepsilon \leq 0$ e, como $Y_{(n)} > 0$, a probabilidade é 0.

Caso $0 < \varepsilon < \theta$:

$$\begin{aligned} \mathbb{P}(|Y_{(n)} - \theta| \geq \varepsilon) &= \mathbb{P}(Y_{(n)} \leq \theta - \varepsilon) = F_{Y_{(n)}}(\theta - \varepsilon) && [\text{Passo 2}] \\ &= \left(\frac{\theta - \varepsilon}{\theta}\right)^n. && [\text{Passo 1}] \end{aligned}$$

Como $0 < \frac{\theta - \varepsilon}{\theta} < 1$, temos $r^n \rightarrow 0$ para $0 \leq r < 1$, e a probabilidade vai a zero.

Caminho alternativo (via EQM). A densidade do máximo é a derivada da f.d.a.: $f_{Y_{(n)}}(y) = \frac{ny^{n-1}}{\theta^n}$, $0 < y < \theta$.

$$\mathbb{E}(Y_{(n)}) = \int_0^\theta y \cdot \frac{ny^{n-1}}{\theta^n} dy = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n\theta}{n+1}, \quad [\text{P7, I3, I4}]$$

$$\mathbb{E}(Y_{(n)}^2) = \frac{n}{\theta^n} \int_0^\theta y^{n+1} dy = \frac{n}{\theta^n} \cdot \frac{\theta^{n+2}}{n+2} = \frac{n\theta^2}{n+2}, \quad [\text{P7, I3, I4}]$$

$$\text{Var}(Y_{(n)}) = \frac{n\theta^2}{n+2} - \frac{n^2\theta^2}{(n+1)^2} = n\theta^2 \frac{(n+1)^2 - n(n+2)}{(n+1)^2(n+2)} = \frac{n\theta^2}{(n+1)^2(n+2)}, \quad [\text{P4}]$$

$$\text{B}(Y_{(n)}) = \frac{n\theta}{n+1} - \theta = -\frac{\theta}{n+1}.$$

Na variância, o numerador é $(n+1)^2 - n(n+2) = n^2 + 2n + 1 - n^2 - 2n = 1$. Então

$$\begin{aligned} \text{EQM}(Y_{(n)}) &= \frac{n\theta^2}{(n+1)^2(n+2)} + \frac{\theta^2}{(n+1)^2} & [\text{Decomp}] \\ &= \frac{\theta^2 [n + (n+2)]}{(n+1)^2(n+2)} & [\text{denominador comum}] \\ &= \frac{2\theta^2(n+1)}{(n+1)^2(n+2)} = \frac{2\theta^2}{(n+1)(n+2)} \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

Resposta

$\hat{\theta} = Y_{(n)}$ é consistente: $\mathbb{P}(|Y_{(n)} - \theta| \geq \varepsilon) = \left(\frac{\theta-\varepsilon}{\theta}\right)^n \rightarrow 0$ para $0 < \varepsilon < \theta$ (e vale 0 para $\varepsilon \geq \theta$). Também é consistente em MQ, com $\text{EQM} = \frac{2\theta^2}{(n+1)(n+2)}$. É viciado (subestima, pois $Y_{(n)} < \theta$), com $\text{B} = -\frac{\theta}{n+1} \rightarrow 0$.

(b) Estimador de momentos

$$\mathbb{E}(Y) = \int_0^\theta y \cdot \frac{1}{\theta} dy = \frac{1}{\theta} \cdot \frac{\theta^2}{2} = \frac{\theta}{2}. \quad [\text{P7, I3, I4}]$$

Igualando ao momento amostral:

$$\frac{\tilde{\theta}}{2} = \bar{Y} \implies \tilde{\theta} = 2\bar{Y}.$$

Propriedades. Com $\text{Var}(Y) = \frac{(\theta-0)^2}{12} = \frac{\theta^2}{12}$:

$$\mathbb{E}(\tilde{\theta}) = 2\mathbb{E}(\bar{Y}) = 2 \cdot \frac{\theta}{2} = \theta, \quad [\text{P1}]$$

$$\text{Var}(\tilde{\theta}) = 4 \text{Var}(\bar{Y}) = 4 \cdot \frac{\theta^2/12}{n} = \frac{\theta^2}{3n}, \quad [\text{P2}]$$

$$\text{EQM}(\tilde{\theta}) = \frac{\theta^2}{3n} \rightarrow 0. \quad [\text{Decomp, Li1}]$$

Resposta

$\tilde{\theta} = 2\bar{Y}$: não-viciado, com $\text{EQM} = \frac{\theta^2}{3n}$, e consistente.

(c) Comparação

Quando $Y_{(n)}$ tem EQM menor?

$$\begin{aligned}\frac{2\theta^2}{(n+1)(n+2)} < \frac{\theta^2}{3n} &\iff 6n < (n+1)(n+2) && [\text{Li3: multiplica por } \frac{3n(n+1)(n+2)}{\theta^2} > 0] \\ &\iff 0 < n^2 + 3n + 2 - 6n = n^2 - 3n + 2 \\ &\iff (n-1)(n-2) > 0 \\ &\iff n \geq 3 \quad (n \text{ inteiro positivo}).\end{aligned}$$

Para $n = 1$ e $n = 2$ os EQM são iguais (confira: com $n = 1$ ambos valem $\frac{\theta^2}{3}$; com $n = 2$ ambos valem $\frac{\theta^2}{6}$).

Ordem de convergência. $\text{EQM}(Y_{(n)}) \approx \frac{2\theta^2}{n^2}$ vai a zero como $1/n^2$, enquanto $\text{EQM}(2\bar{Y}) = \frac{\theta^2}{3n}$ vai como $1/n$. A eficiência relativa é

$$\text{ef}(Y_{(n)}, 2\bar{Y}) = \frac{\theta^2/(3n)}{2\theta^2/[(n+1)(n+2)]} = \frac{(n+1)(n+2)}{6n} \xrightarrow{n \rightarrow \infty} \infty.$$

Por exemplo, com $n = 20$ ela vale $\frac{21 \cdot 22}{120} = 3,85$.

Compatibilidade com os dados. Como $\theta \geq Y_{(n)}$ sempre, uma estimativa razoável deve satisfazer $\tilde{\theta} \geq y_{(n)}$. Mas $2\bar{y}$ pode ser menor que o máximo observado. Com a amostra $(1, 2, 9)$: $\bar{y} = 4$ e $2\bar{y} = 8 < 9 = y_{(n)}$. O modelo ajustado diria que observar 9 era impossível.

Resposta

- **Viés:** $2\bar{Y}$ é não-viciado; $Y_{(n)}$ é viciado (subestima), mas assintoticamente não-viciado.
- **EQM:** para todo $n \geq 3$ e todo θ , $\text{EQM}(Y_{(n)}) < \text{EQM}(2\bar{Y})$; para $n = 1, 2$ eles empatam. Logo $Y_{(n)}$ é melhor pelo critério do EQM, e a vantagem cresce com n (ordem $1/n^2$ contra $1/n$).
- **Consistência:** ambos são consistentes.
- **Coerência:** $Y_{(n)}$ nunca contradiz os dados; $2\bar{Y}$ pode dar estimativa menor que o máximo observado.
- **Observação:** o limite de Cramér–Rao não se aplica aqui, porque o suporte depende de θ . Por isso é possível ter EQM de ordem $1/n^2$. A versão corrigida $\frac{n+1}{n}Y_{(n)}$ é não-viciada, com variância $\frac{\theta^2}{n(n+2)}$, também menor que $\frac{\theta^2}{3n}$ para $n \geq 2$.

9 Exercício 9 – Uniforme $U(-\theta, \theta)$

Dados do modelo. $f(y; \theta) = \frac{1}{\theta - (-\theta)} = \frac{1}{2\theta}$ para $-\theta < y < \theta$, com $\theta > 0$.

Passo 1 – o primeiro momento não serve

$$\mathbb{E}(Y) = \int_{-\theta}^{\theta} y \cdot \frac{1}{2\theta} dy = \frac{1}{2\theta} \cdot \frac{\theta^2 - (-\theta)^2}{2} = \frac{1}{2\theta} \cdot 0 = 0. \quad [\text{P7, I3, I4}]$$

$\mathbb{E}(Y) = 0$ **não depende de θ** : igualar a $\bar{Y}$ dá a equação $0 = \bar{Y}$, que não envolve θ . Por isso passamos ao segundo momento, como manda o roteiro do método.

Passo 2 – segundo momento

$$\begin{aligned}\mathbb{E}(Y^2) &= \int_{-\theta}^{\theta} y^2 \cdot \frac{1}{2\theta} dy && [\text{P7}] \\ &= \frac{1}{2\theta} \cdot \frac{\theta^3 - (-\theta)^3}{3} && [\text{I3, I4}] \\ &= \frac{1}{2\theta} \cdot \frac{2\theta^3}{3} = \frac{\theta^2}{3}. && [(-\theta)^3 = -\theta^3]\end{aligned}$$

(Confere com a tabela: $\text{Var}(Y) = \frac{(2\theta)^2}{12} = \frac{\theta^2}{3}$ e $\mathbb{E}(Y^2) = \text{Var}(Y) + 0^2$.)

Passo 3 – igualar e resolver

$$\begin{aligned}\frac{\tilde{\theta}^2}{3} &= M_2 = \frac{1}{n} \sum_{i=1}^n Y_i^2 \\ \tilde{\theta}^2 &= \frac{3}{n} \sum_{i=1}^n Y_i^2 && [\text{multiplica por 3}] \\ \tilde{\theta} &= \sqrt{\frac{3}{n} \sum_{i=1}^n Y_i^2}. && [\text{raiz positiva, pois } \theta > 0]\end{aligned}$$

Resposta

$$\tilde{\theta} = \sqrt{3M_2} = \sqrt{\frac{3}{n} \sum_{i=1}^n Y_i^2}.$$

Comentários

Consistência. $M_2 \xrightarrow{\mathbb{P}} \mathbb{E}(Y^2) = \theta^2/3$ (LGN aplicada a Y_i^2), e $g(x) = \sqrt{3x}$ é contínua em $x = \theta^2/3 > 0$. Logo $\tilde{\theta} \xrightarrow{\mathbb{P}} \sqrt{3 \cdot \theta^2/3} = \theta$ (Cont).

Não-unicidade. Outra opção seria usar $\mathbb{E}|Y|$:

$$\mathbb{E}|Y| = \int_{-\theta}^{\theta} |y| \frac{1}{2\theta} dy = 2 \int_0^{\theta} \frac{y}{2\theta} dy = \frac{\theta}{2},$$

o que levaria a $\tilde{\theta}' = \frac{2}{n} \sum_i |Y_i|$. Ilustra que “o” estimador de momentos depende de quais momentos se escolhe; o padrão do curso é usar os momentos $\mathbb{E}(Y^k)$ em ordem crescente, o que dá $\sqrt{3M_2}$.

Compatibilidade. Os dados exigem $\theta > \max_i |y_i|$, e $\tilde{\theta}$ pode violar isso, como no Exercício 8. O estimador natural baseado nos extremos é $\max_i |Y_i|$.