

CE309 – Inferência Estatística

Lista 7 – Estimadores de Máxima Verossimilhança
Resumo teórico e resolução comentada passo a passo

Sumário

Parte I – Resumo teórico	2
1 Definições e roteiro	2
2 Propriedades do EMV	2
3 Métodos numéricos	4
 Parte II – Resolução da lista	 4
1 Exercício 1 – Poisson	4
2 Exercício 2 – Bernoulli	6
3 Exercício 3 – Exponencial	7
4 Exercício 4 – Gama(α, β)	8
5 Exercício 5 – Binomial negativa (μ, ϕ), ϕ conhecido	9
6 Exercício 6 – Log-normal (μ, σ^2)	11
7 Exercício 7 – $f(y; \theta) = \theta e^{-\theta y}$	12
8 Exercício 8 – $f(y; \theta) = 2\theta y e^{-\theta y^2}$ (Rayleigh)	13
9 Exercício 9 – Weibull: $f(y) = \theta k y^{k-1} e^{-\theta y^k}$	13
10 Exercício 10 – Implementação computacional	15

Parte I – Resumo teórico

1 Definições e roteiro

Definição 1.1 (Verossimilhança e EMV). Dada a amostra observada $y_1, \dots, y_n$ de uma a.a. com densidade $f(y; \theta)$, a *função de verossimilhança* é a densidade conjunta vista como função de θ (com os dados fixos):

$$L(\theta) = \prod_{i=1}^n f(y_i; \theta), \quad \theta \in \Theta.$$

O *estimador de máxima verossimilhança* (EMV) $\hat{\theta}$ é o valor de $\theta \in \Theta$ que maximiza $L(\theta)$. Intuição: é o valor do parâmetro que torna os dados observados “mais prováveis”.

Como log é estritamente crescente, maximizar L é o mesmo que maximizar

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(y_i; \theta),$$

o que transforma produtos em somas e facilita derivar.

Definição 1.2 (Score e informações). Para θ escalar:

$$U(\theta) = \frac{d\ell(\theta)}{d\theta} \quad (\text{score}), \quad I_o(\theta) = -\frac{d^2\ell(\theta)}{d\theta^2} \quad (\text{informação observada}),$$

$$I_e(\theta) = \mathbb{E}_\theta[I_o(\theta)] = \mathbb{E}_\theta[U(\theta)^2] \quad (\text{informação esperada de Fisher}).$$

Para $\theta = (\theta_1, \dots, \theta_p)$, U é o vetor gradiente e I_o , I_e são matrizes $p \times p$ com entradas $-\partial^2\ell/\partial\theta_j\partial\theta_k$.

Roteiro de prova para o EMV (caso regular)

1. Escrever $L(\theta) = \prod_i f(y_i; \theta)$ e simplificar o produto (S5, L3).
2. Tomar o log: $\ell(\theta)$, separando os termos que dependem de θ dos que não dependem.
3. Derivar: $U(\theta)$.
4. Resolver a *equação de verossimilhança* $U(\hat{\theta}) = 0$.
5. Verificar que é máximo: $\frac{d^2\ell}{d\theta^2} < 0$ no ponto, isto é, $I_o(\hat{\theta}) > 0$. Se $\ell'' < 0$ para todo θ , a função é côncava e o máximo é global e único.
6. Calcular $I_e(\theta)$ e estudar as propriedades.

Atenção: se o suporte de f depende de θ (uniformes!), o passo 3 não vale. Escreva L com funções indicadoras e maximize “olhando” a função (Exercício 10).

2 Propriedades do EMV

Teorema 2.1 (Invariância). Se $\hat{\theta}$ é o EMV de θ , então para qualquer função g , o EMV de $g(\theta)$ é $g(\hat{\theta})$.

Teorema 2.2 (Função de estatística suficiente). Se T é suficiente para θ e o EMV é único, então $\hat{\theta}$ é função de T .

Teorema 2.3 (Critério da fatoração de Neyman). $T = T(Y_1, \dots, Y_n)$ é suficiente para θ se, e somente se, existem funções $g \geq 0$ e $h \geq 0$ tais que

$$\prod_{i=1}^n f(y_i; \theta) = g(T(y); \theta) \cdot h(y),$$

em que h não depende de θ e g depende dos dados apenas através de T .

Teorema 2.4 (Propriedades assintóticas – sob regularidade). Sob condições de regularidade (suporte não depende de θ , θ interior a Θ , derivadas até 3ª ordem bem-comportadas):

(i) **Consistência:** $\hat{\theta} \xrightarrow{\mathbb{P}} \theta$.

(ii) **Normalidade assintótica:** $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{\mathcal{D}} N(0, i_1(\theta)^{-1})$, em que $i_1(\theta) = I_e(\theta)/n$ é a informação de uma observação. Na prática:

$$\hat{\theta} \sim N\left(\theta, \frac{1}{I_e(\theta)}\right), \quad \text{com erro-padrão estimado } \frac{1}{\sqrt{I_e(\hat{\theta})}} \quad \text{ou} \quad \frac{1}{\sqrt{I_o(\hat{\theta})}}.$$

(iii) **Eficiência assintótica:** a variância assintótica $1/I_e(\theta)$ é o limite de Cramér–Rao.

O que o EMV não garante: não-vício em amostras finitas (ver Exercícios 3, 4 e 7), nem existência em forma fechada (Exercícios 4 e 9), nem unicidade (Exercício 10c).

Teorema 2.5 (Limite de Cramér–Rao e eficiência). Sob regularidade, se T é não-viciado para $\tau(\theta)$, então $\text{Var}(T) \geq [\tau'(\theta)]^2 / I_e(\theta)$. Se a igualdade vale, T é eficiente. Isso ocorre se, e somente se, o escore pode ser escrito como $U(\theta) = a(\theta) [T - \tau(\theta)]$.

Uma ferramenta muito usada nesta lista vem da família exponencial com estatística $S = \sum_i Y_i$. Se $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Gama}(\alpha, \beta)$ (taxa β), então $S \sim \text{Gama}(n\alpha, \beta)$, e para $m = n\alpha$:

$$\begin{aligned} \mathbb{E}\left(\frac{1}{S}\right) &= \int_0^\infty \frac{1}{s} \frac{\beta^m}{\Gamma(m)} s^{m-1} e^{-\beta s} ds = \frac{\beta^m}{\Gamma(m)} \cdot \frac{\Gamma(m-1)}{\beta^{m-1}} = \frac{\beta}{m-1} \quad (m > 1), \\ \mathbb{E}\left(\frac{1}{S^2}\right) &= \frac{\beta^m}{\Gamma(m)} \cdot \frac{\Gamma(m-2)}{\beta^{m-2}} = \frac{\beta^2}{(m-1)(m-2)} \quad (m > 2), \end{aligned}$$

usando a integral gama e $\Gamma(m) = (m-1)(m-2)\Gamma(m-2)$.

3 Métodos numéricos

Quando $U(\theta) = 0$ não tem solução explícita, usa-se um método iterativo a partir de um chute inicial $\theta^{(0)}$ (por exemplo, o estimador de momentos).

Definição 3.1 (Newton–Raphson). Expandindo U em Taylor ao redor de $\theta^{(m)}$, $0 = U(\hat{\theta}) \approx U(\theta^{(m)}) + U'(\theta^{(m)})(\hat{\theta} - \theta^{(m)})$. Isolando:

$$\theta^{(m+1)} = \theta^{(m)} - \frac{U(\theta^{(m)})}{U'(\theta^{(m)})} = \theta^{(m)} + \frac{U(\theta^{(m)})}{I_o(\theta^{(m)})}.$$

Itera-se até $|\theta^{(m+1)} - \theta^{(m)}| < \text{tolerância}$.

Escore de Fisher: troca I_o por I_e , ou seja, $\theta^{(m+1)} = \theta^{(m)} + U(\theta^{(m)})/I_e(\theta^{(m)})$. **Bisseccção:** se U é contínua e muda de sinal em $[a, b]$, divide-se o intervalo ao meio repetidamente. É mais lenta, mas sempre converge.

Verossimilhança perfilada: com dois parâmetros (θ, k) , se para k fixo existe $\hat{\theta}(k)$ explícito, substitui-se em ℓ e maximiza-se $\ell_p(k) = \ell(\hat{\theta}(k), k)$, um problema de uma variável só (Exercício 9).

Funções especiais: $\psi(\alpha) = \frac{d}{d\alpha} \log \Gamma(\alpha)$ (digama) e $\psi'(\alpha)$ (trigama). Valem

$$\psi'(\alpha) = \sum_{j=0}^{\infty} \frac{1}{(\alpha + j)^2} > 0,$$

$\psi(\alpha) \rightarrow -\infty$ quando $\alpha \rightarrow 0^+$ e $\psi(\alpha) \rightarrow +\infty$ quando $\alpha \rightarrow \infty$.

Etiquetas usadas nas passagens

As mesmas dos materiais anteriores: **P1** linearidade da esperança; **P2** $\text{Var}(aX + b) = a^2 \text{Var}(X)$; **P3** variância de soma de independentes; **P4** $\text{Var} = \mathbb{E}(X^2) - [\mathbb{E}X]^2$; **P6** independência; **P7** LOTUS; **P8** identicamente distribuídas; **S1–S5** somatórios/produtórios ($\prod c = c^n$, $\prod a_i b_i = \prod a_i \prod b_i$); **L1** $\log \prod = \sum \log$; **L2** $\log a^b = b \log a$; **L3** $\log e^x = x$, $\prod e^{a_i} = e^{\sum a_i}$; **D1** derivada de constante e de cx ; **D2** $(\log x)' = 1/x$, $(x^k)' = kx^{k-1}$; **Decomp** $\text{EQM} = \text{Var} + B^2$; **LGN**, **Cont**.

Parte II – Resolução da lista

1 Exercício 1 – Poisson

$Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Poi}(\lambda)$, $f(y; \lambda) = \frac{e^{-\lambda} \lambda^y}{y!}$, $y = 0, 1, 2, \dots$, $\lambda > 0$.

Verossimilhança

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!} = \frac{\prod_i e^{-\lambda} \cdot \prod_i \lambda^{y_i}}{\prod_i y_i!} & [\text{S5}] \\ &= \frac{e^{-n\lambda} \lambda^{\sum_i y_i}}{\prod_i y_i!}. & [\text{S5, L3; } \prod \lambda^{y_i} = \lambda^{\sum y_i}] \end{aligned}$$

Log-verossimilhança

$$\ell(\lambda) = \log e^{-n\lambda} + \log \lambda^{\sum_i y_i} - \log \prod_i y_i! \quad [\text{L1}]$$

$$= -n\lambda + \left(\sum_{i=1}^n y_i \right) \log \lambda - \sum_{i=1}^n \log(y_i!). \quad [\text{L3, L2, L1}]$$

Escore e equação de verossimilhança

$$U(\lambda) = -n + \frac{\sum_i y_i}{\lambda} + 0 \quad [\text{D1, D2}]$$

$$U(\hat{\lambda}) = 0 \iff \frac{\sum_i y_i}{\hat{\lambda}} = n \iff \hat{\lambda} = \frac{\sum_i y_i}{n} = \bar{y}.$$

Verificação do máximo

$$\frac{d^2 \ell}{d\lambda^2} = -\frac{\sum_i y_i}{\lambda^2} \implies I_o(\lambda) = \frac{\sum_i y_i}{\lambda^2} \geq 0. \quad [\text{D2}]$$

Se $\sum_i y_i > 0$, temos $\ell'' < 0$ para todo λ : ℓ é estritamente côncava e $\hat{\lambda} = \bar{y}$ é o máximo global. (Se todos os $y_i = 0$, $\ell(\lambda) = -n\lambda$ é decrescente e o supremo fica na fronteira $\lambda \rightarrow 0$; nesse caso o EMV não existe em $(0, \infty)$, embora $\bar{y} = 0$ seja a estimativa natural.)

Informação esperada

$$I_e(\lambda) = \mathbb{E}\left[\frac{\sum_i Y_i}{\lambda^2}\right] = \frac{n\lambda}{\lambda^2} = \frac{n}{\lambda}. \quad [\text{P1, P8}]$$

Propriedades

$$\mathbb{E}(\hat{\lambda}) = \frac{1}{n} \sum_i \mathbb{E}(Y_i) = \lambda, \quad [\text{P1, P8}]$$

$$\text{Var}(\hat{\lambda}) = \frac{1}{n^2} \sum_i \text{Var}(Y_i) = \frac{\lambda}{n} = \frac{1}{I_e(\lambda)}. \quad [\text{P2, P3}]$$

Resposta

$\hat{\lambda} = \bar{Y}$. Propriedades:

- **não-viciado**, com $\text{Var}(\hat{\lambda}) = \text{EQM} = \lambda/n$;
- **eficiente**: atinge o limite de Cramér-Rao $1/I_e = \lambda/n$, como confirma o escore na forma $U(\lambda) = \frac{n}{\lambda}(\bar{Y} - \lambda)$;
- **consistente** (em MQ e em probabilidade, pois $\text{EQM} \rightarrow 0$);
- função da estatística suficiente $\sum_i Y_i$;
- assintoticamente $\hat{\lambda} \sim N(\lambda, \lambda/n)$ (TCL);
- por invariância, o EMV de $\mathbb{P}(Y = 0) = e^{-\lambda}$ é $e^{-\bar{Y}}$.

2 Exercício 2 – Bernoulli

$Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Ber}(p)$, $f(y; p) = p^y(1-p)^{1-y}$, $y \in \{0, 1\}$, $0 < p < 1$. Notação: $s = \sum_i y_i$ (número de sucessos).

Verossimilhança e log-verossimilhança

$$L(p) = \prod_{i=1}^n p^{y_i} (1-p)^{1-y_i} = p^{\sum_i y_i} (1-p)^{\sum_i (1-y_i)} = p^s (1-p)^{n-s}, \quad [\text{S5}; \sum (1-y_i) = n-s]$$

$$\ell(p) = s \log p + (n-s) \log(1-p). \quad [\text{L1}, \text{L2}]$$

Escore

Pela regra da cadeia, $\frac{d}{dp} \log(1-p) = \frac{-1}{1-p}$:

$$U(p) = \frac{s}{p} - \frac{n-s}{1-p}. \quad [\text{D2}]$$

$$\begin{aligned} U(\hat{p}) = 0 &\iff \frac{s}{\hat{p}} = \frac{n-s}{1-\hat{p}} \\ &\iff s(1-\hat{p}) = (n-s)\hat{p} \\ &\iff s - s\hat{p} = n\hat{p} - s\hat{p} \\ &\iff \hat{p} = \frac{s}{n} = \bar{y}. \end{aligned} \quad [\text{multiplica cruzado}]$$

Verificação e informação

$$\begin{aligned} \frac{d^2 \ell}{dp^2} &= -\frac{s}{p^2} - \frac{n-s}{(1-p)^2} < 0 \quad (\text{se } 0 < s < n), \\ I_o(p) &= \frac{s}{p^2} + \frac{n-s}{(1-p)^2}, \\ I_e(p) &= \frac{np}{p^2} + \frac{n-np}{(1-p)^2} = \frac{n}{p} + \frac{n}{1-p} \\ &= \frac{n(1-p) + np}{p(1-p)} = \frac{n}{p(1-p)}. \end{aligned} \quad [\text{P1: } \mathbb{E}(S) = np]$$

Resposta

$\hat{p} = \bar{Y}$ (proporção amostral de sucessos). Propriedades:

- **não-viciado**, com $\text{Var}(\hat{p}) = \frac{p(1-p)}{n} = \frac{1}{I_e(\hat{p})}$, ou seja, **eficiente**;
- **consistente** (Lista 6, Exercício 1);
- função da suficiente $\sum_i Y_i$;
- $\hat{p} \sim N(p, p(1-p)/n)$;
- por invariância, o EMV da chance $p/(1-p)$ é $\hat{p}/(1-\hat{p})$.

Se $s = 0$ ou $s = n$, o máximo ocorre na fronteira ($\hat{p} = 0$ ou 1), fora do espaço aberto $(0, 1)$.

3 Exercício 3 – Exponencial

Parametrização pela taxa: $f(y; \lambda) = \lambda e^{-\lambda y}$, $y > 0$, $\lambda > 0$, com $\mathbb{E}(Y) = 1/\lambda$ e $\text{Var}(Y) = 1/\lambda^2$.
Notação: $s = \sum_i y_i$.

Verossimilhança, log-verossimilhança e escore

$$L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda y_i} = \lambda^n e^{-\lambda \sum_i y_i} = \lambda^n e^{-\lambda s}, \quad [\text{S5, L3}]$$

$$\ell(\lambda) = n \log \lambda - \lambda s, \quad [\text{L1, L2, L3}]$$

$$U(\lambda) = \frac{n}{\lambda} - s. \quad [\text{D1, D2}]$$

$$U(\hat{\lambda}) = 0 \iff \frac{n}{\hat{\lambda}} = s \iff \hat{\lambda} = \frac{n}{s} = \frac{1}{\bar{y}}.$$

Verificação e informação

$$\frac{d^2 \ell}{d\lambda^2} = -\frac{n}{\lambda^2} < 0 \quad \forall \lambda \implies I_o(\lambda) = I_e(\lambda) = \frac{n}{\lambda^2}.$$

ℓ é estritamente côncava, então o máximo é global e único. Aqui I_o não depende dos dados, por isso coincide com I_e .

Distribuição de $S = \sum_i Y_i$

A FGM de Y é $M_Y(t) = \int_0^\infty e^{ty} \lambda e^{-\lambda y} dy = \frac{\lambda}{\lambda - t}$ para $t < \lambda$. Por independência,

$$M_S(t) = \prod_i M_{Y_i}(t) = \left(\frac{\lambda}{\lambda - t} \right)^n,$$

que é a FGM de uma Gama(n, λ). Logo $S \sim \text{Gama}(n, \lambda)$, e pelas fórmulas da Parte I com $m = n$, $\beta = \lambda$:

$$\mathbb{E}\left(\frac{1}{S}\right) = \frac{\lambda}{n-1}, \quad \mathbb{E}\left(\frac{1}{S^2}\right) = \frac{\lambda^2}{(n-1)(n-2)}.$$

Viés, variância e EQM

$$\mathbb{E}(\hat{\lambda}) = n \mathbb{E}\left(\frac{1}{S}\right) = \frac{n\lambda}{n-1}, \quad [\text{P1}]$$

$$\text{B}(\hat{\lambda}) = \frac{n\lambda}{n-1} - \lambda = \frac{\lambda}{n-1}, \quad [\text{denominador comum}]$$

$$\mathbb{E}(\hat{\lambda}^2) = n^2 \mathbb{E}\left(\frac{1}{S^2}\right) = \frac{n^2 \lambda^2}{(n-1)(n-2)}, \quad [\text{P1}]$$

$$\text{Var}(\hat{\lambda}) = \frac{n^2 \lambda^2}{(n-1)(n-2)} - \frac{n^2 \lambda^2}{(n-1)^2} \quad [\text{P4}]$$

$$= n^2 \lambda^2 \frac{(n-1) - (n-2)}{(n-1)^2(n-2)} = \frac{n^2 \lambda^2}{(n-1)^2(n-2)},$$

$$\text{EQM}(\hat{\lambda}) = \frac{n^2 \lambda^2}{(n-1)^2(n-2)} + \frac{\lambda^2}{(n-1)^2} \quad [\text{Decomp}]$$

$$= \frac{\lambda^2 [n^2 + (n-2)]}{(n-1)^2(n-2)} = \frac{\lambda^2 (n+2)(n-1)}{(n-1)^2(n-2)} = \frac{(n+2)\lambda^2}{(n-1)(n-2)},$$

usando a fatoração $n^2 + n - 2 = (n+2)(n-1)$.

Resposta

$\hat{\lambda} = 1/\bar{Y}$. Propriedades:

- **viciado**: $\mathbb{E}(\hat{\lambda}) = \frac{n}{n-1}\lambda$ (superestima), mas assintoticamente não-viciado ($B = \frac{\lambda}{n-1} \rightarrow 0$);
- $\text{EQM} = \frac{(n+2)\lambda^2}{(n-1)(n-2)} \rightarrow 0$, logo **consistente** (também por LGN + Cont);
- a versão corrigida $\tilde{\lambda} = \frac{n-1}{n}\hat{\lambda} = \frac{n-1}{S}$ é não-viciada, com $\text{Var} = \frac{\lambda^2}{n-2}$. Isso é maior que o limite de Cramér–Rao $\frac{\lambda^2}{n}$: nem ela é eficiente, mas a razão vai a 1;
- **assintoticamente eficiente**: $\hat{\lambda} \sim N(\lambda, \lambda^2/n)$;
- função da suficiente $\sum_i Y_i$;
- por invariância, o EMV da média $1/\lambda$ é $\bar{Y}$, que é não-viciado e eficiente ($\text{Var} = \frac{1}{n\lambda^2}$).

4 Exercício 4 – Gama(α, β)

Parametrização pela taxa: $f(y; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$, $y > 0$. Temos $\mathbb{E}(Y) = \alpha/\beta$ e $\text{Var}(Y) = \alpha/\beta^2$.

Log-verossimilhança comum aos dois casos

$$L(\alpha, \beta) = \prod_{i=1}^n \frac{\beta^\alpha}{\Gamma(\alpha)} y_i^{\alpha-1} e^{-\beta y_i} = \frac{\beta^{n\alpha}}{[\Gamma(\alpha)]^n} \left(\prod_i y_i \right)^{\alpha-1} e^{-\beta \sum_i y_i}, \quad [\text{S5}, \text{L3}]$$

$$\ell(\alpha, \beta) = n\alpha \log \beta - n \log \Gamma(\alpha) + (\alpha - 1) \sum_{i=1}^n \log y_i - \beta \sum_{i=1}^n y_i. \quad [\text{L1}, \text{L2}]$$

(i) EMV de α com β conhecido

Score. Usando $\frac{d}{d\alpha} \log \Gamma(\alpha) = \psi(\alpha)$:

$$U(\alpha) = n \log \beta - n\psi(\alpha) + \sum_{i=1}^n \log y_i.$$

Equação de verossimilhança.

$$U(\hat{\alpha}) = 0 \iff \psi(\hat{\alpha}) = \log \beta + \frac{1}{n} \sum_{i=1}^n \log y_i.$$

Existência e unicidade. ψ é contínua e estritamente crescente ($\psi' > 0$), com $\psi(0^+) = -\infty$ e $\psi(\infty) = +\infty$. Logo, para qualquer valor do lado direito, existe exatamente uma solução $\hat{\alpha} > 0$. Além disso,

$$\frac{d^2 \ell}{d\alpha^2} = -n\psi'(\alpha) < 0 \implies I_o(\alpha) = I_e(\alpha) = n\psi'(\alpha),$$

então ℓ é côncava em α e a raiz é o máximo global. **Não há forma fechada**: resolve-se numericamente, por exemplo com Newton–Raphson:

$$\alpha^{(m+1)} = \alpha^{(m)} - \frac{\psi(\alpha^{(m)}) - c}{\psi'(\alpha^{(m)})}, \quad c = \log \beta + \frac{1}{n} \sum_i \log y_i,$$

partindo do estimador de momentos com β conhecido, $\alpha^{(0)} = \beta \bar{y}$ (pois $\mathbb{E}Y = \alpha/\beta$).

Resposta

$\hat{\alpha}$ é a única solução de $\psi(\hat{\alpha}) = \log \beta + \frac{1}{n} \sum_i \log Y_i$ (sem forma fechada). Propriedades:

- é função da estatística suficiente $\sum_i \log Y_i$. Pela fatoração, com β conhecido:

$$L = \left[\beta^{n\alpha} \Gamma(\alpha)^{-n} e^{(\alpha-1) \sum \log y_i} \right] \cdot e^{-\beta \sum y_i};$$

- viés e variância exatos não têm expressão simples;
- pelas propriedades gerais (modelo regular): **consistente**, **assintoticamente normal** e **assintoticamente eficiente**, com $\hat{\alpha} \sim N\left(\alpha, \frac{1}{n\psi'(\alpha)}\right)$.

(ii) EMV de β com α conhecido

$$U(\beta) = \frac{n\alpha}{\beta} - \sum_i y_i, \quad [\text{D1}, \text{D2}]$$

$$U(\hat{\beta}) = 0 \iff \hat{\beta} = \frac{n\alpha}{\sum_i y_i} = \frac{\alpha}{\bar{y}},$$

$$\frac{d^2 \ell}{d\beta^2} = -\frac{n\alpha}{\beta^2} < 0 \implies I_o(\beta) = I_e(\beta) = \frac{n\alpha}{\beta^2}.$$

Propriedades exatas. $S = \sum_i Y_i \sim \text{Gama}(n\alpha, \beta)$ (produto das FGMs). Com $m = n\alpha$:

$$\mathbb{E}(\hat{\beta}) = n\alpha \mathbb{E}\left(\frac{1}{S}\right) = \frac{n\alpha\beta}{n\alpha-1}, \quad \text{B}(\hat{\beta}) = \frac{\beta}{n\alpha-1}, \quad [\text{P1}]$$

$$\text{Var}(\hat{\beta}) = (n\alpha)^2 \left[\frac{\beta^2}{(n\alpha-1)(n\alpha-2)} - \frac{\beta^2}{(n\alpha-1)^2} \right] = \frac{(n\alpha)^2 \beta^2}{(n\alpha-1)^2(n\alpha-2)}. \quad [\text{P4}]$$

(A conta é idêntica à do Exercício 3, trocando n por $n\alpha$; com $\alpha = 1$ recupera-se o Exercício 3.)

Resposta

$\hat{\beta} = \alpha/\bar{Y}$. Propriedades:

- **viciado**, com $\text{B} = \frac{\beta}{n\alpha-1} \rightarrow 0$; versão não-viciada: $\frac{n\alpha-1}{S}$;
- **consistente**: $\text{Var} \rightarrow 0$ e $\text{B} \rightarrow 0$;
- **assintoticamente eficiente**: $\hat{\beta} \sim N\left(\beta, \frac{\beta^2}{n\alpha}\right)$;
- função da suficiente $\sum_i Y_i$;
- por invariância, o EMV da média α/β é $\bar{Y}$ (não-viciado).

5 Exercício 5 – Binomial negativa (μ, ϕ) , ϕ conhecido

Parametrização média–dispersão:

$$f(y; \mu, \phi) = \frac{\Gamma(y+\phi)}{\Gamma(\phi) y!} \left(\frac{\phi}{\mu+\phi} \right)^\phi \left(\frac{\mu}{\mu+\phi} \right)^y, \quad y = 0, 1, 2, \dots,$$

com $\mathbb{E}(Y) = \mu$ e $\text{Var}(Y) = \mu + \mu^2/\phi$. Notação: $s = \sum_i y_i$.

Log-verossimilhança

Tomando o log de cada fator (L1, L2) e somando em i :

$$\begin{aligned}\ell(\mu) &= \underbrace{\sum_{i=1}^n \log \frac{\Gamma(y_i + \phi)}{\Gamma(\phi) y_i!}}_{\text{não depende de } \mu} + n\phi \log \phi - n\phi \log(\mu + \phi) + s \log \mu - s \log(\mu + \phi) \\ &= C + s \log \mu - (n\phi + s) \log(\mu + \phi).\end{aligned}$$

Os termos com $\log(\mu + \phi)$ vêm de $\phi \log \frac{\phi}{\mu + \phi}$ (somado n vezes) e de $y_i \log \frac{\mu}{\mu + \phi}$ (somado em i).

Escore e equação

$$\begin{aligned}U(\mu) &= \frac{s}{\mu} - \frac{n\phi + s}{\mu + \phi}, & [\text{D2}] \\ U(\hat{\mu}) = 0 &\iff s(\hat{\mu} + \phi) = \hat{\mu}(n\phi + s) & [\text{multiplica cruzado}] \\ &\iff s\hat{\mu} + s\phi = n\phi\hat{\mu} + s\hat{\mu} \\ &\iff s\phi = n\phi\hat{\mu} \iff \hat{\mu} = \frac{s}{n} = \bar{y}. & [\text{divide por } n\phi > 0]\end{aligned}$$

Verificação e informação

$$\frac{d^2\ell}{d\mu^2} = -\frac{s}{\mu^2} + \frac{n\phi + s}{(\mu + \phi)^2}. \quad [\text{D2}]$$

No ponto $\mu = \bar{y}$, com $s = n\bar{y}$:

$$\left. \frac{d^2\ell}{d\mu^2} \right|_{\hat{\mu}} = -\frac{n}{\bar{y}} + \frac{n(\phi + \bar{y})}{(\bar{y} + \phi)^2} = -\frac{n}{\bar{y}} + \frac{n}{\bar{y} + \phi} < 0 \quad (\bar{y} > 0),$$

então é um máximo. Para a informação esperada, trocamos s por S e usamos $\mathbb{E}(S) = n\mu$:

$$I_e(\mu) = \frac{n\mu}{\mu^2} - \frac{n\phi + n\mu}{(\mu + \phi)^2} = \frac{n}{\mu} - \frac{n}{\mu + \phi} = \frac{n\phi}{\mu(\mu + \phi)}. \quad [\text{P1}]$$

Propriedades

$$\begin{aligned}\mathbb{E}(\hat{\mu}) &= \mu, \\ \text{Var}(\hat{\mu}) &= \frac{\text{Var}(Y)}{n} = \frac{\mu + \mu^2/\phi}{n} = \frac{\mu(\mu + \phi)}{n\phi} = \frac{1}{I_e(\mu)}.\end{aligned} \quad [\text{P2, P3}]$$

Resposta

$\hat{\mu} = \bar{Y}$. Propriedades:

- **não-viciado** e **eficiente**: atinge o limite de Cramér–Rao $\frac{\mu(\mu + \phi)}{n\phi}$;
- **consistente**: EQM = $\frac{\mu(\mu + \phi)}{n\phi} \rightarrow 0$;
- função da suficiente $\sum_i Y_i$;
- $\hat{\mu} \sim N\left(\mu, \frac{\mu + \mu^2/\phi}{n}\right)$;

- observação: a variância é maior que a da Poisson (μ/n) por causa da sobredispersão. Quando $\phi \rightarrow \infty$ recupera-se o caso Poisson.

6 Exercício 6 – Log-normal (μ, σ^2)

$f(y; \mu, \sigma^2) = \frac{1}{y\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(\log y - \mu)^2}{2\sigma^2}\right\}$, $y > 0$. Notação: $z_i = \log y_i$ e $\bar{z} = \frac{1}{n} \sum_i z_i$. Fato-chave: $Y \sim \text{LN}(\mu, \sigma^2) \iff Z = \log Y \sim N(\mu, \sigma^2)$.

Log-verossimilhança

$$\begin{aligned}\ell(\mu, \sigma^2) &= \sum_{i=1}^n \left[-\log y_i - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log \sigma^2 - \frac{(z_i - \mu)^2}{2\sigma^2} \right] & [\text{L1, L2, L3}] \\ &= -\sum_i z_i - \frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (z_i - \mu)^2. & [\text{S1, S3}]\end{aligned}$$

Escores (derivamos em relação a μ e a $\tau = \sigma^2$)

$$\begin{aligned}\frac{\partial \ell}{\partial \mu} &= -\frac{1}{2\sigma^2} \sum_i 2(z_i - \mu)(-1) = \frac{1}{\sigma^2} \sum_{i=1}^n (z_i - \mu), & [\text{regra da cadeia}] \\ \frac{\partial \ell}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (z_i - \mu)^2. & [\text{D2: } \frac{d}{d\tau} \tau^{-1} = -\tau^{-2}]\end{aligned}$$

Sistema de equações

Da primeira: $\sum_i (z_i - \hat{\mu}) = 0 \iff \sum_i z_i - n\hat{\mu} = 0 \iff \hat{\mu} = \bar{z}$.
Substituindo na segunda e multiplicando por $2\hat{\sigma}^4 > 0$:

$$-n\hat{\sigma}^2 + \sum_i (z_i - \bar{z})^2 = 0 \iff \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (z_i - \bar{z})^2.$$

Verificação (matriz hessiana)

$$\frac{\partial^2 \ell}{\partial \mu^2} = -\frac{n}{\sigma^2}, \quad \frac{\partial^2 \ell}{\partial \mu \partial \sigma^2} = -\frac{1}{\sigma^4} \sum_i (z_i - \mu), \quad \frac{\partial^2 \ell}{\partial (\sigma^2)^2} = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_i (z_i - \mu)^2.$$

No ponto $(\bar{z}, \hat{\sigma}^2)$: o termo cruzado é zero (pois $\sum (z_i - \bar{z}) = 0$) e

$$\frac{\partial^2 \ell}{\partial (\sigma^2)^2} = \frac{n}{2\hat{\sigma}^4} - \frac{n\hat{\sigma}^2}{\hat{\sigma}^6} = -\frac{n}{2\hat{\sigma}^4}.$$

A hessiana é diagonal com entradas $-\frac{n}{\hat{\sigma}^2} < 0$ e $-\frac{n}{2\hat{\sigma}^4} < 0$, ou seja, negativa definida: é um máximo.
Matriz de informação esperada (usando $\mathbb{E}(Z_i - \mu) = 0$ e $\mathbb{E}(Z_i - \mu)^2 = \sigma^2$):

$$I_e(\mu, \sigma^2) = \begin{pmatrix} n/\sigma^2 & 0 \\ 0 & n/(2\sigma^4) \end{pmatrix}.$$

Resposta

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \log Y_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (\log Y_i - \hat{\mu})^2.$$

Como $Z_i = \log Y_i \sim N(\mu, \sigma^2)$, valem os resultados da Lista 6 (Exercícios 2 e 3):

- $\hat{\mu}$: **não-viciado**, $\text{Var} = \sigma^2/n$, que é o limite de Cramér–Rao, logo **eficiente**; consistente;
- $\hat{\sigma}^2$: **viciado**, $B = -\sigma^2/n$; $\text{Var} = \frac{2(n-1)\sigma^4}{n^2}$; $\text{EQM} = \frac{(2n-1)\sigma^4}{n^2}$; consistente e assintoticamente eficiente (limite $2\sigma^4/n$);
- $\hat{\mu}$ e $\hat{\sigma}^2$ são independentes (teorema de Fisher) e funções das suficientes $\sum \log Y_i$ e $\sum (\log Y_i)^2$;
- por invariância, o EMV da média da log-normal, $\mathbb{E}(Y) = e^{\mu+\sigma^2/2}$, é $e^{\hat{\mu}+\hat{\sigma}^2/2}$, que é viciado em amostras finitas.

7 Exercício 7 – $f(y; \theta) = \theta e^{-\theta y}$

É a exponencial do Exercício 3 com θ no lugar de λ . Escrevemos tudo explicitamente, como pede o enunciado.

Verossimilhança

$$L(\theta) = \prod_{i=1}^n \theta e^{-\theta y_i} = \theta^n \exp\left(-\theta \sum_{i=1}^n y_i\right), \quad \theta > 0. \quad [\text{S5, L3}]$$

Log-verossimilhança

$$\ell(\theta) = n \log \theta - \theta \sum_{i=1}^n y_i. \quad [\text{L1, L2, L3}]$$

EMV

$$U(\theta) = \frac{n}{\theta} - \sum_i y_i = 0 \iff \hat{\theta} = \frac{n}{\sum_i y_i} = \frac{1}{\bar{y}}, \quad \frac{d^2 \ell}{d\theta^2} = -\frac{n}{\theta^2} < 0.$$

É não-viciado?

Com $S = \sum_i Y_i \sim \text{Gama}(n, \theta)$ e $\mathbb{E}(1/S) = \frac{\theta}{n-1}$ (ver Exercício 3):

$$\mathbb{E}(\hat{\theta}) = n \mathbb{E}\left(\frac{1}{S}\right) = \frac{n}{n-1} \theta \neq \theta.$$

Resposta

$$L(\theta) = \theta^n e^{-\theta \sum y_i}, \quad \ell(\theta) = n \log \theta - \theta \sum y_i, \quad \hat{\theta} = 1/\bar{Y}.$$

Não é não-viciado: $\mathbb{E}(\hat{\theta}) = \frac{n}{n-1} \theta$, com viés $\frac{\theta}{n-1} > 0$ (superestima). É assintoticamente não-viciado, e $\frac{n-1}{\sum_i Y_i}$ é a versão não-viciada.

8 Exercício 8 – $f(y; \theta) = 2\theta y e^{-\theta y^2}$ (Rayleigh)

Suficiência de $T = \sum_i Y_i^2$ (fatoração)

$$\begin{aligned} \prod_{i=1}^n 2\theta y_i e^{-\theta y_i^2} &= 2^n \theta^n \left(\prod_i y_i \right) \exp \left(-\theta \sum_i y_i^2 \right) \\ &= \underbrace{\theta^n \exp \left(-\theta \sum_i y_i^2 \right)}_{g(T; \theta)} \cdot \underbrace{2^n \prod_i y_i}_{h(y)}. \end{aligned} \quad [\text{S5, L3}]$$

g depende dos dados só através de $T = \sum_i y_i^2$, e h não depende de θ . Pelo critério da fatoração, $T = \sum_i Y_i^2$ é suficiente para θ .

EMV

$$\ell(\theta) = n \log 2 + n \log \theta + \sum_i \log y_i - \theta \sum_i y_i^2, \quad [\text{L1, L2, L3}]$$

$$U(\theta) = \frac{n}{\theta} - \sum_i y_i^2, \quad [\text{D1, D2}]$$

$$U(\hat{\theta}) = 0 \iff \hat{\theta} = \frac{n}{\sum_i y_i^2},$$

$$\frac{d^2 \ell}{d\theta^2} = -\frac{n}{\theta^2} < 0 \implies I_o = I_e = \frac{n}{\theta^2}.$$

Note que o EMV é função de T , como garante a teoria.

Complemento. $W = Y^2$ tem distribuição exponencial de taxa θ :

$$\mathbb{P}(W > t) = \mathbb{P}(Y > \sqrt{t}) = \int_{\sqrt{t}}^{\infty} 2\theta y e^{-\theta y^2} dy = \left[-e^{-\theta y^2} \right]_{\sqrt{t}}^{\infty} = e^{-\theta t}.$$

Logo $\hat{\theta} = n / \sum W_i$ tem exatamente as propriedades do Exercício 3: viciado, com $\mathbb{E}(\hat{\theta}) = \frac{n}{n-1}\theta$, consistente e assintoticamente eficiente.

Resposta

$\sum_i Y_i^2$ é suficiente (fatoração) e $\hat{\theta} = \frac{n}{\sum_{i=1}^n Y_i^2}$.

9 Exercício 9 – Weibull: $f(y) = \theta k y^{k-1} e^{-\theta y^k}$

(a) EMV de θ com k conhecido

$$L(\theta, k) = \theta^n k^n \left(\prod_i y_i \right)^{k-1} \exp \left(-\theta \sum_i y_i^k \right), \quad [\text{S5, L3}]$$

$$\ell(\theta, k) = n \log \theta + n \log k + (k-1) \sum_i \log y_i - \theta \sum_i y_i^k, \quad [\text{L1, L2}]$$

$$\frac{\partial \ell}{\partial \theta} = \frac{n}{\theta} - \sum_i y_i^k = 0 \iff \hat{\theta} = \frac{n}{\sum_{i=1}^n y_i^k}, \quad [\text{D1, D2}]$$

$$\frac{\partial^2 \ell}{\partial \theta^2} = -\frac{n}{\theta^2} < 0.$$

Resposta

$$\hat{\theta} = \frac{n}{\sum_{i=1}^n Y_i^k}. \text{ (Com } k = 1 \text{ volta-se ao Exercício 7; com } k = 2, \text{ ao Exercício 8.)}$$

(b) Método numérico para k desconhecido

Escore em k . Usando $\frac{d}{dk} y^k = y^k \log y$:

$$\frac{\partial \ell}{\partial k} = \frac{n}{k} + \sum_i \log y_i - \theta \sum_i y_i^k \log y_i.$$

Verossimilhança perfilada. Para cada k , o melhor θ é $\hat{\theta}(k) = n / \sum_i y_i^k$. Substituindo no escore em k e dividindo por n , obtemos uma equação só em k :

$$g(k) = \frac{1}{k} + \frac{1}{n} \sum_{i=1}^n \log y_i - \frac{\sum_i y_i^k \log y_i}{\sum_i y_i^k} = 0.$$

Defina $A(k) = \sum_i y_i^k$, $B(k) = \sum_i y_i^k \log y_i$ e $C(k) = \sum_i y_i^k (\log y_i)^2$. Note que $A' = B$ e $B' = C$. Pela regra do quociente,

$$g'(k) = -\frac{1}{k^2} - \frac{C A - B^2}{A^2}.$$

Como $CA - B^2 \geq 0$ (Cauchy-Schwarz: é A^2 vezes uma variância ponderada de $\log y_i$), temos $g'(k) < 0$. Logo g é estritamente decrescente e a raiz é única.

Resposta

Método sugerido: Newton–Raphson na equação perfilada

$$k^{(m+1)} = k^{(m)} - \frac{g(k^{(m)})}{g'(k^{(m)})},$$

a partir de $k^{(0)} = 1$ (caso exponencial), até $|k^{(m+1)} - k^{(m)}| < 10^{-6}$. Depois, $\hat{\theta} = n/A(\hat{k})$. Como g é monótona, a bissecção também funciona e sempre converge. Alternativa: Newton–Raphson bidimensional em (θ, k) usando a matriz I_o .

(c) Estimativa com $y = (4,2; 0,7; 2,5; 1,9; 7,9)$, $n = 5$

Quantidade fixa: $\frac{1}{n} \sum_i \log y_i = \frac{4,703417}{5} = 0,940683$.

Iteração 0 ($k^{(0)} = 1$), calculada linha a linha:

y_i	$\log y_i$	$y_i \log y_i$	$y_i (\log y_i)^2$
4,2	1,435085	6,027355	8,649764
0,7	−0,356675	−0,249672	0,089052
2,5	0,916291	2,290727	2,098972
1,9	0,641854	1,219522	0,782755
7,9	2,066863	16,328216	33,748181
Soma	4,703417	$B = 25,616148$	$C = 45,368724$

Com $A(1) = \sum y_i = 17,2$:

$$g(1) = \frac{1}{1} + 0,940683 - \frac{25,616148}{17,2} = 1 + 0,940683 - 1,489311 = 0,451372,$$

$$g'(1) = -1 - \frac{45,368724 \cdot 17,2 - 25,616148^2}{17,2^2} = -1 - 0,419669 = -1,419669,$$

$$k^{(1)} = 1 - \frac{0,451372}{-1,419669} = 1 + 0,317942 = 1,317942.$$

Iterações seguintes (mesmo procedimento, com y_i^k no lugar de y_i):

m	$k^{(m)}$	A	B	$g(k^{(m)})$	$g'(k^{(m)})$
0	1,000000	17,2000	25,6161	0,451372	-1,419670
1	1,317942	28,1702	45,3520	0,089515	-0,916331
2	1,415630	33,0204	54,2230	0,004976	-0,817372
3	1,421718	33,3524	54,8326	0,000017	-0,811756
4	1,421739	33,3535	54,8347	0,000000	-0,811737

A convergência é quadrática: o número de casas corretas praticamente dobra a cada passo, típico do Newton–Raphson.

Estimativa de θ :

$$\hat{\theta} = \frac{n}{A(\hat{k})} = \frac{5}{33,3535} \approx 0,1499.$$

Resposta

$\hat{k} \approx 1,4217$ e $\hat{\theta} \approx 0,1499$.

Como $\hat{k} > 1$, a taxa de falha da Weibull é crescente. O valor máximo da log-verossimilhança é $\ell(\hat{\theta}, \hat{k}) \approx -10,746$.

10 Exercício 10 – Implementação computacional

(a) $f(x; \theta) = (\theta + 1)x^\theta$, $0 \leq x \leq 1$, $\theta > -1$

O suporte $[0, 1]$ não depende de θ : é um caso regular.

$$\ell(\theta) = n \log(\theta + 1) + \theta \sum_{i=1}^n \log x_i,$$

[L1, L2]

$$U(\theta) = \frac{n}{\theta + 1} + \sum_i \log x_i = 0 \iff \hat{\theta} = -\frac{n}{\sum_i \log x_i} - 1,$$

$$\frac{d^2 \ell}{d\theta^2} = -\frac{n}{(\theta + 1)^2} < 0.$$

Resposta

Há forma fechada: $\hat{\theta} = -1 - n / \sum_i \log x_i$. Não é preciso otimizar numericamente; basta calcular a expressão. Como $x_i \in (0, 1)$, temos $\sum \log x_i < 0$ e portanto $\hat{\theta} > -1$: a estimativa sempre cai no espaço paramétrico.

Cuidados de implementação:

- $x_i = 0$ gera $\log 0 = -\infty$ (evento de probabilidade zero, mas pode ocorrer por arredondamento);

- $x_i = 1$ para todo i dá divisão por zero;
- se usar um otimizador genérico, reparametrize $\eta = \log(\theta + 1)$ para eliminar a restrição $\theta > -1$.

A log-verossimilhança é côncava, então qualquer método de gradiente converge. (Bônus: $W = -\log X \sim \text{Exp}(\theta + 1)$, logo $\hat{\theta} + 1 = n / \sum W_i$ tem as propriedades do Exercício 3.)

(b) $f(x; \theta) = (2\theta)^{-1}$, $-\theta \leq x \leq \theta$, $\theta > 0$

O suporte depende de θ . Escrevemos L com indicadoras:

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n \frac{1}{2\theta} \mathbf{1}\{-\theta \leq x_i \leq \theta\} = (2\theta)^{-n} \prod_i \mathbf{1}\{|x_i| \leq \theta\} \\ &= (2\theta)^{-n} \mathbf{1}\left\{\theta \geq \max_i |x_i|\right\}. \end{aligned}$$

Para $\theta < \max_i |x_i|$, $L = 0$; para $\theta \geq \max_i |x_i|$, $L = (2\theta)^{-n}$ é *estritamente decrescente* em θ . O máximo está no menor θ permitido.

Resposta

$\hat{\theta} = \max_i |X_i|$. Derivar e igualar a zero **não funciona**: $U(\theta) = -n/\theta$ nunca se anula e L é descontínua em $\max |x_i|$. Um otimizador baseado em gradiente (Newton, BFGS) empurraria θ para baixo até “cair” em $L = 0$ ($\ell = -\infty$), falhando ou devolvendo resultado errado. A implementação correta é **analítica**: calcular $\max |x_i|$. Também falham as propriedades assintóticas usuais e o limite de Cramér–Rao, porque o suporte depende de θ .

(c) $f(x; \theta) = \frac{1}{2}$, $\theta - 1 \leq x \leq \theta + 1$

$$L(\theta) = \left(\frac{1}{2}\right)^n \prod_i \mathbf{1}\{\theta - 1 \leq x_i \leq \theta + 1\} = 2^{-n} \mathbf{1}\{x_{(n)} - 1 \leq \theta \leq x_{(1)} + 1\}.$$

A condição $\theta - 1 \leq x_i$ para todo i equivale a $\theta \leq x_{(1)} + 1$; a condição $x_i \leq \theta + 1$ para todo i equivale a $\theta \geq x_{(n)} - 1$. O intervalo é não vazio, porque $x_{(n)} - x_{(1)} \leq 2$.

Resposta

L é **constante** ($= 2^{-n}$) em todo o intervalo $[x_{(n)} - 1, x_{(1)} + 1]$, e zero fora dele. Logo **o EMV não é único**: qualquer $\hat{\theta}$ nesse intervalo é EMV.

Implementação:

- o gradiente é zero em todo o intervalo, então um otimizador devolve um ponto arbitrário (geralmente o próprio chute inicial, se ele for viável) e reporta “convergência” enganosa;
- a saída correta é reportar o intervalo $[x_{(n)} - 1, x_{(1)} + 1]$ ou adotar uma regra de escolha, como o ponto médio $\frac{x_{(1)} + x_{(n)}}{2}$;
- como no item (b), o problema é não regular e deve ser tratado analiticamente.