Exercício 1

Obs.: Com $Y_i \overset{iid}{\sim} \text{Bin}(n,p)$, $E(Y_i) = np$, logo $E(\hat{p}) = np \neq p$ (viés $B(\hat{p}) = (n-1)p$) e o item (a) seria falso. Resolvido para $Y_i \overset{iid}{\sim} \text{Bin}(m,p)$, $i = 1,\dots,n$, com $\hat{p} = \frac{1}{nm}\sum_{i=1}^n Y_i$; $m = 1$ (Bernoulli) é o $\hat{p}$ do enunciado. A letra m não veio das aulas.

(a) Viés

Em separado:

Raciocínio: *Esperança da binomial: nº de ensaios × probabilidade.*

$$E(Y_i) = mp, \quad i = 1,\dots,n$$

Raciocínio: *Constante sai; esperança da soma = soma das esperanças (lin. vale sem independência).*

Na Prova:

$$\begin{aligned} E(\hat{p}) &= E\Big(\frac{1}{nm}\sum_{i=1}^n Y_i\Big) \\ &\overset{\text{lin.}}{=} \frac{1}{nm}\sum_{i=1}^n E(Y_i) \end{aligned}$$

Raciocínio: *Mesma distribuição ⇒ mesma esperança mp; n termos iguais.*

Na Prova:

$$\begin{aligned} &\overset{\text{i.d.}}{=} \frac{1}{nm}\cdot n \cdot mp \\ &= p \end{aligned}$$

Como $E(\hat{p}) = p$, $\hat{p}$ é não viesado para p.

$\hat{p}$ é não viesado para p.

(b) Variância

Em separado:

Raciocínio: *Variância da binomial.*

$$\text{Var}(Y_i) = mp(1-p), \quad i = 1,\dots,n$$

Raciocínio: $\text{Var}(cX) = c^2\,\text{Var}(X)$.

Na Prova:

$$\begin{aligned} \text{Var}(\hat{p}) &= \text{Var}\left(\frac{1}{nm}\sum_{i=1}^n Y_i\right) \\ &\overset{\text{prop.}}{=} \frac{1}{n^2m^2}\,\text{Var}\left(\sum_{i=1}^n Y_i\right) \end{aligned}$$

Raciocínio: *Y_i independentes (a.a.): Var da soma = soma das Var; depois mesma variância.*

Na Prova:

$$\begin{aligned} &\overset{\text{ind.}}{=} \frac{1}{n^2m^2}\sum_{i=1}^n \text{Var}(Y_i) \\ &\overset{\text{i.d.}}{=} \frac{1}{n^2m^2}\cdot n \cdot mp(1-p) \\ &= \frac{p(1-p)}{nm} \end{aligned}$$

$$\boxed{\text{Var}(\hat{p}) = \frac{p(1-p)}{nm}}$$

Raciocínio: *Verificação: $m = 1$ dá $p(1-p)/n$, variância da proporção amostral.*

(c) Erro quadrático médio

Decomposição do EQM: $\text{EQM}(\hat{\theta}) = E[(\hat{\theta}-\theta)^2] = \text{Var}(\hat{\theta}) + B^2(\hat{\theta})$.

Em separado:

Raciocínio: *Viés sai do item (a).*

$$B(\hat{p}) = E(\hat{p}) - p \overset{\text{(a)}}{=} p - p = 0$$

Na Prova:

$$\begin{aligned} \text{EQM}(\hat{p}) &= \text{Var}(\hat{p}) + B^2(\hat{p}) \\ &\overset{\text{(a),(b)}}{=} \frac{p(1-p)}{nm} + 0^2 \\ &= \frac{p(1-p)}{nm} \end{aligned}$$

$$\boxed{\text{EQM}(\hat{p}) = \frac{p(1-p)}{nm}}$$

(d) Médio quadrático consistente

Definição: $\hat{\theta}$ é médio quadrático consistente para θ se $\lim_{n\to\infty}\text{EQM}(\hat{\theta}) = 0$.

Raciocínio: *$p(1-p)$ e m fixos; só o denominador cresce.*

Na Prova:

$$\begin{aligned} \lim_{n\to\infty}\text{EQM}(\hat{p}) &\overset{\text{(c)}}{=} \lim_{n\to\infty}\frac{p(1-p)}{nm} \\ &= 0 \end{aligned}$$

Como $\lim_{n\to\infty}\text{EQM}(\hat{p}) = 0$, $\hat{p}$ é médio quadrático consistente para p.

$\hat{p}$ é médio quadrático consistente para p.

(e) Consistente em probabilidade

Definição: $\hat{\theta}$ é consistente em probabilidade para θ se, $\forall\,\varepsilon > 0$, $\lim_{n\to\infty} P(|\hat{\theta}-\theta| \geq \varepsilon) = 0$.

Chebyshev: se $E(X)$ e $\text{Var}(X)$ finitas, $\forall\,\varepsilon > 0$: $P(|X - E(X)| \geq \varepsilon) \leq \text{Var}(X)/\varepsilon^2$.

Raciocínio: *Var finita (b) e $E(\hat{p}) = p$ (a): Chebyshev já fica centrado em p.*

Na Prova:

Seja $\varepsilon > 0$.

$$\begin{aligned} P(|\hat{p}-p| \geq \varepsilon) &\overset{\text{(a)}}{=} P(|\hat{p} - E(\hat{p})| \geq \varepsilon) \\ &\overset{\text{Cheb.}}{\leq} \frac{\text{Var}(\hat{p})}{\varepsilon^2} \\ &\overset{\text{(b)}}{=} \frac{p(1-p)}{nm\,\varepsilon^2} \end{aligned}$$

Raciocínio: *Probabilidade presa entre 0 e algo que vai a 0: confronto.*

Na Prova:

$$\begin{aligned} &0 \leq P(|\hat{p}-p| \geq \varepsilon) \\ &\leq \frac{p(1-p)}{nm\,\varepsilon^2} \xrightarrow{n\to\infty} 0 \\ &\Rightarrow \lim_{n\to\infty} P(|\hat{p}-p| \geq \varepsilon) = 0, \ \forall\,\varepsilon > 0 \end{aligned}$$

Como o limite é 0 para todo $\varepsilon > 0$, $\hat{p}$ é consistente em probabilidade para p.

$\hat{p}$ é consistente em probabilidade para p.

Cola

- Binomial: $E(Y) = mp$, $\text{Var}(Y) = mp(1-p)$.
- lin.: $E(\sum a_iY_i) = \sum a_iE(Y_i)$ (sempre).
- $\text{Var}(cX) = c^2\,\text{Var}(X)$.
- ind.: $\text{Var}(\sum Y_i) = \sum \text{Var}(Y_i)$ (só com independência).
- Viés: $B(\hat{\theta}) = E(\hat{\theta}) - \theta$.
- $\text{EQM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + B^2(\hat{\theta})$.
- M.q. consistente: $\lim_{n\to\infty}\text{EQM}(\hat{\theta}) = 0$.
- Cheb.: $P(|X - E(X)| \geq \varepsilon) \leq \text{Var}(X)/\varepsilon^2$.
- Consist. em prob.: $\lim P(|\hat{\theta}-\theta| \geq \varepsilon) = 0$, $\forall\,\varepsilon > 0$.

Erro comum: usar $E(Y_i) = p$ para binomial com mais de um ensaio (só vale na Bernoulli). É a armadilha do enunciado como escrito, onde $E(\hat{p}) = np$.

Exercício 2

Obs.: $Y_i \overset{iid}{\sim} N(\mu,\sigma^2)$, $i = 1,\dots,n$, $\hat{\mu} = \frac{1}{n}\sum_{i=1}^n Y_i$.

(a) Viés

Em separado:

Raciocínio: *Esperança da normal.*

$$E(Y_i) = \mu, \quad i = 1,\dots,n$$

Raciocínio: *Constante sai; lin. vale sem independência.*

Na Prova:

$$\begin{aligned} E(\hat{\mu}) &= E\Big(\frac{1}{n}\sum_{i=1}^n Y_i\Big) \\ &\overset{\text{lin.}}{=} \frac{1}{n}\sum_{i=1}^n E(Y_i) \end{aligned}$$

Raciocínio: *Todas com esperança μ; n termos iguais.*

Na Prova:

$$\begin{aligned} &\overset{\text{i.d.}}{=} \frac{1}{n}\cdot n\mu \\ &= \mu \end{aligned}$$

Como $E(\hat{\mu}) = \mu$, $\hat{\mu}$ é não viesado para μ.

$\hat{\mu}$ é não viesado para μ.

(b) Variância

Em separado:

Raciocínio: *Variância da normal.*

$$\text{Var}(Y_i) = \sigma^2, \quad i = 1,\dots,n$$

Raciocínio: $\text{Var}(cX) = c^2\,\text{Var}(X)$.

Na Prova:

$$\begin{aligned} \text{Var}(\hat{\mu}) &= \text{Var}\left(\frac{1}{n}\sum_{i=1}^n Y_i\right) \\ &\overset{\text{prop.}}{=} \frac{1}{n^2}\,\text{Var}\left(\sum_{i=1}^n Y_i\right) \end{aligned}$$

Raciocínio: *Y_i independentes (a.a.); depois mesma variância σ^2.*

Na Prova:

$$\begin{aligned} &\overset{\text{ind.}}{=} \frac{1}{n^2}\sum_{i=1}^n \text{Var}(Y_i) \\ &\overset{\text{i.d.}}{=} \frac{1}{n^2}\cdot n\sigma^2 \\ &= \frac{\sigma^2}{n} \end{aligned}$$

$$\boxed{\text{Var}(\hat{\mu}) = \frac{\sigma^2}{n}}$$

Raciocínio: *Verificação: comb. linear de normais independentes é normal, $\hat{\mu} \sim N(\mu,\sigma^2/n)$; bate com (a) e (b).*

(c) Erro quadrático médio

Decomposição do EQM: $\text{EQM}(\hat{\theta}) = E[(\hat{\theta}-\theta)^2] = \text{Var}(\hat{\theta}) + B^2(\hat{\theta})$.

Em separado:

Raciocínio: *Viés sai do item (a).*

$$B(\hat{\mu}) = E(\hat{\mu}) - \mu \overset{\text{(a)}}{=} \mu - \mu = 0$$

Na Prova:

$$\begin{aligned} \text{EQM}(\hat{\mu}) &= \text{Var}(\hat{\mu}) + B^2(\hat{\mu}) \\ &\overset{\text{(a),(b)}}{=} \frac{\sigma^2}{n} + 0^2 \\ &= \frac{\sigma^2}{n} \end{aligned}$$

$$\boxed{\text{EQM}(\hat{\mu}) = \frac{\sigma^2}{n}}$$

(d) Médio quadrático consistente

Definição: $\hat{\theta}$ é m.q. consistente para θ se $\lim_{n\to\infty}\text{EQM}(\hat{\theta}) = 0$.

Raciocínio: *σ^2 fixo e finito.*

Na Prova:

$$\begin{aligned} \lim_{n\to\infty}\text{EQM}(\hat{\mu}) &\overset{\text{(c)}}{=} \lim_{n\to\infty}\frac{\sigma^2}{n} \\ &= 0 \end{aligned}$$

Como $\lim_{n\to\infty}\text{EQM}(\hat{\mu}) = 0$, $\hat{\mu}$ é médio quadrático consistente para μ.

$\hat{\mu}$ é médio quadrático consistente para μ.

(e) Consistente em probabilidade

Definição: $\forall\,\varepsilon > 0$, $\lim_{n\to\infty} P(|\hat{\theta}-\theta| \geq \varepsilon) = 0$.

Chebyshev: se $E(X)$ e $\text{Var}(X)$ finitas, $\forall\,\varepsilon > 0$: $P(|X - E(X)| \geq \varepsilon) \leq \text{Var}(X)/\varepsilon^2$.

Raciocínio: $\text{Var}(\hat{\mu}) = \sigma^2/n$ *finita (b);* $E(\hat{\mu}) = \mu$ *(a).*

Na Prova:

Seja $\varepsilon > 0$.

$$\begin{aligned} P(|\hat{\mu}-\mu| \geq \varepsilon) &\overset{\text{(a)}}{=} P(|\hat{\mu} - E(\hat{\mu})| \geq \varepsilon) \\ &\overset{\text{Cheb.}}{\leq} \frac{\text{Var}(\hat{\mu})}{\varepsilon^2} \\ &\overset{\text{(b)}}{=} \frac{\sigma^2}{n\varepsilon^2} \end{aligned}$$

Raciocínio: *Confronto.*

Na Prova:

$$\begin{aligned} &0 \leq P(|\hat{\mu}-\mu| \geq \varepsilon) \\ &\leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n\to\infty} 0 \\ &\Rightarrow \lim_{n\to\infty} P(|\hat{\mu}-\mu| \geq \varepsilon) = 0, \ \forall\,\varepsilon > 0 \end{aligned}$$

Como o limite é 0 para todo $\varepsilon > 0$, $\hat{\mu}$ é consistente em probabilidade para μ.

$\hat{\mu}$ é consistente em probabilidade para μ.

Cola

- Normal: $E(Y) = \mu$, $\text{Var}(Y) = \sigma^2$.
- lin.: $E(\sum a_iY_i) = \sum a_iE(Y_i)$ (sempre).
- $\text{Var}(cX) = c^2\,\text{Var}(X)$.
- ind.: $\text{Var}(\sum Y_i) = \sum \text{Var}(Y_i)$ (só com independência).
- $\hat{\mu} \sim N(\mu, \sigma^2/n)$.
- $B(\hat{\theta}) = E(\hat{\theta}) - \theta$; $\text{EQM} = \text{Var} + B^2$.
- M.q. consistente: $\lim \text{EQM} = 0$.
- Cheb.: $P(|X - E(X)| \geq \varepsilon) \leq \text{Var}(X)/\varepsilon^2$.
- Consist. em prob.: $\lim P(|\hat{\theta}-\theta| \geq \varepsilon) = 0$, $\forall\,\varepsilon > 0$.

Erro comum: tirar o $\frac{1}{n}$ da variância sem elevar ao quadrado: dá $\text{Var}(\hat{\mu}) = \sigma^2$, o EQM não vai a zero e a consistência "falha".

Exercício 3

Obs.: Notação auxiliar (não veio das aulas): $Q = \sum_{i=1}^{n}(Y_i - \hat{\mu})^2$, logo $\hat{\sigma}_1^2 = \frac{Q}{n}$ e $\hat{\sigma}_2^2 = \frac{Q}{n-1} = S^2$. χ^2_k: qui-quadrado com k g.l.

(a) Viés

Raciocínio: *Os dois são múltiplos de Q: basta $E(Q)$. Expando o quadrado e uso $\sum Y_i = n\hat{\mu}$ (def. de $\hat{\mu}$).*

Na Prova:

$$\begin{aligned} Q &= \sum_{i=1}^{n}(Y_i - \hat{\mu})^2 \\ &= \sum_{i=1}^{n} Y_i^2 - 2\hat{\mu}\sum_{i=1}^{n} Y_i + n\hat{\mu}^2 \\ &\overset{\text{def.}}{=} \sum_{i=1}^{n} Y_i^2 - 2n\hat{\mu}^2 + n\hat{\mu}^2 \\ &= \sum_{i=1}^{n} Y_i^2 - n\hat{\mu}^2 \end{aligned}$$

Em separado:

Raciocínio: *$E(X^2) = \mathrm{Var}(X) + E^2(X)$ (variância finita). Para $\hat{\mu}$: Ex. 2, $E(\hat{\mu}) = \mu$, $\mathrm{Var}(\hat{\mu}) = \sigma^2/n$.*

$$\begin{aligned} E(Y_i^2) &= \mathrm{Var}(Y_i) + E^2(Y_i) \\ &= \sigma^2 + \mu^2 \\ E(\hat{\mu}^2) &= \mathrm{Var}(\hat{\mu}) + E^2(\hat{\mu}) \\ &\overset{\text{Ex. 2}}{=} \frac{\sigma^2}{n} + \mu^2 \end{aligned}$$

Raciocínio: *Volto à conta principal: lin. na soma; mesmo $E(Y_i^2)$ para todo i.*

Na Prova:

$$\begin{aligned} E(Q) &\overset{\text{lin.}}{=} \sum_{i=1}^{n} E(Y_i^2) - n\,E(\hat{\mu}^2) \\ &\overset{\text{i.d.}}{=} n(\sigma^2 + \mu^2) - n\Big(\frac{\sigma^2}{n} + \mu^2\Big) \\ &= n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2 \\ &= (n-1)\sigma^2 \end{aligned}$$

$$\begin{aligned} E(\hat{\sigma}_1^2) &= E\Big(\frac{Q}{n}\Big) \overset{\text{lin.}}{=} \frac{(n-1)\sigma^2}{n} \\ B(\hat{\sigma}_1^2) &= \frac{(n-1)\sigma^2}{n} - \sigma^2 = -\frac{\sigma^2}{n} \\ E(\hat{\sigma}_2^2) &= E\Big(\frac{Q}{n-1}\Big) \overset{\text{lin.}}{=} \frac{(n-1)\sigma^2}{n-1} = \sigma^2 \\ B(\hat{\sigma}_2^2) &= \sigma^2 - \sigma^2 = 0 \end{aligned}$$

Como $E(\hat{\sigma}_1^2) \neq \sigma^2$, $\hat{\sigma}_1^2$ é viesado para σ^2. Como $E(\hat{\sigma}_2^2) = \sigma^2$, $\hat{\sigma}_2^2$ é não viesado para σ^2.

$\hat{\sigma}_1^2$ é viesado, com $B(\hat{\sigma}_1^2) = -\sigma^2/n$; $\hat{\sigma}_2^2$ é não viesado para σ^2.

Raciocínio: *Verificação: $B(\hat{\sigma}_1^2) \to 0$, então $\hat{\sigma}_1^2$ é assintoticamente não viesado; sinal negativo: subestima σ^2 em média.*

(b) Variância

Resultado (amostra normal): se $Y_i \overset{iid}{\sim} N(\mu, \sigma^2)$, então $\frac{Q}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$. Se $X \sim \chi^2_k$: $E(X) = k$, $\mathrm{Var}(X) = 2k$.

Raciocínio: *Normalidade está no enunciado. Escrevo $Q = \sigma^2 \cdot \frac{Q}{\sigma^2}$ e tiro σ^2 ao quadrado.*

Na Prova:

$$\begin{aligned} \mathrm{Var}(Q) &= \mathrm{Var}\Big(\sigma^2 \cdot \frac{Q}{\sigma^2}\Big) \\ &\overset{\text{prop.}}{=} \sigma^4\,\mathrm{Var}\Big(\frac{Q}{\sigma^2}\Big) \\ &\overset{\chi^2_{n-1}}{=} 2(n-1)\sigma^4 \end{aligned}$$

$$\begin{aligned} \mathrm{Var}(\hat{\sigma}_1^2) &= \mathrm{Var}\Big(\frac{Q}{n}\Big) \overset{\text{prop.}}{=} \frac{1}{n^2}\mathrm{Var}(Q) \\ &= \frac{2(n-1)\sigma^4}{n^2} \end{aligned}$$

$$\begin{aligned} \mathrm{Var}(\hat{\sigma}_2^2) &= \mathrm{Var}\Big(\frac{Q}{n-1}\Big) \\ &\overset{\text{prop.}}{=} \frac{1}{(n-1)^2}\mathrm{Var}(Q) \\ &= \frac{2(n-1)\sigma^4}{(n-1)^2} \\ &= \frac{2\sigma^4}{n-1} \end{aligned}$$

$\mathrm{Var}(\hat{\sigma}_1^2) = \dfrac{2(n-1)\sigma^4}{n^2}$ e $\mathrm{Var}(\hat{\sigma}_2^2) = \dfrac{2\sigma^4}{n-1}$

Raciocínio: *Verificação: pelo resultado, $E(Q) = \sigma^2(n-1)$, bate com (a).*

(c) Erro quadrático médio

Decomposição do EQM: $\mathrm{EQM}(\hat{\theta}) = \mathrm{Var}(\hat{\theta}) + B^2(\hat{\theta})$.

Na Prova:

$$\begin{aligned} \mathrm{EQM}(\hat{\sigma}_1^2) &= \mathrm{Var}(\hat{\sigma}_1^2) + B^2(\hat{\sigma}_1^2) \\ &\overset{\text{(a),(b)}}{=} \frac{2(n-1)\sigma^4}{n^2} + \Big(-\frac{\sigma^2}{n}\Big)^2 \\ &= \frac{2(n-1)\sigma^4}{n^2} + \frac{\sigma^4}{n^2} \\ &= \frac{(2n-1)\sigma^4}{n^2} \end{aligned}$$

$$\begin{aligned} \mathrm{EQM}(\hat{\sigma}_2^2) &= \mathrm{Var}(\hat{\sigma}_2^2) + B^2(\hat{\sigma}_2^2) \\ &\overset{\text{(a),(b)}}{=} \frac{2\sigma^4}{n-1} + 0^2 \\ &= \frac{2\sigma^4}{n-1} \end{aligned}$$

$\mathrm{EQM}(\hat{\sigma}_1^2) = \dfrac{(2n-1)\sigma^4}{n^2}$ e $\mathrm{EQM}(\hat{\sigma}_2^2) = \dfrac{2\sigma^4}{n-1}$

(d) Médio quadrático consistente

Definição: $\lim_{n\to\infty} \mathrm{EQM}(\hat{\theta}) = 0$.

Raciocínio: *Divido numerador e denominador por n^2; σ^4 fixo e finito.*

Na Prova:

$$\begin{aligned} \lim_{n\to\infty} \mathrm{EQM}(\hat{\sigma}_1^2) &\overset{\text{(c)}}{=} \lim_{n\to\infty} \frac{(2n-1)\sigma^4}{n^2} \\ &= \lim_{n\to\infty} \Big(\frac{2}{n} - \frac{1}{n^2}\Big)\sigma^4 \\ &= 0 \end{aligned}$$

$$\begin{aligned} \lim_{n\to\infty} \mathrm{EQM}(\hat{\sigma}_2^2) &\overset{\text{(c)}}{=} \lim_{n\to\infty} \frac{2\sigma^4}{n-1} \\ &= 0 \end{aligned}$$

Como os dois limites são 0, $\hat{\sigma}_1^2$ e $\hat{\sigma}_2^2$ são médio quadrático consistentes para σ^2.

$\hat{\sigma}_1^2$ e $\hat{\sigma}_2^2$ são médio quadrático consistentes para σ^2.

(e) Consistente em probabilidade

Definição: $\forall\,\varepsilon > 0$, $\lim_{n\to\infty} P(|\hat{\theta} - \theta| \geq \varepsilon) = 0$.

Chebyshev (forma geral): para qualquer constante c e $\varepsilon > 0$: $P(|X - c| \geq \varepsilon) \leq E[(X-c)^2]/\varepsilon^2$.

Raciocínio: *$\hat{\sigma}_1^2$ é viesado: não dá para centrar em $E(\hat{\sigma}_1^2)$. Uso $c = \sigma^2$; o numerador vira o EQM. Vale para $j = 1, 2$.*

Na Prova:

Seja $\varepsilon > 0$ e $j = 1, 2$.

$$\begin{aligned} P(|\hat{\sigma}_j^2 - \sigma^2| \geq \varepsilon) &\overset{\text{Cheb.}}{\leq} \frac{E[(\hat{\sigma}_j^2 - \sigma^2)^2]}{\varepsilon^2} \\ &\overset{\text{def.}}{=} \frac{\mathrm{EQM}(\hat{\sigma}_j^2)}{\varepsilon^2} \end{aligned}$$

Raciocínio: *Pelo item (d), o EQM vai a 0; confronto.*

Na Prova:

$$\begin{aligned} &0 \leq P(|\hat{\sigma}_j^2 - \sigma^2| \geq \varepsilon) \\ &\leq \frac{\mathrm{EQM}(\hat{\sigma}_j^2)}{\varepsilon^2} \xrightarrow[\text{(d)}]{n\to\infty} 0 \\ &\Rightarrow \lim_{n\to\infty} P(|\hat{\sigma}_j^2 - \sigma^2| \geq \varepsilon) = 0, \\ &\quad \forall\,\varepsilon > 0,\ j = 1, 2 \end{aligned}$$

Como o limite é 0 para todo $\varepsilon > 0$, $\hat{\sigma}_1^2$ e $\hat{\sigma}_2^2$ são consistentes em probabilidade para σ^2.

$\hat{\sigma}_1^2$ e $\hat{\sigma}_2^2$ são consistentes em probabilidade para σ^2.

Raciocínio: *Observação: o argumento mostra que m.q. consistente $\Rightarrow$ consistente em probabilidade.*

(f) Comparação

Eficiência relativa: $Ef_r(\hat{\theta}_1, \hat{\theta}_2) = \mathrm{EQM}(\hat{\theta}_1)/\,\mathrm{EQM}(\hat{\theta}_2)$; se < 1, $\hat{\theta}_1$ é superior a $\hat{\theta}_2$.

Na Prova:

$$\begin{aligned} Ef_r(\hat{\sigma}_1^2, \hat{\sigma}_2^2) &\overset{\text{(c)}}{=} \frac{(2n-1)\sigma^4/n^2}{2\sigma^4/(n-1)} \\ &= \frac{(2n-1)(n-1)}{2n^2} \\ &= \frac{2n^2 - 3n + 1}{2n^2} \\ &= 1 - \frac{3n-1}{2n^2} \end{aligned}$$

Raciocínio: *Para $n \geq 2$ (para S^2 existir), $3n - 1 > 0$. Verificação $n = 2$: $\frac{3\cdot 1}{8} = \frac{3}{8} < 1$.*

Na Prova:

$$\begin{aligned} &\frac{3n-1}{2n^2} > 0,\ \forall\, n \geq 2 \\ &\Rightarrow Ef_r(\hat{\sigma}_1^2, \hat{\sigma}_2^2) < 1 \\ &\lim_{n\to\infty} Ef_r(\hat{\sigma}_1^2, \hat{\sigma}_2^2) = 1 \end{aligned}$$

Como $Ef_r(\hat{\sigma}_1^2, \hat{\sigma}_2^2) < 1$, $\hat{\sigma}_1^2$ é superior a $\hat{\sigma}_2^2$ em EQM.

$\hat{\sigma}_1^2$ é viesado, mas tem EQM menor que $\hat{\sigma}_2^2$ para todo $n \geq 2$; $\hat{\sigma}_2^2$ é não viesado, mas tem variância maior. Para n grande, são equivalentes.

Raciocínio: *Compromisso viés-variância: aceitar um viés pequeno (que some com n) reduz o erro total. "Não viesado" não significa "melhor".*

Cola

- $\sum(Y_i - \hat{\mu})^2 = \sum Y_i^2 - n\hat{\mu}^2$.
- $E(X^2) = \mathrm{Var}(X) + E^2(X)$.
- $E(\hat{\mu}) = \mu$, $\mathrm{Var}(\hat{\mu}) = \sigma^2/n$.
- $E(Q) = (n-1)\sigma^2$ (não exige normalidade).
- Normal: $Q/\sigma^2 \sim \chi^2_{n-1}$; χ^2_k: $E = k$, $\mathrm{Var} = 2k$.
- $\mathrm{Var}(cX) = c^2\,\mathrm{Var}(X)$; $\mathrm{EQM} = \mathrm{Var} + B^2$.
- Cheb. geral: $P(|X - c| \geq \varepsilon) \leq E[(X-c)^2]/\varepsilon^2$.
- M.q. consistente $\Rightarrow$ consistente em prob.
- $Ef_r = \mathrm{EQM}_1\,/\,\mathrm{EQM}_2$; se < 1, o 1 é superior.

Erro comum: concluir que S^2 é "melhor" só por ser não viesado. O critério é o EQM, e por ele $\hat{\sigma}_1^2$ ganha.

Exercício 4

Obs.: Falta no enunciado: a distribuição. Uso só $E(Y_i) = \mu$ e $\mathrm{Var}(Y_i) = \sigma^2$, com $0 < \sigma^2 < \infty$ (se $\sigma^2 = 0$ as Y_i seriam constantes e a afirmação seria falsa). Y_i i.i.d., $i = 1, \ldots, n$, $T = \frac{Y_1 + Y_2}{2}$.

Não viesado

Na Prova:

$$\begin{aligned} E(T) &= E\Big(\frac{Y_1 + Y_2}{2}\Big) \\ &\overset{\text{lin.}}{=} \frac{1}{2}[E(Y_1) + E(Y_2)] \\ &\overset{\text{i.d.}}{=} \frac{1}{2}\cdot 2\mu \\ &= \mu \end{aligned}$$

Como $E(T) = \mu$, T é não viesado para μ.

T é não viesado para μ.

Não consistente

Em separado:

Raciocínio: *Y_1, Y_2 independentes: Var da soma = soma das Var; $\frac{1}{2}$ sai ao quadrado.*

$$\begin{aligned} \mathrm{Var}(T) &\overset{\text{prop.}}{=} \frac{1}{4}\mathrm{Var}(Y_1 + Y_2) \\ &\overset{\text{ind.}}{=} \frac{1}{4}[\mathrm{Var}(Y_1) + \mathrm{Var}(Y_2)] \\ &\overset{\text{i.d.}}{=} \frac{1}{4}\cdot 2\sigma^2 \\ &= \frac{\sigma^2}{2} \end{aligned}$$

Definição: $\hat{\theta}$ é consistente em probabilidade para θ se, $\forall\,\varepsilon > 0$, $\lim_{n\to\infty} P(|\hat{\theta} - \theta| \geq \varepsilon) = 0$.

Raciocínio: *T usa só Y_1, Y_2: sua distribuição é a mesma para todo n, logo a probabilidade é constante em n.*

Na Prova:

Para $\varepsilon > 0$, seja $p_\varepsilon = P(|T - \mu| \geq \varepsilon)$. Como p_ε não depende de n:

$$\lim_{n\to\infty} P(|T - \mu| \geq \varepsilon) = p_\varepsilon$$

Raciocínio: *Basta achar ε com $p_\varepsilon > 0$. Por contradição: se todas fossem nulas, $T = \mu$ com prob. 1 e $\mathrm{Var}(T) = 0$. Subaditividade: $P(\bigcup A_k) \leq \sum P(A_k)$.*

Na Prova:

Suponha $p_\varepsilon = 0$ para todo $\varepsilon > 0$. Então:

$$\begin{aligned} P(|T - \mu| > 0) &= P\Big(\bigcup_{k=1}^{\infty}\big\{|T - \mu| \geq \tfrac{1}{k}\big\}\Big) \\ &\overset{\text{subad.}}{\leq} \sum_{k=1}^{\infty} p_{1/k} \\ &= 0 \end{aligned}$$

$$\Rightarrow P(T = \mu) = 1 \ \Rightarrow\ \mathrm{Var}(T) = 0$$

Isso contradiz $\mathrm{Var}(T) = \sigma^2/2 > 0$. Logo existe $\varepsilon_0 > 0$ com:

$$\lim_{n\to\infty} P(|T-\mu|\geq\varepsilon_0) = p_{\varepsilon_0} > 0$$

Como o limite não é 0 para todo $\varepsilon > 0$, T não é consistente em probabilidade para μ.

T é não viesado, mas não é consistente para μ.

Raciocínio: *Complemento: também não é m.q. consistente.*

Na Prova:

$$\begin{aligned}\lim_{n\to\infty}\mathrm{EQM}(T) &= \lim_{n\to\infty}[\mathrm{Var}(T)+B^2(T)]\\ &= \lim_{n\to\infty}\Big(\frac{\sigma^2}{2}+0\Big)\\ &= \frac{\sigma^2}{2}\neq 0\end{aligned}$$

Raciocínio: *Intuição: aumentar n não traz informação nova, pois T ignora $Y_3,\ldots,Y_n$.*

Cola

- lin.: $E(aY_1+bY_2)=aE(Y_1)+bE(Y_2)$.
- Var $(\frac{Y_1+Y_2}{2}) = \frac{1}{4}(\sigma^2+\sigma^2) = \frac{\sigma^2}{2}$ (ind.).
- Distribuição de T não depende de $n \Rightarrow$ o limite é a própria probabilidade.
- Com $E(T)=\mu$: $P(T=\mu)=1 \iff \mathrm{Var}(T)=0$.
- Subaditividade: $P(\bigcup A_k)\leq\sum P(A_k)$.
- Não viés e consistência são independentes: uma não implica a outra.

Erro comum: concluir não consistência porque a cota de Chebyshev $\frac{\sigma^2}{2\varepsilon^2}$ não vai a zero. Chebyshev é cota superior: serve para provar consistência, nunca para negá-la.

Exercício 5

Obs.: Hipóteses: $Y_1,\ldots,Y_n$ a.a. de Y, $E(Y)=\mu$ finita; a_i constantes conhecidas que não dependem de μ (garante que T é estatística). Independência não é necessária. $T=\sum_{i=1}^n a_iY_i$.

Raciocínio: *Constantes saem por lin.; mesma esperança μ, que sai da soma.*

Na Prova:

$$\begin{aligned}E(T) &= E\Big(\sum_{i=1}^n a_iY_i\Big)\\ &\overset{\text{lin.}}{=} \sum_{i=1}^n a_i\,E(Y_i)\\ &\overset{\text{i.d.}}{=} \sum_{i=1}^n a_i\,\mu\\ &= \mu\sum_{i=1}^n a_i\end{aligned}$$

Raciocínio: *Não viés exige $E(T)=\mu$ para **todo** μ: vira identidade em μ.*

Na Prova:

$$\begin{aligned}&E(T)=\mu,\ \forall\,\mu\\ \iff&\mu\sum_{i=1}^n a_i=\mu,\ \forall\,\mu\\ \iff&\mu\Big(\sum_{i=1}^n a_i-1\Big)=0,\ \forall\,\mu\end{aligned}$$

Raciocínio: *Produto nulo para todo $\mu \Rightarrow$ fator constante nulo (basta tomar $\mu\neq 0$); a volta também vale.*

Na Prova:

$$\iff \sum_{i=1}^n a_i = 1$$

Como $E(T)=\mu\sum a_i$, T é não viesado para $E(Y)$ se e somente se $\sum a_i=1$.

Condição: $\sum_{i=1}^n a_i = 1$.

Raciocínio: *Verificação: $a_i=\frac{1}{n}$ dá $T=\bar{Y}$, $\sum a_i=1$ (Ex. 2); $a_1=a_2=\frac{1}{2}$, demais nulos, dá o T do Ex. 4, $\sum a_i=1$.*

Cola

- lin.: $E(\sum a_iY_i)=\sum a_iE(Y_i)$ (sem independência).
- i.d.: $E(Y_i)=\mu$ para todo i.
- Não viesado: $E(T)=\theta$ **para todo** θ.
- $\mu c=0$ para todo $\mu \iff c=0$.
- Comb. linear não viesada para a média $\iff \sum a_i=1$.

Erro comum: esquecer o "para todo μ": com $\mu=0$ qualquer a_i serve, mas isso não garante não viés em geral; é o quantificador que força $\sum a_i=1$.

Exercício 6

Obs.: $Y\sim\mathrm{Bin}(n,p)$, $T_1=\frac{Y}{n}$, $T_2=\frac{Y+1}{n+2}$.

Em separado:

$$E(Y)=np,\qquad \mathrm{Var}(Y)=np(1-p)$$

Decomposição do EQM: $\mathrm{EQM}(\hat\theta)=E[(\hat\theta-\theta)^2]=\mathrm{Var}(\hat\theta)+B^2(\hat\theta)$.

EQM de T_1

Na Prova:

$$\begin{aligned}E(T_1)=E\Big(\frac{Y}{n}\Big) &\overset{\text{lin.}}{=} \frac{np}{n}=p\\ \Rightarrow B(T_1)&=p-p=0\end{aligned}$$

Raciocínio: *$\frac{1}{n}$ sai da variância ao quadrado.*

Na Prova:

$$\begin{aligned}\mathrm{Var}(T_1)=\mathrm{Var}\Big(\frac{Y}{n}\Big) &\overset{\text{prop.}}{=} \frac{np(1-p)}{n^2}\\ &= \frac{p(1-p)}{n}\\ \mathrm{EQM}(T_1)&=\mathrm{Var}(T_1)+B^2(T_1)\\ &= \frac{p(1-p)}{n}+0^2\end{aligned}$$

$$\boxed{\mathbf{EQM}(T_1)=\frac{p(1-p)}{n}}$$

EQM de T_2

Na Prova:

$$\begin{aligned}E(T_2)=E\Big(\frac{Y+1}{n+2}\Big) &\overset{\text{lin.}}{=} \frac{np+1}{n+2}\\ B(T_2)&=\frac{np+1}{n+2}-p\\ &=\frac{np+1-np-2p}{n+2}\\ &=\frac{1-2p}{n+2}\end{aligned}$$

Raciocínio: *Somar 1 não altera a variância; $\frac{1}{n+2}$ sai ao quadrado.*

Na Prova:

$$\begin{aligned}\mathrm{Var}(T_2)=\mathrm{Var}\Big(\frac{Y+1}{n+2}\Big) &\overset{\text{prop.}}{=} \frac{\mathrm{Var}(Y)}{(n+2)^2}=\frac{np(1-p)}{(n+2)^2}\\ \mathrm{EQM}(T_2)&=\mathrm{Var}(T_2)+B^2(T_2)\\ &=\frac{np(1-p)}{(n+2)^2}+\frac{(1-2p)^2}{(n+2)^2}\end{aligned}$$

$$\boxed{\mathbf{EQM}(T_2)=\frac{np(1-p)+(1-2p)^2}{(n+2)^2}}$$

Raciocínio: *Verificação: T_2 é viesado exceto em $p=\frac{1}{2}$; $B(T_2)\to 0$, então é assintoticamente não viesado.*

Comparação

Raciocínio: *Melhor = EQM menor para **todo** $p\in[0,1]$. Testo dois valores.*

Na Prova:

Para $p=0$:

$$\begin{aligned}\mathrm{EQM}(T_1)&=0\\ \mathrm{EQM}(T_2)&=\frac{0+1}{(n+2)^2}=\frac{1}{(n+2)^2}>0\\ &\Rightarrow \mathrm{EQM}(T_1)<\mathrm{EQM}(T_2)\end{aligned}$$

Para $p=\frac{1}{2}$:

$$\begin{aligned}\mathrm{EQM}(T_1)&=\frac{1}{4n}\\ \mathrm{EQM}(T_2)&=\frac{n/4+0}{(n+2)^2}=\frac{n}{4(n+2)^2}\end{aligned}$$

Como $n^2<(n+2)^2$:

$$\begin{aligned}\frac{n}{4(n+2)^2}<\frac{n}{4n^2}&=\frac{1}{4n}\\ \Rightarrow \mathrm{EQM}(T_2)&<\mathrm{EQM}(T_1)\end{aligned}$$

Raciocínio: *A ordem se inverte: nenhum é uniformemente melhor. Para a região exata, uso $q=p(1-p)$ e $(1-2p)^2=1-4p+4p^2=1-4q$.*

Em separado:

$$\mathrm{EQM}(T_2)=\frac{nq+1-4q}{(n+2)^2}=\frac{(n-4)q+1}{(n+2)^2}$$

Raciocínio: *Multiplico por $n(n+2)^2>0$, sem inverter o sinal.*

Na Prova:

$$\begin{aligned}&\mathrm{EQM}(T_2)<\mathrm{EQM}(T_1)\\ \iff&\frac{(n-4)q+1}{(n+2)^2}<\frac{q}{n}\\ \iff&n(n-4)q+n<q(n+2)^2\\ \iff&n<q[n^2+4n+4-n^2+4n]\\ \iff&n<q(8n+4)\\ \iff&p(1-p)>\frac{n}{8n+4}\end{aligned}$$

Raciocínio: *Inequação do 2º grau $p^2-p+\frac{n}{8n+4}<0$: vale entre as raízes.*

Na Prova:

$$\begin{aligned}\Delta&=1-\frac{4n}{8n+4}=\frac{8n+4-4n}{8n+4}\\ &=\frac{4n+4}{8n+4}=\frac{n+1}{2n+1}\\ &\Rightarrow \mathrm{EQM}(T_2)<\mathrm{EQM}(T_1)\\ &\iff\Big|p-\frac{1}{2}\Big|<\frac{1}{2}\sqrt{\frac{n+1}{2n+1}}\end{aligned}$$

Como a ordem dos EQMs depende de p, nenhum dos estimadores é uniformemente melhor que o outro.

Nenhum é melhor para todo p. T_2 tem EQM menor quando p está perto de $\frac{1}{2}$, isto é, $|p-\frac{1}{2}|<\frac{1}{2}\sqrt{\frac{n+1}{2n+1}}$; T_1 tem EQM menor perto de 0 ou de 1.

Raciocínio: *Verificação: $p=\frac{1}{2}$ está dentro da região e $p=0$ fora. Com $n\to\infty$, o raio tende a $\frac{1}{2\sqrt{2}}\approx 0{,}354$: T_2 ganha para $p\in(0{,}146;\ 0{,}854)$. Intuição: T_2 "puxa" a estimativa para $\frac{1}{2}$.*

Cola

- Binomial: $E(Y)=np$, $\mathrm{Var}(Y)=np(1-p)$.
- $\mathrm{Var}(aY+b)=a^2\,\mathrm{Var}(Y)$ (a constante somada some).
- EQM = Var $+B^2$.
- $B(T_2)=\frac{1-2p}{n+2}$, nulo só em $p=\frac{1}{2}$.
- $(1-2p)^2=1-4p(1-p)$.
- Uniformemente melhor: EQM menor para **todo** θ.
- Dois valores de p com ordem invertida provam que não há estimador uniformemente melhor.

Erro comum: comparar os EQMs num único p (ex.: $p=\frac{1}{2}$) e declarar T_2 melhor. A comparação precisa valer para todo p; aqui as curvas se cruzam.

Exercício 7

Obs.: $Y_i \overset{iid}{\sim} f(y;\theta)$, $i=1,\ldots,n$, $f(y;\theta)=\theta^2\,y\,e^{-\theta y}$, $y>0$, $\theta>0$.

Método dos momentos: com p parâmetros, $\tilde\theta$ resolve $m_r=\mu_r$, $r=1,\ldots,p$, com $m_r=\frac{1}{n}\sum_{i=1}^n Y_i^r$ e $\mu_r=E(Y^r)$.

Raciocínio: *Um parâmetro ($p=1$): basta $m_1=\bar{Y}$ e $\mu_1=E(Y)$.*

Em separado:

Raciocínio: *Definição de esperança (v.a. contínua), suporte $y>0$.*

$$\begin{aligned}E(Y) &\overset{\text{def.}}{=} \int_0^\infty y\,\theta^2\,y\,e^{-\theta y}\,dy\\ &= \theta^2\int_0^\infty y^2e^{-\theta y}\,dy\end{aligned}$$

Raciocínio: *$t=\theta y$, $y=t/\theta$, $dy=dt/\theta$; como $\theta>0$, limites continuam 0 e ∞.*

$$\begin{aligned}&\overset{\text{subst.}}{=} \theta^2\int_0^\infty\Big(\frac{t}{\theta}\Big)^2e^{-t}\,\frac{dt}{\theta}\\ &=\frac{\theta^2}{\theta^3}\int_0^\infty t^{3-1}e^{-t}\,dt\\ &\overset{\Gamma}{=}\frac{1}{\theta}\,\Gamma(3)\end{aligned}$$

Raciocínio: *$\Gamma(\alpha+1)=\alpha\Gamma(\alpha)$ e $\Gamma(1)=1$.*

$$\begin{aligned}\Gamma(3)&=2\,\Gamma(2)=2\cdot1\cdot\Gamma(1)=2\\ \Rightarrow E(Y)&=\frac{2}{\theta}\end{aligned}$$

Raciocínio: *Verificação: f é Gama$(2,\theta)$ pela taxa ($\theta^2/\Gamma(2)=\theta^2$), logo $E(Y)=\alpha/\theta=2/\theta$.*

Na Prova:

$$\begin{aligned}m_1&=\mu_1\\ \bar{Y}&=\frac{2}{\tilde\theta}\end{aligned}$$

Raciocínio: *Isolo $\tilde\theta$; válido pois $Y_i>0\Rightarrow\bar{Y}>0$.*

Na Prova:

$$\tilde\theta=\frac{2}{\bar{Y}}=\frac{2n}{\sum_{i=1}^n Y_i}$$

O estimador de momentos de θ é $\tilde\theta=2/\bar{Y}$.

$$\boxed{\tilde{\boldsymbol\theta}=\frac{\mathbf{2}}{\bar{\boldsymbol Y}}}$$

Raciocínio: *Verificação: positivo, como θ; $\bar{Y}$ alto $\Rightarrow$ taxa pequena, coerente com uma taxa.*

Cola

- MM: $m_r=\mu_r$; um parâmetro $\Rightarrow \bar{Y}=E(Y)$.
- $E(Y)=\int y\,f(y;\theta)\,dy$ no suporte.
- $t=\theta y$, $dy=dt/\theta$ para cair em Γ.
- $\Gamma(\alpha)=\int_0^\infty t^{\alpha-1}e^{-t}dt$, $\Gamma(\alpha+1)=\alpha\Gamma(\alpha)$, $\Gamma(1)=1$.
- Gama(α,θ) (taxa): $E(Y)=\alpha/\theta$; aqui $\alpha=2$.

Erro comum: escrever $E(2/\bar{Y})=2/E(\bar{Y})=\theta$ e concluir não viés. A esperança não passa por $1/x$; por Jensen, $E(\tilde\theta)>\theta$.

Exercício 8

Obs.: $Y_i \overset{iid}{\sim} U(0,\theta)$, $i=1,\ldots,n$, $f(y;\theta)=\frac{1}{\theta}$, $0\leq y\leq\theta$.

Em separado:

Acumulada de Y:

$$F_Y(y) = 0, \quad y < 0$$
$$F_Y(y) = \int_0^y \frac{1}{\theta}\,dt = \frac{y}{\theta}, \quad 0 \le y \le \theta$$
$$F_Y(y) = 1, \quad y > \theta$$

(a) Consistência de $\hat\theta = Y_{(n)}$

Raciocínio: *Método da acumulada: o máximo fica abaixo de y sse todas ficam abaixo de y.*

Na Prova:

Para $0 \le y \le \theta$:

$$\begin{aligned} F_{\hat\theta}(y) &= P(Y_{(n)} \le y) \\ &= P(Y_1 \le y, \ldots, Y_n \le y) \\ &\overset{\text{ind.}}{=} \prod_{i=1}^{n} P(Y_i \le y) \\ &\overset{\text{i.d.}}{=} [F_Y(y)]^n \\ &= \left(\frac{y}{\theta}\right)^n \end{aligned}$$

Derivando:

$$f_{\hat\theta}(y) = \frac{d}{dy}F_{\hat\theta}(y) = \frac{n\,y^{n-1}}{\theta^n}, \quad 0 \le y \le \theta$$

Definição: $\hat\theta$ é consistente em probabilidade se, $\forall\,\varepsilon > 0$, $\lim_{n\to\infty} P(|\hat\theta - \theta| \ge \varepsilon) = 0$.

Raciocínio: *$\hat\theta \le \theta$ sempre, então $|\hat\theta - \theta| = \theta - \hat\theta$ e $\{|\hat\theta - \theta| \ge \varepsilon\} = \{\hat\theta \le \theta - \varepsilon\}$. Dois casos: $\theta - \varepsilon$ dentro ou fora do suporte.*

Na Prova:

Caso $0 < \varepsilon < \theta$:

$$\begin{aligned} P(|\hat\theta - \theta| \ge \varepsilon) &= P(\hat\theta \le \theta - \varepsilon) \\ &= F_{\hat\theta}(\theta - \varepsilon) \\ &= \left(\frac{\theta - \varepsilon}{\theta}\right)^n \\ &= \left(1 - \frac{\varepsilon}{\theta}\right)^n \xrightarrow{n\to\infty} 0 \end{aligned}$$

pois $0 < 1 - \frac{\varepsilon}{\theta} < 1$.

Caso $\varepsilon \ge \theta$:

$$\begin{aligned} P(|\hat\theta - \theta| \ge \varepsilon) &= P(\hat\theta \le \theta - \varepsilon) \\ &\le P(\hat\theta \le 0) = 0 \end{aligned}$$

Nos dois casos:

$$\lim_{n\to\infty} P(|\hat\theta - \theta| \ge \varepsilon) = 0, \ \forall\,\varepsilon > 0$$

Como o limite é 0 para todo $\varepsilon > 0$, $\hat\theta$ é consistente em probabilidade para θ.

$\hat\theta = Y_{(n)}$ é consistente em probabilidade para θ.

(b) Estimador dos momentos

MM: resolver $m_r = \mu_r$, $r = 1, \ldots, p$.

Raciocínio: *Um parâmetro: $\bar Y = E(Y)$.*

Em separado:

$$E(Y) \overset{\text{def.}}{=} \int_0^\theta y \cdot \frac{1}{\theta}\,dy = \frac{1}{\theta}\cdot\frac{\theta^2}{2} = \frac{\theta}{2}$$

Na Prova:

$$\begin{aligned} m_1 &= \mu_1 \\ \bar Y &= \frac{\tilde\theta}{2} \\ \tilde\theta &= 2\bar Y \end{aligned}$$

$\tilde\theta = 2\bar Y$

(c) Comparação

Decomposição do EQM: $\mathrm{EQM}(\hat\theta) = \mathrm{Var}(\hat\theta) + B^2(\hat\theta)$.

Eficiência relativa: $Ef_r(\hat\theta_1, \hat\theta_2) = \mathrm{EQM}(\hat\theta_1)/\,\mathrm{EQM}(\hat\theta_2)$; se < 1, $\hat\theta_1$ é superior.

EQM de $\hat\theta = Y_{(n)}$

Em separado:

Raciocínio: *Uso $f_{\hat\theta}$ do item (a).*

$$\begin{aligned} E(\hat\theta) &\overset{\text{def.}}{=} \int_0^\theta y \cdot \frac{n\,y^{n-1}}{\theta^n}\,dy \\ &= \frac{n}{\theta^n}\cdot\frac{\theta^{n+1}}{n+1} = \frac{n\theta}{n+1} \\ E(\hat\theta^2) &\overset{\text{def.}}{=} \int_0^\theta y^2 \cdot \frac{n\,y^{n-1}}{\theta^n}\,dy \\ &= \frac{n}{\theta^n}\cdot\frac{\theta^{n+2}}{n+2} = \frac{n\theta^2}{n+2} \end{aligned}$$

Raciocínio: *$\mathrm{Var} = E(\hat\theta^2) - E^2(\hat\theta)$; denominador comum $(n+2)(n+1)^2$; $(n+1)^2 - n(n+2) = 1$.*

Na Prova:

$$\begin{aligned} \mathrm{Var}(\hat\theta) &= E(\hat\theta^2) - E^2(\hat\theta) \\ &= \frac{n\theta^2}{n+2} - \frac{n^2\theta^2}{(n+1)^2} \\ &= \frac{n\theta^2[(n+1)^2 - n(n+2)]}{(n+2)(n+1)^2} \\ &= \frac{n\theta^2}{(n+2)(n+1)^2} \end{aligned}$$

$$B(\hat\theta) = \frac{n\theta}{n+1} - \theta = -\frac{\theta}{n+1}$$

$$\begin{aligned} \mathrm{EQM}(\hat\theta) &= \frac{n\theta^2}{(n+2)(n+1)^2} + \frac{\theta^2}{(n+1)^2} \\ &= \frac{\theta^2[n + (n+2)]}{(n+2)(n+1)^2} \\ &= \frac{2\theta^2(n+1)}{(n+2)(n+1)^2} \\ &= \frac{2\theta^2}{(n+1)(n+2)} \end{aligned}$$

EQM de $\tilde\theta = 2\bar Y$

Em separado:

$$\begin{aligned} E(Y^2) &= \int_0^\theta y^2 \cdot \frac{1}{\theta}\,dy = \frac{\theta^2}{3} \\ \mathrm{Var}(Y) &= E(Y^2) - E^2(Y) \\ &= \frac{\theta^2}{3} - \frac{\theta^2}{4} = \frac{\theta^2}{12} \end{aligned}$$

Raciocínio: *Como no Ex. 2 (lin., ind., i.d.): $E(\bar Y) = E(Y)$, $\mathrm{Var}(\bar Y) = \mathrm{Var}(Y)/n$.*

Na Prova:

$$\begin{aligned} E(\tilde\theta) &= 2E(\bar Y) \overset{\text{lin.}}{=} 2\cdot\frac{\theta}{2} = \theta \\ \Rightarrow B(\tilde\theta) &= 0 \\ \mathrm{Var}(\tilde\theta) &= 4\,\mathrm{Var}(\bar Y) \\ &\overset{\text{ind., i.d.}}{=} 4\cdot\frac{\theta^2}{12n} = \frac{\theta^2}{3n} \end{aligned}$$

$$\mathrm{EQM}(\tilde\theta) = \frac{\theta^2}{3n} + 0^2 = \frac{\theta^2}{3n}$$

Eficiência relativa

Na Prova:

$$\begin{aligned} Ef_r(\hat\theta, \tilde\theta) &= \frac{2\theta^2/[(n+1)(n+2)]}{\theta^2/(3n)} \\ &= \frac{6n}{(n+1)(n+2)} \end{aligned}$$

Raciocínio: *$(n+1)(n+2) > 0$: multiplico sem inverter o sinal.*

Na Prova:

$$\begin{aligned} &\frac{6n}{(n+1)(n+2)} < 1 \\ \iff &6n < n^2 + 3n + 2 \\ \iff &n^2 - 3n + 2 > 0 \\ \iff &(n-1)(n-2) > 0 \\ \iff &n \ge 3 \end{aligned}$$

Para $n = 1$ ou $n = 2$, $Ef_r(\hat\theta, \tilde\theta) = 1$.

Como $Ef_r(\hat\theta, \tilde\theta) < 1$ para $n \ge 3$, $\hat\theta$ é superior a $\tilde\theta$.

$\tilde\theta = 2\bar Y$ é não viesado; $\hat\theta = Y_{(n)}$ é viesado (subestima θ), mas tem EQM menor para todo $n \ge 3$ e empata para $n = 1, 2$. Portanto $\hat\theta$ é superior.

Raciocínio: *Verificação: $n = 1$, $\hat\theta = Y_1$ e $\tilde\theta = 2Y_1$, ambos com EQM $\theta^2/3$. Intuição: EQM de $\hat\theta$ cai como $1/n^2$, o de $\tilde\theta$ como $1/n$; além disso $\tilde\theta$ pode ficar abaixo da maior observação (ex.: $y = (1;\,1;\,7) \Rightarrow \tilde\theta = 6 < 7$), o que é impossível para θ.*

Cola

- $U(0,\theta)$: $F_Y(y) = y/\theta$, $E(Y) = \theta/2$, $\mathrm{Var}(Y) = \theta^2/12$.
- Método da acumulada (máximo): $F_{Y_{(n)}}(y) = [F_Y(y)]^n$ (ind., i.d.).
- $f_{Y_{(n)}}(y) = n\,y^{n-1}/\theta^n$, $0 \le y \le \theta$.
- $\hat\theta \le \theta \Rightarrow \{|\hat\theta - \theta| \ge \varepsilon\} = \{\hat\theta \le \theta - \varepsilon\}$.
- $E(Y_{(n)}) = \frac{n\theta}{n+1}$, $\mathrm{EQM}(Y_{(n)}) = \frac{2\theta^2}{(n+1)(n+2)}$.
- MM: $\bar\theta = 2\bar Y$, $\mathrm{EQM} = \theta^2/(3n)$.
- $Ef_r = \frac{6n}{(n+1)(n+2)} < 1 \iff n \ge 3$.

Erro comum: esquecer a potência n no método da acumulada, ou escrever $f_{Y_{(n)}} = [f_Y]^n$. É a **acumulada** que vira potência; a densidade sai derivando depois.

Exercício 9

Obs.: $Y_i \overset{iid}{\sim} U(-\theta, \theta)$, $i = 1, \ldots, n$, $f(y;\theta) = \frac{1}{2\theta}$, $-\theta \le y \le \theta$, $\theta > 0$.

MM: resolver $m_r = \mu_r$, $m_r = \frac{1}{n}\sum_{i=1}^n Y_i^r$, $\mu_r = E(Y^r)$.

Em separado:

Primeiro momento

Raciocínio: *Um parâmetro: começar por $r = 1$.*

$$\begin{aligned} \mu_1 = E(Y) &\overset{\text{def.}}{=} \int_{-\theta}^{\theta} y \cdot \frac{1}{2\theta}\,dy \\ &= \frac{1}{2\theta}\left[\frac{y^2}{2}\right]_{-\theta}^{\theta} \\ &= \frac{1}{2\theta}\left(\frac{\theta^2}{2} - \frac{\theta^2}{2}\right) \\ &= 0 \end{aligned}$$

Raciocínio: *$\mu_1 = 0$ não depende de θ: $\bar Y = 0$ não tem θ para isolar. Passo ao primeiro momento que depende de θ: $r = 2$.*

Em separado:

Segundo momento

Raciocínio: *y^2 é par e o intervalo é simétrico em torno de 0.*

$$\begin{aligned} \mu_2 = E(Y^2) &\overset{\text{def.}}{=} \int_{-\theta}^{\theta} y^2 \cdot \frac{1}{2\theta}\,dy \\ &= \frac{1}{2\theta}\left[\frac{y^3}{3}\right]_{-\theta}^{\theta} \\ &= \frac{1}{2\theta}\left(\frac{\theta^3}{3} + \frac{\theta^3}{3}\right) \\ &= \frac{\theta^2}{3} \end{aligned}$$

Raciocínio: *Verificação: $\mathrm{Var}(Y) = E(Y^2) - E^2(Y) = \frac{\theta^2}{3}$, igual a $\frac{(b-a)^2}{12} = \frac{(2\theta)^2}{12}$.*

Na Prova:

$$\begin{aligned} m_2 &= \mu_2 \\ \frac{1}{n}\sum_{i=1}^n Y_i^2 &= \frac{\tilde\theta^2}{3} \\ \tilde\theta^2 &= \frac{3}{n}\sum_{i=1}^n Y_i^2 \end{aligned}$$

Raciocínio: *Raiz positiva, pois $\theta > 0$.*

Na Prova:

$$\tilde\theta = \sqrt{\frac{3}{n}\sum_{i=1}^n Y_i^2}$$

O estimador de momentos de θ é $\tilde\theta = \sqrt{3\,m_2}$.

$\tilde{\boldsymbol\theta} = \sqrt{\dfrac{\boldsymbol 3}{\boldsymbol n}\displaystyle\sum_{\boldsymbol{i=1}}^{\boldsymbol n} \boldsymbol{Y_i^2}}$

Raciocínio: *Verificação: sempre não negativo. Se todos os $|Y_i| \approx \theta$ (extremidades), $\tilde\theta \approx \sqrt{3}\,\theta$; com pontos espalhados uniformemente, $m_2 \approx \theta^2/3$ e $\tilde\theta \approx \theta$.*

Cola

- $U(-\theta,\theta)$: $f(y;\theta) = \frac{1}{2\theta}$, $-\theta \le y \le \theta$.
- Integrando ímpar em intervalo simétrico $\Rightarrow$ integral nula: $E(Y) = 0$.
- $E(Y^2) = \theta^2/3$.
- Se μ_1 não depende de θ, usar o menor r com μ_r dependente de θ.
- $m_2 = \frac{1}{n}\sum Y_i^2$ (não é S^2: não centra em $\bar Y$).
- Raiz: sinal compatível com o espaço paramétrico ($\theta > 0$).

Erro comum: igualar o segundo momento a S^2 ou a $\hat\sigma^2 = \frac{1}{n}\sum(Y_i - \bar Y)^2$ em vez de $m_2 = \frac{1}{n}\sum Y_i^2$. Isso é outro método (igualar variâncias); o MM das aulas usa momentos **não centrados**.