

Guia de Resolução para Inferência Estatística Avançada

Análise e Estratégias para as Listas de Exercícios 1-9

Miqueias Teixeira (compilado por Gemini)

14 de setembro de 2026

Sumário

Fundamentos e Ferramentas de Probabilidade

1 Revisão de Distribuições e Modelagem (Listas 1 e 3)

Esta seção cobre os exercícios que pedem para você (a) propor um modelo probabilístico para uma situação real ou (b) calcular probabilidades usando um modelo já estabelecido.

1.1 Como Identificar o Exercício

O enunciado descreve um "fenômeno aleatório" em vez de fornecer uma fórmula matemática explícita. Ele usa frases-chave que se conectam diretamente a uma distribuição:

- "Itens classificados como conforme ou não-conforme" ou "número de sucessos em N tentativas" → **Binomial**.
- "Número de carros que chegam... durante um período de uma hora" ou "pedidos por hora" → **Poisson**.
- "Tempo... antes de apresentar defeitos" ou "tempo até o próximo evento" → **Exponencial**.
- "Valores... seguem uma distribuição normal com média..." ou "Medidas antropométricas (peso e altura)" → **Normal**.
- "Tempo de demora pode ser qualquer tempo entre 1 e 20 minutos" → **Uniforme** (Discreta ou Contínua).
- "Lançamento de um dado 12 vezes, X_i é o número de vezes que a face i caiu" → **Multinomial**.

1.2 Teoria Necessária: O "Cartão de ID" das Distribuições

Para resolver esses problemas, você precisa saber o "Cartão de Identidade" das distribuições mais comuns.

Tabela 1: Resumo das Principais Distribuições				
Distribuição	Y (O que mede)	Suporte	Parâmetros	E(Y) / V(Y)
Binomial(n, p)	Nº de sucessos	$k \in \{0, \dots, n\}$	n, p	np / $np(1 - p)$
Poisson(λ)	Nº de eventos	$k \in \{0, 1, \dots\}$	λ	λ / λ
Exponencial(θ)	Tempo até evento	$y > 0$	θ (taxa)	$1/\theta$ / $1/\theta^2$
Normal(μ, σ^2)	Medida contínua	$y \in \mathbb{R}$	μ, σ^2	μ / σ^2
Uniforme(a, b)	Sorteio em $\mathbb{R}$	$y \in [a, b]$	a, b	$\frac{a+b}{2}$ / $\frac{(b-a)^2}{12}$
Gama(α, β)	Tempo até α -ésimo evento	$y > 0$	α, β	$\alpha\beta$ / $\alpha\beta^2$

Nota: A parametrização importa! A Exponencial pode ser por taxa (θ) ou escala ($\beta = 1/\theta$). A Gama também tem variações. Verifique sempre a f.d.p. usada.

1.3 Passo a Passo para Resolução (Modelagem)

1. **Identifique a Variável Aleatória (V.A.):** Qual é o Y no problema? O que está sendo medido? (Contagem, Tempo, Sucesso/Fracasso, Medida Física?).
2. **Identifique o Suporte:** Quais valores Y pode assumir? (Discreto: $\{0, 1, 2, \dots\}$? Contínuo: $Y > 0$?). Isso elimina 50
3. **Conecte ao Processo:** Use as palavras-chave da Seção ?? para escolher a distribuição (Binomial, Poisson, Normal, etc.).
4. **Extraia os Parâmetros:** O texto forneceu n e p ? Ou λ ? Ou μ e σ^2 ?
5. **Formule o Problema:** Escreva o que o problema pede em notação matemática.
 - "Pelo menos 10" → $\mathbb{P}(Y \geq 10)$
 - "Não mais de 5" → $\mathbb{P}(Y \leq 5)$
 - "Mais de 2" → $\mathbb{P}(Y > 2)$
6. **Calcule:**

- Para Normal: Padronize $Z = \frac{Y-\mu}{\sigma}$ e use a tabela Z.
- Para Binomial/Poisson: Use a fórmula da f.p. $P(Y = k)$ ou, para probabilidades acumuladas, use a Normal como aproximação (se n for grande ou λ for grande).

2 Propriedades de V.A. Unidimensionais (Lista 2)

Esta seção cobre exercícios que fornecem uma V.A. Y (via tabela $p(y)$ ou fórmula $f(y)$) e pedem suas propriedades fundamentais, como Esperança e Variância, ou para verificar se uma função é uma f.d.p. válida.

2.1 Como Identificar o Exercício

O enunciado fornece uma função matemática explícita e pede:

- "Encontre a esperança e variância..."
- "Verifique se... é uma função densidade de probabilidade".
- "Calcule $E(Y)$ e $E(Y(Y-1))$..."

A V.A. é dada por:

- **Caso Discreto:** Uma tabela $p(y_i)$ ou uma fórmula $p(y; \theta)$ com suporte em $y = 1, 2, \dots$
- **Caso Contínuo:** Uma fórmula $f(y)$ com um intervalo, ex: "se $0 \leq y \leq 1$ ".

2.2 Teoria Necessária

Definição 2.1 (f.d.p. Válida). *Uma função $f(y)$ é uma f.d.p. válida se:*

1. $f(y) \geq 0$ para todo y no suporte.
2. $\int_{-\infty}^{\infty} f(y)dy = 1$ (ou $\sum p(y_i) = 1$ no caso discreto).

Definição 2.2 (Esperança (Valor Esperado)). *É a média ponderada de Y :*

$$\mathbb{E}(Y) = \begin{cases} \sum_y y \cdot p(y) & \text{Discreto} \\ \int_{-\infty}^{\infty} y \cdot f(y)dy & \text{Contínuo} \end{cases}$$

Propriedade 2.1 (Lei do Estatístico Inconsciente (LOTUS)). *Para calcular a esperança de uma função de Y , (ex: $g(Y) = Y^2$), não é preciso achar a f.d.p. de Y^2 . Basta aplicar:*

$$\mathbb{E}(g(Y)) = \begin{cases} \sum_y g(y) \cdot p(y) & \text{Discreto} \\ \int_{-\infty}^{\infty} g(y) \cdot f(y)dy & \text{Contínuo} \end{cases}$$

Definição 2.3 (Variância). *É a esperança do desvio quadrático da média: $\mathbb{V}(Y) = \mathbb{E}[(Y - \mathbb{E}(Y))^2]$. Na prática, usamos a fórmula computacional:*

$$\mathbb{V}(Y) = \mathbb{E}(Y^2) - [\mathbb{E}(Y)]^2$$

Onde $\mathbb{E}(Y^2)$ é calculado usando LOTUS (com $g(Y) = Y^2$).

2.3 Passo a Passo para Resolução

2.3.1 Verificando se $f(y)$ é f.d.p. válida

1. **Condição 1 (Não-negatividade):** Verifique se $f(y) \geq 0$ dentro do suporte. Se for $f(y) = 3y$ em $[0, 1]$, é ≥ 0 . Se fosse $f(y) = y - 3$ em $[0, 4]$, falharia.
2. **Condição 2 (Integral unitária):** Calcule $\int_{-\infty}^{\infty} f(y)dy$. Lembre-se que a integral só é não-nula dentro do suporte. Se o resultado for 1, ela é válida. Se for 0, ∞ , ou qualquer outro número (ex: $3/2$), ela não é.

2.3.2 Calculando $E(Y)$ e $V(Y)$

1. **Identificar o tipo:** É discreta (tabela/soma) ou contínua (fórmula/integral)?
2. **Calcular $E(Y)$:**
 - **Discreta:** $E(Y) = \sum y \cdot p(y)$.
 - **Contínua:** $E(Y) = \int y \cdot f(y)dy$. (Ex: $f(y) = 2y$ em $[0, 1] \rightarrow E(Y) = \int_0^1 y \cdot (2y)dy = \int_0^1 2y^2dy$).
3. **Calcular $E(Y^2)$:**
 - **Discreta:** $E(Y^2) = \sum y^2 \cdot p(y)$.
 - **Contínua:** $E(Y^2) = \int y^2 \cdot f(y)dy$. (Ex: $f(y) = 2y$ em $[0, 1] \rightarrow E(Y^2) = \int_0^1 y^2 \cdot (2y)dy = \int_0^1 2y^3dy$).
4. **Calcular $V(Y)$:**
 - Use a fórmula $V(Y) = E(Y^2) - [E(Y)]^2$ com os valores dos passos 2 e 3.

Dica (Lista 2, Ex 4): Calcular $E(Y(Y-1)) = E(Y^2 - Y) = E(Y^2) - E(Y)$ é um atalho. Você pode achar $E(Y^2)$ fazendo $E(Y(Y-1)) + E(Y)$ e então usar a fórmula da variância.

3 V.A. Multidimensionais (Listas 2 e 3)

Esta seção cobre exercícios que envolvem duas ou mais V.A.s simultaneamente. Os objetivos são encontrar distribuições marginais, condicionais, covariância e correlação.

3.1 Como Identificar o Exercício

O enunciado fornece:

- Uma **tabela de dupla entrada** $p(y_1, y_2)$.
- Uma **f.d.p. conjunta** $f(y_1, y_2)$ definida sobre uma região (ex: $0 < y_1 < y_2 < 1$).
- Uma **Normal Bivariada/Multivariada** (BN/MVN), definida por um vetor de médias μ e uma matriz de covariâncias Σ .

O enunciado pede:

- "Obtenha as distribuições marginais".
- "Calcule a correlação entre X e Y".
- "Mostre que são independentes".
- "Encontre a distribuição condicional $f(y_1|y_2)$ ".
- "Calcule $P(1/4 < Y_1 < 1/2 | Y_2 = 5/8)$ ".
- "Encontre a distribuição de $X_0 - X_2$ " (a partir de uma MVN).

3.2 Teoria Necessária

Definição 3.1 (Distribuição Marginal). *A distribuição de apenas uma V.A., ignorando as outras.*

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y)dy \quad (\text{ou} \quad p(x) = \sum_y p(x, y))$$

(Integre/some a variável que você quer "eliminar").

Definição 3.2 (Distribuição Condicional). *A distribuição de Y dado que X assumiu um valor x.*

$$f(y|x) = \frac{f(x, y)}{f_X(x)} \quad (\text{Conjunta dividida pela Marginal})$$

Definição 3.3 (Independência). *X e Y são independentes se e somente se:*

$$f(x, y) = f_X(x) \cdot f_Y(y) \quad (\text{ou} \quad p(x, y) = p(x) \cdot p(y))$$

Definição 3.4 (Covariância e Correlação). *Mede a associação linear entre X e Y .*

$$Cov(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

Onde $\mathbb{E}(XY) = \iint xy \cdot f(x, y) dx dy$ (ou $\sum \sum xy \cdot p(x, y)$).

Propriedade 3.1 (Normal Multivariada (MVN)). *Se $\mathbf{Y} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, qualquer combinação linear de $\mathbf{Y}$ também é Normal. Ex (Lista 3, Ex 9): $Y = (X_0, X_2, X_4)^T \sim N_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. A V.A. $W = X_0 - X_2$ é uma combinação linear: $W = (1, -1, 0) \cdot \mathbf{Y}$. Portanto, W também é Normal.*

- $\mathbb{E}(W) = \mathbb{E}(X_0 - X_2) = \mathbb{E}(X_0) - \mathbb{E}(X_2) = \mu_0 - \mu_2$.
- $\mathbb{V}(W) = \mathbb{V}(X_0 - X_2) = \mathbb{V}(X_0) + \mathbb{V}(X_2) - 2Cov(X_0, X_2)$.
- Todos esses valores $(\mu_0, \mu_2, \mathbb{V}(X_0), \mathbb{V}(X_2), Cov(X_0, X_2))$ são lidos diretamente do vetor $\boldsymbol{\mu}$ e da matriz $\boldsymbol{\Sigma}$.

3.3 Passo a Passo para Resolução

3.3.1 Caso 1: Tabela de Dupla Entrada (Ex: Lista 2, Ex 6, 8)

1. **Marginais $p(x)$ e $p(y)$:** Some os valores das linhas (para $p(x)$) e das colunas (para $p(y)$).
2. **Esperanças $\mathbb{E}(X), \mathbb{E}(Y)$:** Use as distribuições marginais (que são unidimensionais) e o método da Seção ??.
3. **Variâncias $\mathbb{V}(X), \mathbb{V}(Y)$:** Calcule $\mathbb{E}(X^2)$ e $\mathbb{E}(Y^2)$ a partir das marginais e use $\mathbb{V}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$.
4. **Esperança Conjunta $\mathbb{E}(XY)$:** Crie uma nova "célula" na tabela $g(x, y) = x \cdot y$. Calcule $\mathbb{E}(XY) = \sum_x \sum_y (x \cdot y) \cdot p(x, y)$.
5. **Covariância:** $Cov(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$.
6. **Correlação:** $\rho(X, Y) = Cov(X, Y) / (\sigma_X \sigma_Y)$.
7. **Independência:** Cheque se $p(x, y) = p(x) \cdot p(y)$ para **todas** as células. Se falhar em uma, não são independentes.

3.3.2 Caso 2: f.d.p. Conjunta $f(x, y)$ (Ex: Lista 2, Ex 7, 9, 10)

1. **Constantes (Ex: c_1, c_2):** Use o fato de que f.d.p.s integram 1.
 - Se $f(y_2) = c_2 y_2^4$ em $0 < y_2 < 1$, então $\int_0^1 c_2 y_2^4 dy_2 = 1 \Rightarrow c_2 [\frac{y_2^5}{5}]_0^1 = 1 \Rightarrow c_2 = 5$.
 - O mesmo vale para $f(y_1|y_2)$.
2. **Marginal $f_X(x)$:** Integre a conjunta em y : $f_X(x) = \int_{y_{min}}^{y_{max}} f(x, y) dy$. **Cuidado com os limites de integração!**
Se $f(x, y) = 2$ para $0 < x < y < 1$, então $f_X(x) = \int_x^1 2 dy = 2(1 - x)$ para $0 < x < 1$.
3. **Marginal $f_Y(y)$:** Integre a conjunta em x : $f_Y(y) = \int_{x_{min}}^{x_{max}} f(x, y) dx$. No exemplo $0 < x < y < 1$, $f_Y(y) = \int_0^y 2 dx = 2y$ para $0 < y < 1$.
4. **Independência:** Verifique se $f(x, y) = f_X(x) \cdot f_Y(y)$.
 - No exemplo $f(x, y) = 2$, temos $f_X(x)f_Y(y) = 2(1 - x) \cdot 2y \neq 2$. Não são independentes.
 - Se o suporte $0 < x < y < 1$ depende um do outro, elas **não podem** ser independentes.
5. **Condicional $f(x|y)$:** Use a fórmula $f(x|y) = f(x, y) / f_Y(y)$.
 - No exemplo $f(x, y) = 2$, temos $f(x|y) = 2 / (2y) = 1/y$, para $0 < x < y$.
6. **Probabilidade Condicional:** Para $P(a < X < b | Y = y_0)$, apenas integre a f.d.p. condicional: $\int_a^b f(x|y_0) dx$.

Parte II

Teoria de Amostragem e Teoremas Limite

4 Ferramentas Avançadas e Teoremas Limite (Lista 4)

Esta seção cobre os resultados teóricos que formam a base da inferência. Os exercícios pedem por "limites" (Desigualdades), "convergência" (LGN) ou "distribuição aproximada" (TCL).

4.1 Como Identificar o Exercício

O enunciado usa palavras-chave específicas:

- "Dê um limite superior para a proporção..." → **Markov** ou **Chebyshev**.
- "Encontre um limite para a probabilidade..." → **Chebyshev**.
- "...converge em probabilidade para..." → **Lei dos Grandes Números (LGN)**.
- "Encontre a distribuição aproximada..." → **Teorema Central do Limite (TCL)**.
- "Argumente sobre a afirmação $t \rightarrow Z$ " → **TCL** + **Teorema de Slutsky**.

4.2 Teoria e Passo a Passo

4.2.1 Desigualdades de Markov e Chebyshev

Usadas quando você sabe muito pouco sobre a distribuição (apenas média e/ou variância) e quer um limite "grosseiro" para uma probabilidade.

- **Desigualdade de Markov:** Para uma V.A. não-negativa X e $a > 0$:

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}$$

- **Desigualdade de Chebyshev:** Para qualquer V.A. X com média μ e variância σ^2 :

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}$$

Exemplo (Lista 4, Q3): $P(|X - 50| \geq 10) \leq \frac{V(X)}{10^2} = \frac{25}{100} = \frac{1}{4}$.

4.2.2 Lei dos Grandes Números (LGN)

Teorema 4.1 (LGN Fraca). Se $Y_1, \dots, Y_n$ são iid com $\mathbb{E}(Y_i) = \mu$ e $\mathbb{V}(Y_i) = \sigma^2 < \infty$, então a média amostral $\bar{Y}_n$ converge em probabilidade para μ .

$$\bar{Y}_n \xrightarrow{p} \mu$$

Interpretação: À medida que sua amostra n cresce, a média da amostra ($\bar{Y}$) fica arbitrariamente próxima da verdadeira média da população (μ). Isso é o que justifica usar a média amostral como um estimador "bom".

4.2.3 Teorema Central do Limite (TCL)

Teorema 4.2 (TCL de Lindeberg-Lévy). Se $Y_1, \dots, Y_n$ são iid com $\mathbb{E}(Y_i) = \mu$ e $\mathbb{V}(Y_i) = \sigma^2 < \infty$, então a média amostral padronizada converge em distribuição para uma Normal Padrão.

$$Z_n = \frac{\bar{Y}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1) \quad \text{quando } n \rightarrow \infty$$

Interpretação: Esta é a ferramenta mais poderosa da estatística. Ela diz que, para n grande, **não importa a distribuição original de Y** , a **distribuição da média amostral $\bar{Y}$** será aproximadamente Normal:

$$\bar{Y} \overset{approx.}{\sim} N\left(\mu, \frac{\sigma^2}{n}\right)$$

É por isso que podemos usar a tabela Normal para aproximar probabilidades Binomiais (Lista 4, Q4) ou calcular probabilidades sobre $\bar{Y}$ de uma Exponencial (Lista 4, Q6).

4.2.4 Teorema de Slutsky

Usado para justificar por que podemos trocar σ por S em amostras grandes.

Teorema 4.3 (Slutsky). Se $X_n \xrightarrow{d} X$ e $Y_n \xrightarrow{p} c$ (uma constante), então: $X_n + Y_n \xrightarrow{d} X + c$ e $X_n \cdot Y_n \xrightarrow{d} X \cdot c$.

Aplicação (Lista 4, Q9): Por que $t \rightarrow Z$?

$$t = \frac{\bar{Y} - \mu}{S/\sqrt{n}} = \underbrace{\left(\frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \right)}_{\xrightarrow{d} Z \text{ (pelo TCL)}} \cdot \underbrace{\left(\frac{\sigma}{S} \right)}_{\xrightarrow{p} 1 \text{ (pois } S \xrightarrow{p} \sigma \text{ pela LGN)}}$$

Pelo Teorema de Slutsky, $t \xrightarrow{d} Z \cdot 1 = Z$.

5 Distribuições Amostrais (Listas 5 e 6)

Esta seção trata das *distribuições de probabilidade de estatísticas* (como $\bar{Y}$, S^2 , $\hat{p}$). Saber qual distribuição usar é a habilidade fundamental para construir ICs e testes de hipótese.

5.1 Como Identificar o Exercício

O enunciado pede uma probabilidade sobre uma estatística amostral:

- "Calcule $P(90 < \bar{Y} < 110)$ ".
- "Qual a probabilidade da média amostral não diferir da média populacional por mais do que 5%?".
- "Calcule a probabilidade da variância amostral ser maior que 700".
- "Qual a probabilidade de a diferença entre as médias amostrais ser maior que 50 pontos?".
- "Qual a probabilidade... de obter uma razão [de variâncias] pelo menos tão grande quanto 2.5?".

5.2 O Fluxograma da Inferência: Z, t, χ^2 ou F?

Para resolver *qualquer* exercício das Listas 5 e 6, use este fluxograma mental:

1. Qual é o parâmetro de interesse?

- **Média (μ) ou Proporção (p)** → Siga para o passo 2.
- **Variância (σ^2)** → Siga para o passo 3.

2. Inferência sobre Média(s) ou Proporção(ões):

- **Uma Média (μ):**
 - A população é Normal E σ é **conhecido**? → Use **Z (Normal)**.

$$Z = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

- A população é Normal E σ é **desconhecido**? → Use **t (Student)**.

$$t = \frac{\bar{Y} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

- A população **não é** Normal (ou desconhecida), mas n é **grande** ($n > 30$)? → Use **Z (TCL)**.

- **Uma Proporção (p):**
 - n é grande ($np > 5$, $n(1-p) > 5$)? → Use **Z (TCL)**.

$$Z = \frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \stackrel{aprox.}{\sim} N(0, 1)$$

- **Duas Médias ($\mu_1 - \mu_2$):**

– σ_1 e σ_2 são **conhecidos**? → Use **Z (Normal)**.

$$Z = \frac{(\bar{Y}_1 - \bar{Y}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$$

– σ_1, σ_2 desconhecidos, mas n_1, n_2 grandes? → Use **Z**, trocando σ por S .

– σ_1, σ_2 desconhecidos (n pequeno)? → Use **t (Student)** (com ν complexo ou agrupado).

3. Inferência sobre Variância(s):

- **Uma Variância (σ^2):** População é Normal? → Use χ^2 (**Qui-Quadrado**).

$$W = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

- **Duas Variâncias (σ_1^2, σ_2^2):** Populações Normais e independentes? → Use **F (Snedecor-Fisher)**.

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}$$

(Se $\sigma_1^2 = \sigma_2^2$, a estatística simplifica para $F = S_1^2/S_2^2$).

5.2.1 Passo a Passo para Calcular Probabilidades

1. **Identifique o Problema:** Ex: Calcular $P(S^2 > 700)$.
2. **Escolha a Estatística-Teste:** Pelo fluxograma, é sobre σ^2 → Usar χ^2 .
3. **Extraia os Dados:** $n = 16$, $\sigma^2 = 600^2 = 360000$ (do $\sigma = 600$).
4. **Transforme a Pergunta:** Você não pode calcular $P(S^2 > 700)$ diretamente. Você deve transformar S^2 na estatística χ^2 .

$$\begin{aligned} P(S^2 > 700) &= P\left(\frac{(n-1)S^2}{\sigma^2} > \frac{(16-1) \cdot 700}{360000}\right) \\ &= P\left(\chi_{15}^2 > \frac{10500}{360000}\right) = P(\chi_{15}^2 > 0.02916) \end{aligned}$$

5. **Calcule:** Use a tabela ou software para encontrar a probabilidade (neste caso, será ≈ 1).

6 Intervalos de Confiança (IC) (Lista 6)

O IC é a primeira aplicação prática das distribuições amostrais. É um intervalo de valores plausíveis para um parâmetro populacional, baseado nos dados da amostra.

6.1 Como Identificar o Exercício

O enunciado é explícito:

- "Encontre o intervalo de confiança para..."
- "Construa um intervalo de confiança..."
- "Calcule o intervalo de confiança de 95% para a variância..."
- "Explique a interpretação..."

6.2 A Estrutura Geral (Para Médias e Proporções)

A maioria dos ICs segue a forma:

Estimador $\pm$ Margem de Erro

Estimador $\pm$ (Valor Crítico) $\times$ (Erro Padrão do Estimador)

- **Estimador:** O seu "melhor chute" (Ex: $\bar{Y}$, $\hat{p}$, $\bar{Y}_1 - \bar{Y}_2$).
- **Valor Crítico:** O quantil da distribuição amostral (Z, t) que define o seu nível de confiança (Ex: $z_{\alpha/2}$, $t_{\alpha/2, n-1}$).
- **Erro Padrão:** O desvio padrão da distribuição amostral do estimador (Ex: $\sigma/\sqrt{n}$, $S/\sqrt{n}$, $\sqrt{\hat{p}(1-\hat{p})/n}$).

6.3 Passo a Passo (Receitas de Bolo para ICs)

6.3.1 IC para Média μ , com σ Conhecido

Contexto: Lista 6, Q5. **Fórmula:** $\bar{Y} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$ **Passos:**

1. Encontre $\bar{Y}$, σ , n .
2. Determine o nível de confiança (ex: 95%) e ache α (ex: 5% = 0.05).
3. Encontre $z_{\alpha/2}$ (ex: $z_{0.025} = 1.96$).
4. Calcule $\bar{Y} - 1.96 \cdot (\sigma/\sqrt{n})$ e $\bar{Y} + 1.96 \cdot (\sigma/\sqrt{n})$.

Nota: Q5 mostra que $\uparrow n$ ou $\downarrow$ Confiança $\Rightarrow \downarrow$ Amplitude do IC.

6.3.2 IC para Média μ , com σ Desconhecido

Contexto: Lista 6, Q8. **Fórmula:** $\bar{Y} \pm t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}$ **Passos:**

1. Encontre $\bar{Y}$, S , n .
2. Ache $t_{\alpha/2, n-1}$ na tabela t com $n - 1$ graus de liberdade.
3. Calcule $\bar{Y} \pm t \cdot (S/\sqrt{n})$.

Nota: Na Q8, $n = 400$ é tão grande que $t_{399} \approx z$. O exercício usa $z_{0.005} = 2.576$.

6.3.3 IC para Proporção p (Amostra Grande)

Contexto: Lista 6, Q6. **Fórmula:** $\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ **Passos:**

1. Encontre $\hat{p}$ (ex: 70% = 0.70) e $n = 625$.
2. Ache $z_{\alpha/2}$ (ex: 90% $\rightarrow z_{0.05} = 1.645$).
3. Calcule $\hat{p} \pm z \cdot \text{Erro Padrão}$.

6.3.4 IC para Variância σ^2

Contexto: Lista 6, Q9. **Fórmula (Assimétrica):** $\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right]$ **Passos:**

1. Encontre $S^2 = 16000$ e $n = 25$.
2. Encontre os **dois** valores críticos da χ^2 com $n - 1 = 24$ g.l.
 - Limite superior (corta 2.5
 - Limite inferior (corta 2.5
3. Calcule o IC. **Cuidado:** O valor crítico maior (39.364) vai no **denominador da esquerda** (para dar o limite inferior do IC).

$$\left[\frac{(24) \cdot 16000}{39.364}, \frac{(24) \cdot 16000}{12.401} \right]$$

6.4 Interpretação Correta do IC (Lista 6, Q7)

Enunciado: $IC[\mu; 0, 95] = [21, 5; 32, 5]$.

- **Interpretação ERRADA:** "A probabilidade de μ estar entre 21,5 e 32,5 é de 95%." (Errado, pois μ é um valor fixo, não aleatório. Ele está ou não está no intervalo).
- **Interpretação CORRETA:** "Nós temos 95% de confiança de que o verdadeiro valor do parâmetro μ está contido no intervalo [21,5; 32,5]."
- **Interpretação CORRETA (Frequencista):** "Se nós repetíssemos este processo de amostragem e construção de intervalo 100 vezes, esperaríamos que 95 dos intervalos resultantes contivessem o verdadeiro valor de μ ."

Parte III

Estimação de Parâmetros

7 Estimação de Parâmetros e Propriedades (Lista 7)

Esta seção foca em como avaliar a "qualidade" de um estimador $\hat{\theta}$. Os exercícios fornecem um $\hat{\theta}$ (ou pedem para você encontrar um) e analisam suas propriedades.

7.1 Vício de um Estimador

Definição 7.1 (Vício (Bias)). *Um estimador $\hat{\theta}$ é dito **não-viciado** (ou não-tendencioso) para θ se o seu valor esperado for igual ao parâmetro, ou seja:*

$$\mathbb{E}(\hat{\theta}) = \theta$$

*Isso significa que, em média, o estimador acerta o alvo. Se $\mathbb{E}(\hat{\theta}) \neq \theta$, o estimador é **viciado**. O vício é a diferença:*

$$B(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$$

Propriedade 7.1 (Vício Assintótico). *Um estimador é **assintoticamente não-viciado** se o vício desaparece quando $n \rightarrow \infty$.*

$$\lim_{n \rightarrow \infty} \mathbb{E}(\hat{\theta}_n) = \theta$$

7.1.1 Exemplo-Chave: Vício do S^2 vs $\hat{\sigma}^2$

Seja $Y_i \stackrel{iid}{\sim} (\mu, \sigma^2)$.

- **Estimador S^2 (Variância Amostral):** $S^2 = \frac{1}{n-1} \sum (Y_i - \bar{Y})^2$
 - É possível provar que $\mathbb{E}[\sum (Y_i - \bar{Y})^2] = (n-1)\sigma^2$.
 - $\mathbb{E}(S^2) = \mathbb{E}\left[\frac{1}{n-1} \sum (Y_i - \bar{Y})^2\right] = \frac{1}{n-1} \mathbb{E}[\sum (Y_i - \bar{Y})^2] = \frac{1}{n-1} (n-1)\sigma^2 = \sigma^2$.
 - **Conclusão:** S^2 é **não-viciado** para σ^2 .
- **Estimador $\hat{\sigma}^2$ (EMV da Normal):** $\hat{\sigma}^2 = \frac{1}{n} \sum (Y_i - \bar{Y})^2$
 - $\mathbb{E}(\hat{\sigma}^2) = \mathbb{E}\left[\frac{1}{n} \sum (Y_i - \bar{Y})^2\right] = \frac{1}{n} (n-1)\sigma^2 = \left(\frac{n-1}{n}\right) \sigma^2$.
 - **Conclusão:** $\hat{\sigma}^2$ é **viciado** para σ^2 .
 - O vício é $B(\hat{\sigma}^2) = \left(\frac{n-1}{n}\right)\sigma^2 - \sigma^2 = -\frac{\sigma^2}{n}$.
 - No entanto, $\lim_{n \rightarrow \infty} \mathbb{E}(\hat{\sigma}^2) = \lim_{n \rightarrow \infty} \left(\frac{n-1}{n}\right)\sigma^2 = \sigma^2$.
 - **Conclusão 2:** $\hat{\sigma}^2$ é **assintoticamente não-viciado**.

7.2 Erro Quadrático Médio (EQM)

O EQM é a métrica principal para avaliar o "erro" total de um estimador.

Definição 7.2 (Erro Quadrático Médio (EQM)). *É a esperança do erro ao quadrado:*

$$EQM(\hat{\theta}) = \mathbb{E}\left[(\hat{\theta} - \theta)^2\right]$$

Propriedade 7.2 (Decomposição do EQM). *A fórmula mais útil para calcular o EQM é sua decomposição em Vício e Variância:*

$$EQM(\hat{\theta}) = \mathbb{V}(\hat{\theta}) + [B(\hat{\theta})]^2$$

Prova:

$$\begin{aligned}
 EQM(\hat{\theta}) &= \mathbb{E}[(\hat{\theta} - \theta)^2] = \mathbb{E}[(\hat{\theta} - \mathbb{E}(\hat{\theta}) + \mathbb{E}(\hat{\theta}) - \theta)^2] \\
 &= \mathbb{E}[\underbrace{(\hat{\theta} - \mathbb{E}(\hat{\theta}))}_{\text{Variância}} + \underbrace{(\mathbb{E}(\hat{\theta}) - \theta)}_{\text{Vício}}]^2 \\
 &= \mathbb{E}[(\hat{\theta} - \mathbb{E}(\hat{\theta}))^2] + 2\mathbb{E}[(\hat{\theta} - \mathbb{E}(\hat{\theta}))(\mathbb{E}(\hat{\theta}) - \theta)] + (\mathbb{E}(\hat{\theta}) - \theta)^2 \\
 &= \mathbb{V}(\hat{\theta}) + 2(\mathbb{E}(\hat{\theta}) - \theta)\mathbb{E}[(\hat{\theta} - \mathbb{E}(\hat{\theta}))] + [B(\hat{\theta})]^2 \\
 &= \mathbb{V}(\hat{\theta}) + 2(\text{Vício}) \cdot 0 + [B(\hat{\theta})]^2 \\
 &= \mathbb{V}(\hat{\theta}) + [B(\hat{\theta})]^2
 \end{aligned}$$

Conclusão: Se um estimador é não-viciado ($B(\hat{\theta}) = 0$), então $EQM(\hat{\theta}) = \mathbb{V}(\hat{\theta})$. Para comparar um estimador viciado e um não-viciado, sempre compare seus EQMs. O **menor EQM** é o melhor.

7.3 Consistência

Definição 7.3 (Consistência (em Probabilidade)). *Um estimador $\hat{\theta}_n$ é consistente para θ se, para qualquer $\epsilon > 0$,*

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\theta}_n - \theta| \geq \epsilon) = 0$$

Isso é, $\hat{\theta}_n \xrightarrow{p} \theta$. A massa de probabilidade do estimador se concentra em torno do parâmetro verdadeiro à medida que n cresce.

Propriedade 7.3 (Consistência Médio Quadrática). *Uma forma fácil de provar consistência é usar o EQM. Se o EQM vai a zero, o estimador é consistente. Se $\lim_{n \rightarrow \infty} EQM(\hat{\theta}_n) = 0$, então $\hat{\theta}_n$ é **médio quadrático consistente** (o que implica consistência em probabilidade).*

7.4 Método dos Momentos (MM) (Lista 7)

Um método para encontrar estimadores baseado na Lei dos Grandes Números (que diz $m'_k \xrightarrow{p} \mu'_k$).

7.4.1 Passo a Passo

1. **Identifique K**, o número de parâmetros.
2. **Calcule os K primeiros Momentos Populacionais:** $\mu'_k = \mathbb{E}(Y^k)$.
3. **Defina os K primeiros Momentos Amostrais:** $m'_k = \frac{1}{n} \sum Y_i^k$.
4. **Equacione e Resolva:** Crie um sistema de K equações igualando $\mu'_k = m'_k$ e isole os parâmetros $\theta_1, \dots, \theta_k$.

7.4.2 Exemplo (Lista 7, Q7): Gama($\alpha = 2, \beta = 1/\theta$)

A fdp é $f(y; \theta) = \theta^2 y e^{-\theta y}$.

1. K = 1 parâmetro (θ).
2. $\mu'_1 = \mathbb{E}(Y) = \int_0^\infty y \cdot (\theta^2 y e^{-\theta y}) dy = \dots = 2/\theta$.
3. $m'_1 = \bar{Y}$.
4. $\mu'_1 = m'_1 \implies \frac{2}{\theta} = \bar{Y} \implies \hat{\theta}_{MM} = \frac{2}{\bar{Y}}$.

7.4.3 Exemplo (Gama(α, β) com 2 parâmetros)

f.d.p. $f(y; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} y^{\alpha-1} e^{-y/\beta}$.

1. K = 2 parâmetros (α, β).
2. $\mu'_1 = \mathbb{E}(Y) = \alpha\beta$.
 $\mu'_2 = \mathbb{E}(Y^2) = \mathbb{V}(Y) + [\mathbb{E}(Y)]^2 = \alpha\beta^2 + (\alpha\beta)^2 = \alpha\beta^2(1 + \alpha)$.
3. $m'_1 = \bar{Y}$.
 $m'_2 = \frac{1}{n} \sum Y_i^2$.
4. $\begin{cases} \alpha\beta = \bar{Y} \\ \alpha\beta^2(1 + \alpha) = m'_2 \end{cases} \implies \dots \implies \text{Resolver o sistema para } \hat{\alpha} \text{ e } \hat{\beta}.$

8 Método da Máxima Verossimilhança (EMV) (Lista 8)

O EMV (ou MLE) é o método mais importante de estimação. A ideia é encontrar o valor do parâmetro ($\hat{\theta}$) que torna a amostra observada ($\mathbf{y}$) o mais provável possível.

8.1 Definições

Definição 8.1 (Função de Verossimilhança $L(\theta)$). Dada uma amostra iid $\mathbf{y} = (y_1, \dots, y_n)$ de uma f.d.p. $f(y; \theta)$, a verossimilhança é o produto das f.d.p.s, mas vista como uma função de θ :

$$L(\theta|\mathbf{y}) = \prod_{i=1}^n f(y_i; \theta)$$

Definição 8.2 (Estimador de Máxima Verossimilhança (EMV)). O EMV, $\hat{\theta}$, é o valor de $\theta \in \Omega$ (espaço paramétrico) que maximiza $L(\theta)$.

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

Definição 8.3 (Função de Log-Verossimilhança $l(\theta)$). Como log é uma função monotônica crescente, maximizar $L(\theta)$ é o mesmo que maximizar $l(\theta) = \ln(L(\theta))$. Isso transforma produtos em somas, o que facilita a derivação.

$$l(\theta) = \ln(L(\theta)) = \sum_{i=1}^n \ln(f(y_i; \theta))$$

8.2 Passo a Passo (Casos Regulares, via Derivada)

Usado quando o parâmetro θ está no interior do espaço paramétrico e a função é diferenciável (ex: Poisson, Normal, Binomial).

1. **Escrever $L(\theta)$:** $L(\theta) = \prod f(y_i; \theta)$.
2. **Calcular $l(\theta)$:** $l(\theta) = \sum \ln(f(y_i; \theta))$.
3. **Calcular a Função Score $U(\theta)$:**

$$U(\theta) = \frac{\partial l(\theta)}{\partial \theta}$$

4. **Resolver a Equação de Score:** Encontre $\hat{\theta}$ que resolve $U(\hat{\theta}) = 0$.
5. **Verificar (Opcional):** Checar se é ponto de máximo (e não mínimo) vendo se a segunda derivada (Hessiana) é negativa:

$$\left. \frac{\partial^2 l(\theta)}{\partial \theta^2} \right|_{\theta=\hat{\theta}} < 0$$

8.2.1 Exemplo (Poisson(λ))

1. $L(\lambda) = \prod \frac{e^{-\lambda} \lambda^{y_i}}{y_i!} = \frac{e^{-n\lambda} \lambda^{\sum y_i}}{\prod y_i!}$
2. $l(\lambda) = -n\lambda + (\sum y_i) \ln(\lambda) - \sum \ln(y_i!)$
3. $U(\lambda) = \frac{\partial l}{\partial \lambda} = -n + \frac{\sum y_i}{\lambda}$
4. $U(\hat{\lambda}) = 0 \implies -n + \frac{\sum y_i}{\hat{\lambda}} = 0 \implies \hat{\lambda} = \frac{\sum y_i}{n} = \bar{Y}$.
5. $\frac{\partial^2 l}{\partial \lambda^2} = -\frac{\sum y_i}{\lambda^2}$. Como $\sum y_i > 0$ e $\lambda^2 > 0$, a segunda derivada é negativa. É um máximo.

8.3 Passo a Passo (Casos Não-Regulares, via Inspeção)

Usado quando o suporte da f.d.p. depende do parâmetro (ex: $U(0, \theta)$). A derivada geralmente não funciona aqui.

8.3.1 Exemplo (Uniforme $U(0, \theta)$)

$f(y; \theta) = \frac{1}{\theta}$ para $0 \leq y \leq \theta$.

1. **Escrever $L(\theta)$:**

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} \cdot \mathbb{I}(0 \leq y_i \leq \theta)$$
$$L(\theta) = \left(\frac{1}{\theta}\right)^n \cdot \mathbb{I}(\min(y_i) \geq 0) \cdot \mathbb{I}(\max(y_i) \leq \theta)$$

Seja $Y_{(n)} = \max(y_i)$. A função de verossimilhança é:

$$L(\theta) = \begin{cases} (1/\theta)^n & \text{se } \theta \geq Y_{(n)} \\ 0 & \text{se } \theta < Y_{(n)} \end{cases}$$

2. **Maximizar $L(\theta)$:** A função $L(\theta) = (1/\theta)^n$ é uma **função decrescente** em θ . Para maximizá-la, queremos o **menor valor possível de θ** .
3. **Encontrar o EMV:** Qual o menor valor que θ pode assumir? Pela restrição $L(\theta)$, θ *deve* ser maior ou igual a $Y_{(n)}$. O menor valor que θ pode assumir é, portanto, $Y_{(n)}$.
4. **Conclusão:** $\hat{\theta}_{EMV} = Y_{(n)}$.

8.4 Estatística Suficiente (Lista 9)

Definição 8.4 (Estatística Suficiente). *Uma estatística $T(\mathbf{Y})$ é suficiente para θ se ela captura toda a informação sobre θ contida na amostra $\mathbf{Y}$.*

Teorema 8.1 (Fatoração de Neyman). *$T(\mathbf{Y})$ é suficiente para θ se, e somente se, a f.d.p. conjunta pode ser fatorada como:*

$$f(\mathbf{y}; \theta) = g(T(\mathbf{y}), \theta) \cdot h(\mathbf{y})$$

onde $h(\mathbf{y})$ não depende de θ .

Propriedade 8.1 (EMV e Suficiência). *O EMV é uma função da estatística suficiente. Se T é suficiente, então $\hat{\theta} = g(T)$. Isto é poderoso: se você encontrar o EMV (ex: $\bar{Y}$ para λ da Poisson), você também encontrou uma função da estatística suficiente (a própria $T = \sum Y_i$ ou $\bar{Y}$).*

9 Propriedades Avançadas do EMV (Lista 9)

Aqui vemos por que o EMV é o "melhor" estimador.

9.1 Propriedade de Invariância

Teorema 9.1 (Invariância). *Se $\hat{\theta}$ é o EMV de θ , então o EMV de uma função $g(\theta)$ é simplesmente $g(\hat{\theta})$.*

Exemplo (Exponencial $Exp(\theta)$): $Y_i \sim Exp(\theta)$. A f.d.p. é $f(y; \theta) = \theta e^{-\theta y}$.

- O EMV do parâmetro θ é $\hat{\theta} = 1/\bar{Y}$.
- Qual o EMV da média, $\mu = \mathbb{E}(Y) = 1/\theta$?
- Pela invariância, $\hat{\mu} = g(\hat{\theta}) = 1/\hat{\theta} = 1/(1/\bar{Y}) = \bar{Y}$.
- Qual o EMV da $P(Y > 1) = e^{-\theta}$?
- Pela invariância, $P(\widehat{Y > 1}) = e^{-\hat{\theta}} = e^{-1/\bar{Y}}$.

9.2 Informação de Fisher e LIRC

O LIRC estabelece o limite teórico de quão "bom"(preciso) um estimador pode ser.

Definição 9.1 (Função Score $U(\theta)$). *É o vetor (ou valor) das primeiras derivadas da log-verossimilhança.*

$$U(\theta) = \frac{\partial l(\theta)}{\partial \theta}$$

Sob condições de regularidade, $\mathbb{E}[U(\theta)] = 0$.

Definição 9.2 (Informação de Fisher $I(\theta)$). Mede a quantidade de informação que a amostra $\mathbf{Y}$ (ou uma única Y) contém sobre θ . É a variância da função score.

$$I_n(\theta) = \mathbb{V}[U(\theta)] \quad (\text{Para a amostra toda})$$

Para uma amostra iid, $I_n(\theta) = n \cdot I_1(\theta)$. $I_1(\theta)$ é a informação de uma única observação. Forma computacional (mais fácil):

$$I_1(\theta) = -\mathbb{E} \left[\frac{\partial^2 \ln f(Y; \theta)}{\partial \theta^2} \right]$$

Teorema 9.2 (Limite Inferior de Cramer-Rao (LIRC)). Seja $T(\mathbf{Y})$ um estimador não-viciado para $g(\theta)$. A variância de T é limitada:

$$\mathbb{V}(T) \geq \frac{[g'(\theta)]^2}{I_n(\theta)} = \frac{[g'(\theta)]^2}{n \cdot I_1(\theta)}$$

Caso especial (T é estimador de θ): Se T é não-viciado para θ , $g(\theta) = \theta$ e $g'(\theta) = 1$. O limite se torna:

$$\mathbb{V}(T) \geq \frac{1}{I_n(\theta)} = \frac{1}{n \cdot I_1(\theta)}$$

Definição 9.3 (Eficiência). Um estimador não-viciado que atinge o LIRC (ou seja, $\mathbb{V}(T) = \frac{1}{I_n(\theta)}$) é dito **eficiente**.

9.2.1 Passo a Passo (Calcular LIRC para θ)

1. **Achar $l(\theta; y)$:** $l(\theta; y) = \ln f(y; \theta)$ (para UMA observação).
2. **Calcular $\frac{\partial^2 l}{\partial \theta^2}$:** A segunda derivada.
3. **Calcular $I_1(\theta)$:** $I_1(\theta) = -\mathbb{E} \left[\frac{\partial^2 l}{\partial \theta^2} \right]$. (Lembre-se de tomar a esperança em Y).
4. **Declarar LIRC:** O limite é $LIRC = \frac{1}{n \cdot I_1(\theta)}$.

9.3 Propriedades Assintóticas do EMV

Este é o teorema final que junta tudo.

Teorema 9.3 (Distribuição Assintótica do EMV). Sob condições de regularidade, o EMV $\hat{\theta}$ é:

1. **Consistente:** $\hat{\theta} \xrightarrow{p} \theta$.
2. **Assintoticamente Não-Viciado:** $\lim \mathbb{E}(\hat{\theta}) = \theta$.
3. **Assintoticamente Eficiente:** Atinge o LIRC.
4. **Assintoticamente Normal:** A distribuição de $\hat{\theta}$ se aproxima de uma Normal.

O teorema é formalmente escrito como:

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, [I_1(\theta)]^{-1})$$

Ou, de forma mais prática, para n grande:

$$\hat{\theta} \overset{\text{aprox.}}{\sim} N\left(\theta, \frac{1}{n \cdot I_1(\theta)}\right)$$

A variância assintótica do EMV é o LIRC! É por isso que ele é o "melhor" estimador.

9.4 Método Delta

Usado para encontrar a distribuição assintótica de uma função do EMV, $g(\hat{\theta})$.

Teorema 9.4 (Método Delta). Se $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, \sigma_{\hat{\theta}}^2)$, então

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{d} N(0, [g'(\theta)]^2 \cdot \sigma_{\hat{\theta}}^2)$$

Aplicação no EMV: Sabemos que $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, [I_1(\theta)]^{-1})$. Portanto, para $g(\hat{\theta})$ (o EMV de $g(\theta)$):

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{d} N(0, [g'(\theta)]^2 \cdot [I_1(\theta)]^{-1})$$

De forma prática:

$$g(\hat{\theta}) \overset{\text{aprox.}}{\sim} N\left(g(\theta), \frac{[g'(\theta)]^2}{n \cdot I_1(\theta)}\right)$$