

1 1. Matemática básica

Potências: $a^m a^n = a^{m+n}$; $a^m / a^n = a^{m-n}$; $(a^m)^n = a^{mn}$; $a^{-n} = 1/a^n$; $a^{1/n} = \sqrt[n]{a}$; $(ab)^n = a^n b^n$.

Logaritmos: $\ln(ab) = \ln a + \ln b$; $\ln(a/b) = \ln a - \ln b$; $\ln a^k = k \ln a$; $\ln e^x = x$; $e^{\ln x} = x$; $\ln 1 = 0$.

Produtório/Somatório (chave p/ L): $\prod_{i=1}^n c = c^n$; $\prod a^{y_i} = a^{\sum y_i}$; $\prod e^{g(y_i)} = e^{\sum g(y_i)}$; $\ln \prod f_i = \sum \ln f_i$; $\sum_{i=1}^n c = nc$; $\sum y_i = n\bar{y}$.
 $\sum (y_i - \bar{y}) = 0$; $\sum (y_i - \bar{y})^2 = \sum y_i^2 - n\bar{y}^2$; $\sum (y_i - \mu)^2 = \sum (y_i - \bar{y})^2 + n(\bar{y} - \mu)^2$.

Fatoração: $a^2 - b^2 = (a - b)(a + b)$; $(a \pm b)^2 = a^2 \pm 2ab + b^2$; $\frac{1}{p} + \frac{1}{1-p} = \frac{1}{p(1-p)}$; $\frac{a}{\theta} - \frac{b}{1-\theta} = 0 \Leftrightarrow \theta = \frac{a}{a+b}$.

Derivadas: $(x^n)' = nx^{n-1}$; $(\ln x)' = 1/x$; $(\ln g)' = g'/g$; $(e^g)' = g'e^g$; $(a^x)' = a^x \ln a$; $(uv)' = u'v + uv'$; $(u/v)' = \frac{u'v - uv'}{v^2}$; $(1/x)' = -1/x^2$; $(\ln(1 - x))' = -\frac{1}{1-x}$; $\frac{d}{d\theta} \ln \Gamma(\theta) = \psi(\theta)$ (digama), $\psi'(\theta)$ trigama; $\frac{d}{dk} y^k = y^k \ln y$.

Integrais: $\int x^n dx = \frac{x^{n+1}}{n+1}$; $\int e^{ax} dx = \frac{e^{ax}}{a}$; $\int \frac{dx}{x} = \ln |x|$; partes: $\int u dv = uv - \int v du$.
 $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$; $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$; $\Gamma(n) = (n-1)!$; $\Gamma(\frac{1}{2}) = \sqrt{\pi}$.

$\int_0^\infty y^{a-1} e^{-by} dy = \frac{\Gamma(a)}{b^a}$; $\int_0^\infty e^{-by} dy = \frac{1}{b}$.

Séries: $\sum_{y \geq 0} \frac{\lambda^y}{y!} = e^\lambda$; $\sum_{y \geq 0} r^y = \frac{1}{1-r}$; $\sum_{y=0}^n \binom{n}{y} a^y b^{n-y} = (a+b)^n$.

2 2. Distribuições

Dist.	$f(y; \theta)$	$E(Y)$	$\text{Var}(Y)$
$Ber(p)$	$p^y (1-p)^{1-y}$, $y \in \{0, 1\}$	p	$p(1-p)$
$Bin(m, p)$	$\binom{m}{y} p^y (1-p)^{m-y}$	mp	$mp(1-p)$
$P(\lambda)$	$e^{-\lambda} \lambda^y / y!$, $y \in \mathbb{N}$	λ	λ
$BN(\mu, \phi)$	$\frac{\Gamma(y+\phi)}{\Gamma(\phi)y!} (\frac{\mu}{\mu+\phi})^y (\frac{\phi}{\mu+\phi})^\phi$	μ	$\mu + \frac{\mu^2}{\phi}$
$Exp(\lambda)$	$\lambda e^{-\lambda y}$, $y > 0$	$1/\lambda$	$1/\lambda^2$
$G(\alpha, \beta)$	$\frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$	α/β	α/β^2
$N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-\mu)^2}{2\sigma^2}}$	μ	σ^2
$LN(\mu, \sigma^2)$	$\frac{1}{y\sqrt{2\pi\sigma^2}} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}$	$e^{\mu+\sigma^2/2}$	$(e^{\sigma^2} - 1)e^{2\mu+\sigma^2}$
$U(a, b)$	$\frac{1}{b-a} I_{[a,b]}(y)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
$Weib(b, k)$	$\theta k y^{k-1} e^{-\theta y^k}$	$Y^k \sim Exp(\theta)$	
χ^2_ν	$G(\nu/2, 1/2)$	ν	2ν

Fatos úteis: $\sum Y_i \sim Bin(n, p)$ (Ber); $\sum Y_i \sim P(n\lambda)$; $\sum Y_i \sim G(n, \lambda)$ (Exp); $\ln Y \sim N(\mu, \sigma^2)$ se $Y \sim LN$; $Y^2 \sim Exp(\theta)$ se $f = 2\theta y e^{-\theta y^2}$.

Se $T \sim G(n, \lambda)$: $E(1/T) = \frac{\lambda}{n-1}$, $E(1/T^2) = \frac{\lambda^2}{(n-1)(n-2)}$.

Normal: $\bar{Y} \sim N(\mu, \sigma^2/n)$; $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$; $\bar{Y} \perp S^2$; $\frac{\bar{Y}-\mu}{S/\sqrt{n}} \sim t_{n-1}$.

Estat. de ordem (F acum.): $F_{Y_{(n)}}(y) = [F(y)]^n$; $F_{Y_{(1)}}(y) = 1 - [1 - F(y)]^n$.

$U(0, \theta)$: $f_{Y_{(n)}} = \frac{ny^{n-1}}{\theta^n}$, $E = \frac{n\theta}{n+1}$, $E(Y_{(n)}^2) = \frac{n\theta^2}{n+2}$,

$\text{Var} = \frac{n\theta^2}{(n+1)^2(n+2)}$.

3 3. Esperança e variância

$E(aX+b) = aEX+b$; $\text{Var}(aX+b) = a^2 \text{Var}X$; $\text{Var}X = EX^2 - (EX)^2$; indep.: $\text{Var}(\sum a_i Y_i) = \sum a_i^2 \text{Var}Y_i$; $\text{Cov}(X, Y) = EXY - EXEY$.

i.i.d.: $E\bar{Y} = \mu$, $\text{Var}\bar{Y} = \sigma^2/n$; $E(S^2) = \sigma^2$ com $S^2 = \frac{1}{n-1} \sum (Y_i - \bar{Y})^2$.

Chebyshev: $P(|T - \theta| \geq \varepsilon) \leq \frac{E(T - \theta)^2}{\varepsilon^2} = \frac{EQM(T)}{\varepsilon^2}$.

Cauchy–Schwarz: $\text{Cov}(X, Y)^2 \leq \text{Var}X \text{Var}Y$.

4 4. Propriedades de estimadores

$T = T(Y_1, \dots, Y_n)$ estimador; t estimativa.

- **Viés:** $B(T) = E(T) - \theta$. Não-viciado $\Leftrightarrow E(T) = \theta \forall \theta$. Assint. não-viciado: $\lim_n ET = \theta$.
- **EQM:** $EQM(T) = E(T - \theta)^2 = \text{Var}(T) + [B(T)]^2$.
- **Consist. médio quadrática:** $\lim_{n \rightarrow \infty} EQM(T) = 0 \Leftrightarrow \text{Var}T \rightarrow 0$ e $B \rightarrow 0$.
- **Consist. em probabilidade:** $\lim_n P(|T - \theta| < \varepsilon) = 1$, $\forall \varepsilon > 0$. MQ $\Rightarrow$ prob. (via Chebyshev): $0 \leq P(|T - \theta| \geq \varepsilon) \leq EQM/\varepsilon^2 \rightarrow 0$.
- **Eficiência relativa:** T_1 melhor que T_2 se $EQM(T_1) \leq EQM(T_2) \forall \theta$ (com desig. estrita p/ algum). Se curvas se cruzam: nenhum domina.
- **Comb. linear** $\sum a_i Y_i$ não-viciada p/ $EY \Leftrightarrow \sum a_i = 1$. Var mínima: $a_i = 1/n$.
- $\frac{Y_1+Y_2}{2}$: $E = \mu$, $\text{Var} = \sigma^2/2 \not\rightarrow 0 \Rightarrow$ não consistente (não depende de n).

5 5. Método dos momentos

Momentos populacionais $\mu'_k = E(Y^k)$; amostrais $m'_k = \frac{1}{n} \sum Y_i^k$. Igualar $\mu'_k(\theta) = m'_k$, $k = 1, \dots, p$ ($p = n^0$ parâmetros) e resolver: $\hat{\theta}$.

Se EY não depende de θ (ex.: $U(-\theta, \theta)$, $EY = 0$),

usar $k = 2$: $\frac{\theta^2}{3} = \frac{1}{n} \sum Y_i^2 \Rightarrow \hat{\theta} = \sqrt{\frac{3}{n} \sum Y_i^2}$.

MM: em geral consistente, nem sempre não-viciado, pode cair fora de Θ (ex.: $2\bar{Y} < Y_{(n)}$ em $U(0, \theta)$).

6 6. Notação padrão de verossimilhança

Gatilho Zzx (início obrigatório): “Considere $Y_1, \dots, Y_n$ uma amostra aleatória de uma variável aleatória $Y \sim \dots$, com $f(y; \theta) = \dots$. Dado que observamos a amostra $\mathbf{y} = (y_1, \dots, y_n)^\top$, a função de verossimilhança é $\dots$ ”

- $L(\theta; \mathbf{y}) = \prod_{i=1}^n f(y_i; \theta)$ (fdp/fp conjunta de $\mathbf{y}$ vista como função de θ).
- $l(\theta; \mathbf{y}) = \ln L(\theta; \mathbf{y}) = \sum_{i=1}^n \ln f(y_i; \theta)$.
- **Escore:** $U(\theta; \mathbf{y}) = \frac{\partial}{\partial \theta} l(\theta; \mathbf{y})$; EMV: $U(\hat{\theta}; \mathbf{y}) = 0$ e $I_o(\hat{\theta}) > 0$.
- Inf. observada: $I_o(\theta; \mathbf{y}) = -\frac{\partial^2}{\partial \theta^2} l(\theta; \mathbf{y}) = -\frac{\partial}{\partial \theta} U(\theta; \mathbf{y})$.
- Multiparâmetro: $I_o(\boldsymbol{\theta}) = -\left[\frac{\partial^2 l}{\partial \theta_j \partial \theta_k}\right]$ (–Hessiana); EMV é máximo se $I_o(\hat{\boldsymbol{\theta}})$ pos. definida.
- Inf. esperada (Fisher): $I_e(\boldsymbol{\theta}) = \text{Var}[U(\boldsymbol{\theta}; \mathbf{Y})] = E[U(\boldsymbol{\theta}; \mathbf{Y})^2] = E[I_o(\boldsymbol{\theta}; \mathbf{Y})]$. i.i.d.: $I_e(\boldsymbol{\theta}) = n i_1(\boldsymbol{\theta})$.
- Razão de verossimilhança: $LR(\theta) = L(\theta)/L(\hat{\theta}) \in (0, 1]$.

- Deviance: $D(\theta) = -2 \ln LR(\theta) = 2[l(\hat{\theta}) - l(\theta)] \sim \chi^2_1$.

Suporte dependente de θ : escrever f com indicadora e expandir:

$\prod_{i=1}^n I_{[0, \theta]}(y_i) = 1 \Leftrightarrow I_{[0, \theta]}(y_i) = 1 \forall i \Leftrightarrow 0 \leq y_i \leq \theta \forall i \Leftrightarrow 0 \leq y_{(1)} \leq \dots \leq y_{(n)} \leq \theta \Leftrightarrow I_{[0, \infty)}(y_{(1)}) I_{[y_{(n)}, \infty)}(\theta) = 1$.

Ex. $U(0, \theta)$: $L(\theta; \mathbf{y}) = \theta^{-n} I_{[y_{(n)}, \infty)}(\theta)$, decrescente em $\theta \Rightarrow \hat{\theta} = Y_{(n)}$ (não derivar!).

$U(-\theta, \theta)$: $-\theta \leq y_i \leq \theta \forall i \Leftrightarrow \theta \geq \max |y_i| = \max(-y_{(1)}, y_{(n)}) \Rightarrow L = (2\theta)^{-n} I_{[\max |y_i|, \infty)}(\theta)$, $\hat{\theta} = \max |Y_i|$.

$U(\theta - 1, \theta + 1)$: $\theta - 1 \leq y_{(1)}$ e $y_{(n)} \leq \theta + 1 \Leftrightarrow y_{(n)} - 1 \leq \theta \leq y_{(1)} + 1$; $L = 2^{-n}$ constante: *qualquer $\hat{\theta} \in [y_{(n)} - 1, y_{(1)} + 1]$ é EMV* (não único).

Caso discreto com Θ finito: calcular $L(\theta)$ p/ cada $\theta \in \Theta$ e escolher o maior.

7 7. Regularidade e propriedades

Condições de regularidade: (i) θ identificável ($f(y; \theta_1) = f(y; \theta_2)$ q.t.p. $\Rightarrow \theta_1 = \theta_2$); (ii) suporte de f não depende de θ ; (iii) $\theta_0 \in$ interior de Θ ; (iv) f 2 vezes cont. diferenciável em θ ; (v) $\frac{\partial}{\partial \theta} e$ f (ou $\sum$) podem ser intercambiáveis.

Identidades de Bartlett: de $\int f(y; \theta) dy = 1$ e $\frac{\partial f}{\partial \theta} = f \frac{\partial \ln f}{\partial \theta}$:

$$E[U(\theta; \mathbf{Y})] = 0, \quad E[U(\theta; \mathbf{Y})^2] = -E[U'(\theta; \mathbf{Y})]$$

$\Rightarrow I_e(\theta) = \text{Var}(U) = E(U^2) = E(I_o)$.

Desig. de Cramér–Rao: T não-viciado p/ $\theta \Rightarrow \text{Var}(T) \geq I_e(\theta)^{-1}$ (LICR). Para $g(\theta)$: $\text{Var}(T) \geq \frac{[g'(\theta)]^2}{I_e(\theta)}$.

Prova: $ET = \theta \Rightarrow \int t \frac{\partial f}{\partial \theta} = 1 \Rightarrow E[TU] = 1 = \text{Cov}(T, U)$; C–S: $1 \leq \text{Var}(T) I_e(\theta)$.

Eficiente: não-viciado e $\text{Var}(T) = I_e(\theta)^{-1}$. Atinge LICR $\Leftrightarrow U(\theta; \mathbf{y}) = I_e(\theta)[T - \hat{\theta}]$.

Suficiência (fatoração de Neyman): T suficiente $\Leftrightarrow L(\theta; \mathbf{y}) = g(T(\mathbf{y}); \theta) h(\mathbf{y})$, h não depende de θ .

Família exponencial: $f = \exp\{c(\theta)T(y) + d(\theta) + S(y)\} \Rightarrow \sum T(Y_i)$ suficiente.

Propriedades do EMV (sob regularidade):

- Invariância: EMV de $g(\theta)$ é $g(\hat{\theta})$.
- Função de estatística suficiente.
- Consistente; assint. não-viciado; assint. eficiente.
- $\hat{\theta} \sim N(\theta, I_e(\theta)^{-1})$ (n grande); $\hat{\boldsymbol{\theta}} \sim N_p(\boldsymbol{\theta}, I_e^{-1})$.
- Não necessariamente não-viciado em amostra finita (ex.: $1/\bar{Y}$).

8 8. Métodos numéricos

Sem solução fechada para $U(\theta) = 0$:

Newton–Raphson: $\theta^{(r+1)} = \theta^{(r)} + \frac{U(\theta^{(r)})}{I_o(\theta^{(r)})}$; multi-

param.: $\boldsymbol{\theta}^{(r+1)} = \boldsymbol{\theta}^{(r)} + I_o^{-1}U$.

Escore de Fisher: troca I_o por I_e . Parar quando $|\theta^{(r+1)} - \theta^{(r)}| < \epsilon$. Chute: estimador de momentos.

Bissecção/Brent em $U(\theta) = 0$; **otimização direta** de l (optimize, optim); **perfilhamento:** substituir

$\hat{\theta}(k)$ em l e maximizar $l_p(k) = l(\hat{\theta}(k), k)$ em 1 dimensão.

Suporte dependente de θ ou L não diferenciável: *não* usar NR; analisar L graficamente / estat. de ordem. Θ restrito ($\theta > -1$, $\theta > 0$): reparametrizar ($\theta = e^\eta - 1$) ou otimizar com limites.

```
require(stats)
y <- c(4.2,0.7,2.5,1.9,7.9); n <- length(y)
Uk <- function(k) n/k + sum(log(y)) -
n*sum(y^k*log(y))/sum(y^k)
k <- uniroot(Uk, c(0.1,1.0))$root
theta <- n/sum(y^k)
```

9 9. Intervalos de confiança

Wald (assintótico): $\hat{\theta} \pm z_{1-\alpha/2} \sqrt{I_e(\hat{\theta})^{-1}}$ (ou $I_o(\hat{\theta})^{-1}$).

Deviance (verossimilhança): $\{\theta : D(\theta) \leq \chi^2_{1-\alpha}\}$, i.e. $LR(\theta) \geq e^{-\chi^2_{1-\alpha}/2}$ ($\chi^2_{0.95} = 3.841$, $c \approx 0.1465$). Resolver $2[l(\hat{\theta}) - l(\theta)] = 3.841$ (numérico); IC não necessariamente simétrico; invariante.

Quantidade pivotal $Q(\mathbf{Y}, \theta)$, distribuição livre de θ : $P(q_1 \leq Q \leq q_2) = 1 - \alpha$ e isolar θ .

Ex.: $\frac{\bar{Y}-\mu}{\sigma/\sqrt{n}} \sim N(0, 1)$; $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$; Exp: $2\lambda \sum Y_i \sim \chi^2_{2n}$; $U(0, \theta)$: $Y_{(n)}/\theta \sim Beta(n, 1)$, $P(Y_{(n)}/\theta \leq q) = q^n$.

$z_{0.975} = 1.96$, $z_{0.95} = 1.645$, $z_{0.995} = 2.576$.

10 10. Algoritmo metama (Estimação + IC)

1. **Zzx** + $f(y; \theta)$ com suporte (indicadora se depender de θ).
2. $L(\theta; \mathbf{y}) = \prod f(y_i; \theta)$: separar o que depende de θ ($\prod a^{y_i} = a^{\sum y_i}$, $\prod c = c^n$).
3. $l(\theta; \mathbf{y}) = \ln L$: termos sem θ como constante.
4. $U(\theta; \mathbf{y}) = \frac{\partial l}{\partial \theta}$; $U(\hat{\theta}) = 0 \Rightarrow \hat{\theta}$; trocar $y_i \rightarrow Y_i$ para o estimador.
5. $I_o(\theta; \mathbf{y}) = -\frac{\partial U}{\partial \theta}$; verificar $I_o(\hat{\theta}) > 0$ (máximo).
6. $I_e(\theta) = E[I_o(\hat{\theta}; \mathbf{Y})]$ (usar EY_i).
7. Propriedades: $E\hat{\theta}$ (viés), Var , LICR = I_e^{-1} , suficiência, consistência, dist. assintótica.
8. IC: (a) Wald; (b) Deviance; (c) Quantidade pivotal.

11 11. Algoritmo thm (Testes de hipóteses)

1. $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$ ($>$ ou $<$).
2. Nível $\alpha = P(\text{rej. } H_0 \mid H_0 \text{ verd.})$ (erro tipo I); $\beta = P(\text{não rej. } H_0 \mid H_1)$; poder $\pi = 1 - \beta$.
3. Tipo: bilateral / unilateral (direita/esquerda).
4. Estatística de teste (sob H_0):

Wald: $W = \frac{(\hat{\theta} - \theta_0)^2}{I_e(\hat{\theta})^{-1}}$ ou $Z = \frac{\hat{\theta} - \theta_0}{\sqrt{I_e(\hat{\theta})^{-1}}} \sim N(0, 1)$;

Escore: $S = \frac{U(\theta_0)^2}{I_e(\theta_0)} \sim \chi^2_1$;

RV: $D(\theta_0) = 2[l(\hat{\theta}) - l(\theta_0)] \sim \chi^2_1$ (χ^2_q ; $q = n^0$ restrições).

Neyman–Pearson (simples θ_0 vs θ_1): rejeitar se $\frac{L(\theta_0)}{L(\theta_1)} \leq k$.

5. Região crítica: $RC = \{Z \mid Z > z_{1-\alpha/2}\}$, $\{Z > z_{1-\alpha}\}$, $\{D > \chi^2_{1-\alpha}\}$. p-valor = $P(\text{estat.} \geq$

obs. $|H_0\rangle$.

6. Conclusão: estat. $\in RC$ (ou p-valor $< \alpha$) $\Rightarrow$ rejeita H_0 ao nível α ; caso contrário não rejeita. Interpretar no contexto.

12 12. Respostas-chave – Lista 6

E1 Ber: $E\hat{p} = p$; $\text{Var}\hat{p} = \text{EQM} = \frac{p(1-p)}{n} \rightarrow 0$.

E2 Normal: $E\hat{\mu} = \mu$; $\text{Var} = \text{EQM} = \sigma^2/n \rightarrow 0$.

E3: $\sum(Y_i - \bar{Y})^2 = \sigma^2 Q$, $Q \sim \chi^2_{n-1}$.

$\hat{\sigma}_1^2 = \frac{\sigma^2}{n} Q$: $E = \frac{n-1}{n} \sigma^2$ (viés $-\sigma^2/n$), $\text{Var} = \frac{2(n-1)\sigma^4}{n^2}$, $\text{EQM} = \frac{(2n-1)\sigma^4}{n^2}$.

$\hat{\sigma}_2^2 = S^2$: não-viciado, $\text{Var} = \text{EQM} = \frac{2\sigma^4}{n-1}$. Ambos $\rightarrow 0$.

Compar.: $\frac{2n-1}{n^2} < \frac{2}{n-1} \Leftrightarrow 2n^2 - 3n + 1 < 2n^2$ (sempre): $\hat{\sigma}_1^2$ tem menor EQM, apesar de viciado.

E4: $\bar{Y}_2 = \frac{Y_1+Y_2}{2}$: $E = \mu$, $\text{EQM} = \sigma^2/2$ constante $\Rightarrow$ não consistente.

E5: $E(\sum a_i Y_i) = \mu \sum a_i = \mu \Leftrightarrow \sum a_i = 1$.

E6: $\text{EQM}(T_1) = \frac{p(1-p)}{n}$; T_2 : $E = \frac{np+1}{n+2}$, viés $\frac{1-2p}{n+2}$, $\text{EQM}(T_2) = \frac{np(1-p)+(1-2p)^2}{(n+2)^2}$. Curvas se cruzam: T_2 melhor p/ p perto de $1/2$, T_1 perto de 0 ou $1 \Rightarrow$ nenhum uniformemente melhor.

E7: $f = \theta^2 y e^{-\theta y}$ é $G(2, \theta)$: $EY = 2/\theta = \bar{Y} \Rightarrow \tilde{\theta} = 2/\bar{Y}$.

E8 $U(0, \theta)$: $\text{EQM}(Y_{(n)}) = \frac{2\theta^2}{(n+1)(n+2)} \rightarrow 0$ (consistente, viciado); $\tilde{\theta} = 2\bar{Y}$: não-viciado, $\text{EQM} = \frac{\theta^2}{3n}$. Para $n \geq 3$: $\text{EQM}(Y_{(n)}) < \text{EQM}(2\bar{Y})$.

E9 $U(-\theta, \theta)$: $EY^2 = \theta^2/3 \Rightarrow \tilde{\theta} = \sqrt{3m_2}$.

13 13. Respostas-chave – Lista 7

1 Poisson: $l = -n\lambda + \sum y_i \ln \lambda - \sum \ln y_i!$; $U = -n + \sum \frac{y_i}{\lambda}$; $\hat{\lambda} = \bar{Y}$; $I_o = \sum \frac{y_i}{\lambda^2}$; $I_e = \frac{n}{\lambda}$; $\text{Var}\hat{\lambda} = \frac{\lambda}{n}$ = LICR: não-viciado, eficiente, consistente, $\sum Y_i$ suficiente.

2 Bernoulli: $U = \sum \frac{y_i}{p} - \frac{n-\sum y_i}{1-p}$; $\hat{p} = \bar{Y}$; $I_o = \sum \frac{y_i}{p^2} + \frac{n-\sum y_i}{(1-p)^2}$; $I_e = \frac{n}{p(1-p)}$: eficiente.

3/7 Exp: $l = n \ln \lambda - \lambda \sum y_i$; $U = \frac{n}{\lambda} - \sum y_i$; $\hat{\lambda} = 1/\bar{Y}$; $I_o = I_e = \frac{n}{\lambda^2}$; $E\hat{\lambda} = \frac{n\lambda}{n-1}$ (viciado; $\frac{n-1}{\sum Y_i}$ é não-viciado); consistente, assint. eficiente.

4 Gama: $l = n\alpha \ln \beta - n \ln \Gamma(\alpha) + (\alpha - 1) \sum \ln y_i - \beta \sum y_i$.
 α conh.: $U_\beta = \frac{n\alpha}{\beta} - \sum y_i \Rightarrow \hat{\beta} = \frac{\alpha}{\bar{Y}}$; $I_e = \frac{n\alpha}{\beta^2}$.
 β conh.: $U_\alpha = n \ln \beta - n\psi(\alpha) + \sum \ln y_i = 0 \Rightarrow \psi(\hat{\alpha}) = \ln \beta + \frac{1}{n} \sum \ln y_i$ (numérico, NR); $I_o = I_e = n\psi'(\alpha)$.

5 BN (ϕ conh.): $l = \sum y_i \ln \mu - (\sum y_i + n\phi) \ln(\mu + \phi) + c$; $U = \frac{\sum y_i}{\mu} - \frac{\sum y_i + n\phi}{\mu + \phi} \Rightarrow \hat{\mu} = \bar{Y}$; $I_e = \frac{n\phi}{\mu(\mu + \phi)}$; $\text{Var}\bar{Y} = \frac{\mu + \mu^2/\phi}{n} = I_e^{-1}$: eficiente.

6 Log-normal: $l = -\frac{n}{2} \ln(2\pi\sigma^2) - \sum \ln y_i - \frac{1}{2\sigma^2} \sum (\ln y_i - \mu)^2$; $\hat{\mu} = \frac{1}{n} \sum \ln Y_i$; $\hat{\sigma}^2 = \frac{1}{n} \sum (\ln Y_i - \hat{\mu})^2$ (viciado); $I_e = \text{diag}(\frac{n}{\sigma^2}, \frac{n}{2\sigma^4})$.

8: $L = (2\theta)^n \prod y_i e^{-\theta \sum y_i^2} = g(\sum y_i^2; \theta) h(\mathbf{y}) \Rightarrow \sum Y_i^2$ suficiente; $\hat{\theta} = \frac{n}{\sum Y_i^2}$; $I_e = \frac{n}{\theta^2}$.

9 Weibull: k conh.: $\hat{\theta} = \frac{n}{\sum Y_i^k}$. k desconh.: $U_k = \frac{n}{k} + \sum \ln y_i - \theta \sum y_i^k \ln y_i$; perfilhar $\hat{\theta}(k)$: $\frac{n}{k} + \sum \ln y_i - \frac{n \sum y_i^k \ln y_i}{\sum y_i^k} = 0$ (NR/bisseção). Dados: $\hat{k} \approx 1.422$, $\hat{\theta} \approx 0.150$.

10: (a) $(\theta + 1)x^\theta$: regular; $U = \frac{n}{\theta+1} + \sum \ln x_i$, $\hat{\theta} = -1 - \frac{n}{\sum \ln x_i}$, $I_o = \frac{n}{(\theta+1)^2}$; fechado, NR converge (respeitar $\theta > -1$). (b) $U(-\theta, \theta)$: suporte depende de θ , $\hat{\theta} = \max |x_i|$, sem derivação (NR inadequado). (c) $U(\theta-1, \theta+1)$: L plana em $[x_{(n)}-1, x_{(1)}+1]$, EMV não único; otimizador numérico retorna qualquer ponto do intervalo.