

CE309 – Inferência: Cheatsheet

Propriedades, Momentos, EMV

1. Potências e frações
- $a^m a^n = a^{m+n}$; $a^m / a^n = a^{m-n}$; $(a^m)^n = a^{mn}$
 - $a^{-n} = 1/a^n$; $a^{1/n} = \sqrt[n]{a}$; $a^0 = 1$; $(ab)^n = a^n b^n$
 - $\frac{a}{b} + \frac{c}{d} = \frac{ad+bc}{bd}$; $\frac{a/b}{c/d} = \frac{ad}{bc}$
 - $(a \pm b)^2 = a^2 \pm 2ab + b^2$; $a^2 - b^2 = (a - b)(a + b)$
 - $\frac{1}{n} - \frac{1}{n-1} = \frac{-1}{n(n-1)}$; $\frac{n-1}{n} = 1 - \frac{1}{n}$

2. Logaritmos e exponencial
- $\ln(ab) = \ln a + \ln b$; $\ln(a/b) = \ln a - \ln b$
 - $\ln(a^k) = k \ln a$; $\ln e^x = x$; $e^{\ln x} = x$; $\ln 1 = 0$
 - $e^a e^b = e^{a+b}$; $\prod_{i=1}^n e^{a_i} = e^{\sum_{i=1}^n a_i}$
 - $\ln \prod_{i=1}^n a_i = \sum_{i=1}^n \ln a_i$; $\prod_{i=1}^n a_i^k = (\prod_{i=1}^n a_i)^k$
 - $\prod_{i=1}^n c = c^n$; $\prod_{i=1}^n c a_i = c^n \prod_{i=1}^n a_i$
 - $\ln$ é estritamente crescente: $\arg \max L = \arg \max \ln L$

3. Somatórios
- $\sum_{i=1}^n c = nc$; $\sum_{i=1}^n c a_i = c \sum_{i=1}^n a_i$; $\sum_{i=1}^n (a_i + b_i) = \sum a_i + \sum b_i$
 - $\sum_{i=1}^n Y_i = n\bar{Y}$; $\sum_{i=1}^n (Y_i - \bar{Y}) = 0$
 - $\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n\bar{Y}^2$
 - $\sum_{i=1}^n (Y_i - \mu)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 + n(\bar{Y} - \mu)^2$

4. Derivadas
- | | |
|----------------------|-------------------------|
| $f(x)$ | $f'(x)$ |
| c | 0 |
| x^k | kx^{k-1} |
| $1/x$ | $-1/x^2$ |
| e^x ; $e^{g(x)}$ | e^x ; $g'(x)e^{g(x)}$ |
| a^x | $a^x \ln a$ |
| $\ln x$; $\ln g(x)$ | $1/x$; $g'(x)/g(x)$ |
| $\ln \Gamma(x)$ | $\psi(x)$ (digama) |
| x^k em k | $x^k \ln x$ |
- Cadeia: $[f(g(x))]' = f'(g(x)) g'(x)$
 - Produto: $(uv)' = u'v + uv'$; Quociente: $(u/v)' = \frac{u'v - uv'}{v^2}$
 - Ex.: $\frac{d}{d\theta} [-n \ln(2\theta + 1)] = -\frac{2n}{2\theta+1}$

5. Integrais
- $\int x^k dx = \frac{x^{k+1}}{k+1}$ ($k \neq -1$); $\int \frac{1}{x} dx = \ln|x|$
 - $\int e^{ax} dx = \frac{1}{a} e^{ax}$; partes: $\int u dv = uv - \int v du$
 - Gama**: $\Gamma(\alpha) = \int_0^\infty y^{\alpha-1} e^{-y} dy$
 - $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$; $\Gamma(n) = (n - 1)!$; $\Gamma(\frac{1}{2}) = \sqrt{\pi}$
 - Chave**: $\int_0^\infty y^{\alpha-1} e^{-\beta y} dy = \frac{\Gamma(\alpha)}{\beta^\alpha}$
 - $\int_0^\infty y^k e^{-\theta y} dy = \frac{k!}{\theta^{k+1}}$
 - Densidade integra 1: use para "completar" o núcleo.

6. Esperança e Variância
- $\mathbb{E}(aY + b) = a\mathbb{E}Y + b$; $\mathbb{E} \sum_{i=1}^n a_i Y_i = \sum_{i=1}^n a_i \mathbb{E}Y_i$
 - $\text{Var}(aY + b) = a^2 \text{Var}(Y)$; $\text{Var}(Y) = \mathbb{E}(Y^2) - [\mathbb{E}Y]^2$
 - Indep.: $\text{Var}(\sum_{i=1}^n a_i Y_i) = \sum_{i=1}^n a_i^2 \text{Var}(Y_i)$
 - iid: $\mathbb{E}\bar{Y} = \mu$; $\text{Var}(\bar{Y}) = \sigma^2/n$
 - $\mathbb{E}(Y^2) = \text{Var}(Y) + \mu^2$; $\mathbb{E}(\bar{Y}^2) = \sigma^2/n + \mu^2$
 - $\mathbb{E}g(Y) = \int g(y)f(y)dy$ ou $\sum g(y)p(y)$
 - Jensen: g convexa $\Rightarrow \mathbb{E}g(Y) \geq g(\mathbb{E}Y)$ (ex.: $\mathbb{E}[1/\bar{Y}] \geq 1/\mathbb{E}\bar{Y}$)
 - $\mathbb{E} \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n - 1)\sigma^2$

7. Distribuições

Dist.	$f(y)$	EY	VarY
Ber(p)	$p^y (1 - p)^{1-y}$	p	$p(1 - p)$
Bin(n, p)	$\binom{n}{y} p^y (1 - p)^{n-y}$	np	$np(1 - p)$
Poi(λ)	$\frac{e^{-\lambda} \lambda^y}{y!}$	λ	λ
Exp(λ)	$\lambda e^{-\lambda y}$	$1/\lambda$	$1/\lambda^2$
Gama(α, β)	$\frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$	α/β	α/β^2
$N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-\mu)^2}{2\sigma^2}}$	μ	σ^2
$U(a, b)$	$\frac{1}{b-a}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

- BN**(μ, ϕ): $f = \frac{\Gamma(y+\phi)}{\Gamma(\phi)y!} (\frac{\phi}{\mu+\phi})^\phi (\frac{\mu}{\mu+\phi})^y$; $\mathbb{E} = \mu$; Var = $\mu + \frac{\mu^2}{\phi}$

- LogN**(μ, σ^2): $f = \frac{1}{y\sqrt{2\pi\sigma^2}} e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}$; $\ln Y \sim N(\mu, \sigma^2)$;

$$\mathbb{E} = e^{\mu + \sigma^2/2}$$

- Weibull**: $f = \theta k y^{k-1} e^{-\theta y^k}$; $Y^k \sim \text{Exp}(\theta)$
- $f = 2\theta y e^{-\theta y^2}$ é Weibull com $k = 2$: $Y^2 \sim \text{Exp}(\theta)$
- $f = \theta^2 y e^{-\theta y}$ é Gama(2, θ): $\mathbb{E}Y = 2/\theta$
- $U(-\theta, \theta)$: $\mathbb{E}Y = 0$, $\mathbb{E}Y^2 = \theta^2/3$
- Somas**: $\sum \text{Ber}(p) \sim \text{Bin}(n, p)$; $\sum \text{Poi}(\lambda) \sim \text{Poi}(n\lambda)$; $\sum \text{Exp}(\lambda) \sim \text{Gama}(n, \lambda)$
- $T \sim \text{Gama}(n, \lambda)$: $\mathbb{E}(1/T) = \frac{\lambda}{n-1}$, $\mathbb{E}(1/T^2) = \frac{\lambda^2}{(n-1)(n-2)}$
- Normal: $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$; $\mathbb{E}\chi_k^2 = k$, $\text{Var}\chi_k^2 = 2k$

8. Estatísticas de ordem
- $Y_{(1)} = \min Y_i$; $Y_{(n)} = \max Y_i$
 - $F_{Y_{(n)}}(y) = [F(y)]^n$; $f_{Y_{(n)}}(y) = n[F(y)]^{n-1} f(y)$
 - $F_{Y_{(1)}}(y) = 1 - [1 - F(y)]^n$
 - $U(0, \theta)$: $f_{Y_{(n)}} = \frac{ny^{n-1}}{\theta^n}$, $0 < y < \theta$
 - $\mathbb{E}Y_{(n)} = \frac{n\theta}{n+1}$; $\mathbb{E}Y_{(n)}^2 = \frac{n\theta^2}{n+2}$; $\text{Var}Y_{(n)} = \frac{n\theta^2}{(n+1)^2(n+2)}$
 - $\prod_{i=1}^n I(y_i \leq c) = I(y_{(n)} \leq c)$; $\prod_{i=1}^n I(y_i \geq c) = I(y_{(1)} \geq c)$

9. Propriedades de estimadores
- Vício**: $B(\hat{\theta}) = \mathbb{E}\hat{\theta} - \theta$; não viciado se $B = 0 \forall \theta$
 - Assint. não viciado: $\lim_{n \rightarrow \infty} \mathbb{E}\hat{\theta} = \theta$
 - EQM**: $\mathbb{E}(\hat{\theta} - \theta)^2 = \text{Var}(\hat{\theta}) + [B(\hat{\theta})]^2$
 - Cons. médio quadrática**: $\lim_{n \rightarrow \infty} \text{EQM}(\hat{\theta}) = 0$
 - $\iff \lim \text{Var}(\hat{\theta}) = 0$ e $\lim B(\hat{\theta}) = 0$
 - Cons. em probabilidade**: $\forall \varepsilon > 0$, $\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| > \varepsilon) = 0$

- Chebyshev/Markov**: $P(|\hat{\theta} - \theta| > \varepsilon) \leq \frac{\mathbb{E}(\hat{\theta} - \theta)^2}{\varepsilon^2} = \frac{\text{EQM}}{\varepsilon^2}$
 $\Rightarrow$ cons. MQ implica cons. em prob.
- LGN**: $\bar{Y} \xrightarrow{P} \mu$; g contínua: $g(\hat{\theta}) \xrightarrow{P} g(\theta)$

- Eficiência relativa**: prefere-se menor EQM; $\frac{\text{EQM}(\hat{\theta}_1)}{\text{EQM}(\hat{\theta}_2)}$
- Comb. linear** $\sum_{i=1}^n a_i Y_i$ não viciada p/ $\mathbb{E}Y \iff \sum_{i=1}^n a_i = 1$
- Ex.: $\frac{Y_1 + Y_2}{2}$: $\mathbb{E} = \mu$, $\text{Var} = \sigma^2/2 \not\rightarrow 0 \Rightarrow$ não consistente
- Roteiro (vício, var, EQM, consist.)**

- $\mathbb{E}\hat{\theta}$ por linearidade.
- $\text{Var}\hat{\theta}$ (indep.).
- EQM = Var + B^2 .
- $\lim_n \text{EQM} = 0$.
- Chebyshev $\Rightarrow$ cons. em prob.

- Resultados para conferência
- $\hat{p} = \bar{Y}$ (Ber): Var = $\frac{p(1-p)}{n}$ = EQM
 - $\hat{\mu} = \bar{Y}$ (Normal): Var = $\frac{\sigma^2}{n}$ = EQM
 - $\sigma_2^2 = S^2$: $\mathbb{E} = \sigma^2$, Var = $\frac{2\sigma^4}{n-1}$
 - $\hat{\sigma}_1^2 = \frac{n-1}{n} S^2$: $\mathbb{E} = \frac{n-1}{n} \sigma^2$, $B = -\frac{\sigma^2}{n}$, Var = $\frac{2(n-1)\sigma^4}{n^2}$,
EQM = $\frac{(2n-1)\sigma^4}{n^2} < \frac{2\sigma^4}{n-1}$
 - $T_1 = Y/n$: EQM = $\frac{p(1-p)}{n}$

- $T_2 = \frac{Y+1}{n+2}$: $B = \frac{1-2p}{n+2}$, EQM = $\frac{np(1-p)+(1-2p)^2}{(n+2)^2}$
nenhum domina em todo p (compare em p perto de 1/2 vs extremos)

- $U(0, \theta)$, $Y_{(n)}$: $B = -\frac{\theta}{n+1}$, EQM = $\frac{2\theta^2}{(n+1)(n+2)}$

- $U(0, \theta)$, $2\bar{Y}$: $B = 0$, EQM = $\frac{\theta^2}{3n}$ ($Y_{(n)}$ melhor p/ $n > 2$)

10. Método dos Momentos
- Momento pop.: $\mu_k = \mathbb{E}(Y^k)$; amostral: $m_k = \frac{1}{n} \sum_{i=1}^n Y_i^k$
 - Passos**: 1) calcule $\mathbb{E}(Y^k)$ em função de θ ; 2) iguale $\mu_k(\theta) = m_k$ ($k = 1, \dots, n^0$ de parâmetros); 3) isole θ .
 - Se $\mathbb{E}Y$ não depende de θ (ex.: $\mathbb{E}Y = 0$), use $\mathbb{E}Y^2$.
 - Gama(2, θ): $\frac{\theta}{2} = \bar{Y} \Rightarrow \hat{\theta} = \frac{2}{\bar{Y}}$
 - $U(0, \theta)$: $\frac{\theta}{2} = \bar{Y} \Rightarrow \hat{\theta} = 2\bar{Y}$
 - $U(-\theta, \theta)$: $\frac{\theta^2}{3} = m_2 \Rightarrow \hat{\theta} = \sqrt{\frac{3}{n} \sum_{i=1}^n Y_i^2}$

11. Suficiência
- Fatoração (Neyman)**: T é suficiente $\iff L(\theta; \mathbf{y}) = g(T(\mathbf{y}); \theta) h(\mathbf{y})$, h sem θ
 - Ex.: $f = 2\theta y e^{-\theta y^2}$: $L = (2\theta)^n (\prod_{i=1}^n y_i) e^{-\theta \sum y_i^2}$
 - $g = \theta^n e^{-\theta \sum y_i^2}$, $h = 2^n \prod y_i \Rightarrow T = \sum_{i=1}^n Y_i^2$
 - Família exponencial $f = h(y)c(\theta)e^{w(\theta)t(y)}$: $\sum_{i=1}^n t(Y_i)$ suficiente

12. Máxima Verossimilhança
- $L(\theta) = \prod_{i=1}^n f(y_i; \theta)$; $\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(y_i; \theta)$
 - Score**: $U(\theta) = \frac{d\ell(\theta)}{d\theta}$; EMV resolve $U(\hat{\theta}) = 0$

- Inf. observada**: $I_o(\theta) = -\frac{d^2 \ell(\theta)}{d\theta^2}$; máximo se $I_o(\hat{\theta}) > 0$

- Inf. esperada**: $I_e(\theta) = \mathbb{E}[I_o(\theta)] = \mathbb{E}[U(\theta)^2]$; $\mathbb{E}U(\theta) = 0$

- iid: $I_e(\theta) = n i_1(\theta)$

Roteiro EMV (regular)

- $L(\theta)$ (agrupe: $c^n, \prod, e^\Sigma$).
- $\ell(\theta)$ (log transforma $\prod \rightarrow \Sigma$).
- $U(\theta)$.
- $U(\hat{\theta}) = 0$, isole $\hat{\theta}$.
- $I_o(\hat{\theta}) > 0$.
- Troque y_i por Y_i (estimador).

Suporte depende de θ

Escreva f com indicadora; reduza $\prod I$ a $Y_{(1)}$, $Y_{(n)}$. Se ℓ é monótona onde $L > 0$, o máximo é na **fronteira**. Não iguale $U = 0$.

- $U(0, \theta)$: $\hat{\theta} = Y_{(n)}$

- $U(0, 2\theta + 1)$: $\hat{\theta} = \frac{Y_{(n)}-1}{2}$

- $U(-\theta, \theta)$: $\hat{\theta} = \max|Y_i| = \max\{-Y_{(1)}, Y_{(n)}\}$

- $f = \frac{1}{2}$, $\theta - 1 \leq x \leq \theta + 1$: $L = 2^{-n}$ constante em $[x_{(n)} - 1, x_{(1)} + 1] \Rightarrow$ EMV **não único**

Propriedades do EMV

- Invariância**: EMV de $g(\theta)$ é $g(\hat{\theta})$
- Função de estatística suficiente; pode ser viciado em n finito
- Sob regularidade: consistente, assint. não viciado, assint. eficiente
- $\hat{\theta} \stackrel{L}{\sim} N(\theta, I_e(\theta)^{-1})$
- Cramér–Rao**: $\hat{\theta}$ não viciado $\Rightarrow \text{Var}(\hat{\theta}) \geq \frac{1}{I_e(\hat{\theta})}$; igualdade: eficiente (UMVU)

- Regularidade falha se suporte depende de θ

EMVs das listas (conferência)

Modelo	$\hat{\theta}$	I_e / obs.
Poi(λ)	$\bar{Y}$	n/λ ; NV, efíc.
Ber(p)	$\bar{Y}$	$\frac{n}{p(1-p)}$; NV, efíc.
Exp(λ)	$1/\bar{Y}$	n/λ^2 ; $\mathbb{E} = \frac{n\lambda}{n-1}$
Gama, α conh.	$\hat{\beta} = \alpha/\bar{Y}$	$n\alpha/\beta^2$
Gama, β conh.	$\psi(\hat{\alpha}) = \ln \beta + \overline{\ln Y}$	numérico
BN, ϕ conh.	$\hat{\mu} = \bar{Y}$	$\frac{n\phi}{\mu(\mu+\phi)}$
LogN	$\hat{\mu} = \overline{\ln Y}$ $\hat{\sigma}^2 = \frac{1}{n} \sum (\ln Y_i - \hat{\mu})^2$	NV viciado
$2\theta y e^{-\theta y^2}$	$n / \sum Y_i^2$	n/θ^2
Weibull, k conh.	$n / \sum Y_i^k$ $(\theta + 1)x^\theta$	n/θ^2
	$-\frac{n}{\sum \ln X_i} - 1$	$n/(\theta + 1)^2$

- Sem forma fechada (ψ , k da Weibull): resolver $U = 0$ numericamente

13. Métodos numéricos

- Newton–Raphson**: $\theta^{(r+1)} = \theta^{(r)} + \frac{U(\theta^{(r)})}{I_o(\theta^{(r)})}$

- Escore de Fisher**: troque I_o por I_e
- Parada: $|\theta^{(r+1)} - \theta^{(r)}| < \epsilon$; chute inicial: est. de momentos
- Weibull, k desconhecido (perfil)**: com $\hat{\theta}(k) = n / \sum y_i^k$,

$$U(k) = \frac{n}{k} + \sum_{i=1}^n \ln y_i - \frac{n \sum y_i^k \ln y_i}{\sum y_i^k} = 0$$

- $U'(k)$ para N–R: derive cada termo; $\frac{d}{dk} y^k = y^k \ln y$
- Suporte em θ (ex. 10): não usar N–R; L descontínua, máximo na fronteira